

Transfer Öğrenme Kullanarak Deepfake Tespiti: FaceForensics++ Üzerinde Hiperparametre ve Model Mimarisi Analizi

Sorumlu Kişi:	Kader Terik
Araştırma Grubu:	BAUN AISC
Makale Türü:	Araştırma Raporu
Rapor Tarihi:	09.07.2026
Durum:	Tamamlandı

Özet

Bu çalışmada, derin evrişimli sinir ağları (CNN) kullanarak FaceForensics++ C23 veri setindeki deepfake görüntülerinin tespiti incelenmiştir. Önceden kırılmış yüz bölgelerinden oluşan bu veri seti, GAN'lar vb. ile oluşturulan hiper-gerçekçi sahte medyanın bilgi güvenliği açısından oluşturduğu tehditlere yanıt aramaktadır. Deneysel olarak, tek değişkenli izolasyon yöntemiyle beş farklı deney (EXP001–EXP005) gerçekleştirilmiş; veri artırımı, öğrenme oranı, optimizasyon algoritması ve model mimarisi ayrı ayrı değerlendirilmiştir. Bulgularımız, basit RGB/geometrik augmentasyonların ('Veri Artırımı Paradoksu') tespit özgüllüğünü (%36.5) dramatik biçimde düşürdüğünü göstermiştir. Öte yandan, öğrenme oranının 0.001'den 0.0001'e düşürülmesi, dengesiz veri setinde (%1:6 gerçek:sahte) sınıf dengesizliğinin etkisini hafifleterek özgüllüğü %88.5'e çıkarmıştır. En yüksek genel doğruluk (%94.42) ve F1 (%96.69) skorunu EfficientNet-B0 elde etmiştir, ancak bu modelin eğitim süresi (%46 daha uzun) klasik ResNet18'e göre çok daha yüksektir. Sonuçlar, dikkatli hiperparametre optimizasyonunun ("ince öğrenme" yöntemi) daha hesaplı modellerde bile mükemmel performans sağlayabildiğini vurgulamaktadır.

1. Giriş

Derin üretici modellerdeki (ör. GAN) hızlı ilerlemeler, haber, kimlik doğrulama ve adli bilişim gibi alanlarda sentetik medyanın ("deepfake" video/imalarının) yaygın kullanımına yol açmıştır. Bu durum, kimlik hırsızlığı ve dezenformasyon kampanyaları gibi güvenlik açıklarını derinleştirmektedir. Örneğin, gerçekçi deepfake saldırıları, birey ve kuruluşlara büyük maddi ve itibar zararları verebilmekte; 2025 itibarıyla deepfake pazarı ~\$1.9 milyar değerinde olup %95'i dolandırıcılık, yanlış bilgilendirme ve gizlilik ihlallerine hizmet etmektedir. Bu tehditlere karşı, derin öğrenmeye dayalı tespit sistemleri geliştirilmiştir, ancak çoğu algoritmanın performansı eğitim-veri özelliklerine ve hiperparametre ayarlarına çok duyarlıdır. Yanlış etiketlemeye (false positive) karşı bağımsızlık sağlamak için modelin genelleme yeteneği kritik önemdedir. Gerçek

dünyada eğitim ve test dağılımları arasındaki farklar nedeniyle pek çok derinfake detektörün eğitim-seti içi başarısı yüksektir ama çapraz-set genelleme performansı düşüktür. Ayrıca, FaceForensics++ gibi veri setlerinde Gerçek:Sahte örnek oranı 1:6 gibi büyük dengesizlikler, modelin gerçek sınıfı yanlış sınıflandırma eğilimini artırmaktadır. Bu çalışmada, transfer öğrenme yöntemiyle önceden eğitilmiş CNN modelleri (ResNet18 ve EfficientNet-B0) kullanılarak bu sorunlara yönelik kapsamlı deneyler yapılmıştır.

2. Metodoloji

2.1 Veri Seti ve Ön İşleme

Deneylerde FaceForensics++ C23 veri setinin önceden kırılmış yüz bölgesi alt kümesi kullanılmıştır. FaceForensics++, 1000 özgün video dizisi ve dört farklı sahte yüz manipülasyon yöntemi (DeepFakes, Face2Face, FaceSwap, NeuralTextures) içeren bir benchmark veri setidir. Bizim alt kümede her video yüksek kalite (C23 sıkıştırma) ile karelere ayrılmış ve yalnızca yüz bölgeleri (MTCNN ile tespit edilip kırılarak) alınmıştır. Böylece, arka plan bilgisi modelden büyük ölçüde izole edilmiştir. Verisinde doğası gereği %15 gerçek, %85 sahte örnek bulunmaktadır ($\approx 1:6$ dengesizlik). Tüm görüntüler evrişimli modeller için standart 224x224 boyutuna yeniden ölçeklendirilmiş ve ImageNet istatistiğine göre normalize edilmiştir (mean=[0.485,0.456,0.406], std=[0.229,0.224,0.225]). Veri artırımı olarak sadece EXP002 deneyinde, yatay çevirme, 15° döndürme ve renk-saydamlık (ColorJitter) teknikleri uygulanmıştır.

2.2 Deneysel Tasarım

Beş deney boyunca tek değişkenli izolasyon yöntemi izlenmiştir: her deneyde yalnızca bir hiperparametre veya mimari özelliği değiştirilmiş, diğer tüm ayarlar sabit tutulmuştur. Deneylerin temel ayarları şunlardır:

- EXP001 (Baseline): ResNet18, optimizer=Adam, öğrenme oranı=0.001, herhangi bir veri artırımı yok.
- EXP002 (Veri Artırımı): Baseline'a ek olarak Data Augmentation (Rastgele Flip, 15° dönüşüm, ColorJitter).
- EXP003 (Öğrenme Oranı): Baseline modelde LR değerini 0.0001'e indirerek.
- EXP004 (Optimizatör): Baseline modelde Adam yerine AdamW optimizasyonu kullanarak.
- EXP005 (Mimari): Baseline ayarları (ResNet18 yerine EfficientNet-B0) ile sürdürülmüş model.

Her deneyde 3 epoch boyunca eğitim yapılmış, test setindeki metrikler (Doğruluk, Kesinlik, Duyarlılık, Özgüllük, F1, ROC-AUC) hesaplanmıştır. Eğitim süresi ölçülmüş ve deney sonuçları experiment_log.csv dosyasına kaydedilmiştir.

3. Bulgular

Aşağıdaki tablo, EXP001–EXP005 deneyleri için elde edilen performans metriklerini özetlemektedir. Her sütun, ilgili metrikleri içermektedir:


Deney (EXP)	Doğruluk	Kesinlik	Duyarlılık	Özgüllük	F1 Skoru	Süre (dk)
EXP001 (Baseline)	91.84%	94.68%	95.77%	69.54%	95.22%	24.49
EXP002 (Augment.)	88.99%	89.75%	98.26%	36.51%	93.82%	~25.0
EXP003 (LR=0.0001)	94.12%	97.91%	95.11%	88.51%	96.49%	~25.0
EXP004 (AdamW)	91.65%	92.16%	98.56%	52.51%	95.25%	~25.0
EXP005 (EfficientNet)	94.42%	97.47%	95.93%	85.90%	96.69%	35.84

Tablo 1: Deney sonuçları (Accuracy, Precision, Recall, Specificity, F1, Eğitim Süresi).

4. Tartışma

4.1. Baseline ve Sınıf Dengesizliği


EXP001 (Baseline) deneyi, **%91.84** genel doğruluk ve 0.950 ROC-AUC ile yüksek bir başarı göstermiştir. Ancak karmaşıklık matrisi detayına bakıldığında, gerçek sınıfın yanlış sınıflandırma oranı dikkat çekicidir: Gerçek örneklerin sadece %69.54'ü doğru tanınmıştır. Bu sonuçlar, Stanford Üniversitesi tarafından bildirilen derinfake tespit çalışmalarındaki “aşırı sınıf dengesizliği” sorununu doğrulamaktadır. Yüksek Recall (%95.77) ve düşük Specificity (%69.54) elde edilmiştir.



Şekil 1: EXP001 (Baseline) modelinin eğitim süreci ve performansına dair kavramsal görseller.

4.2. Veri Artırımı (Data Augmentation) Paradoksu


EXP002’de baseline modeline yalnızca fotometrik/geometrik augmentasyon eklendi. Bu, doğruluk ve F1 skorunda hafif düşüşe neden olurken özgüllükte dramatik bir çöküş gözlemlenmiştir (%36.51). Bu etki, literatürde “augmentasyon paradosu”na işaret eder.



Şekil 2: Veri artırımı (Augmentation) işlemlerine dair temsili konsept görseli.

4.3. Öğrenme Oranı ile Sınıf Dengesizliğini Aşmak


EXP003 deneyinde, tek fark olarak öğrenme oranı 0.001’den 0.0001’e düşürülmüştür. Bu değişiklik, modelin öğrenme adımlarının daha yavaş ve hassas olmasını sağlayarak ciddi performans artışına yol açmıştır. Doğruluk **%94.12**’ye, özgüllük ise %88.51’e yükselmiştir.



Şekil 3: Düşük öğrenme oranı (LR=0.0001) ile eğitim konsepti.

4.4. Optimizatör Kısıtları (Adam vs. AdamW)


EXP004’te sadece optimizasyon algoritması Adam’dan AdamW’ye değiştirilmiştir. AdamW, özgüllüğü daha da düşürerek %52.51’e çekmiş; bu da Adam’ın bu senaryoda daha yüksek gerçek yüz tanıma başarısı sağladığını göstermektedir.



Şekil 4: Adam ve AdamW optimizasyonunun etkisine dair temsili görsel.

4.5. Başarı-Oranı vs. Hesaplama Maliyeti Dengesi

EXP005'te EfficientNet-B0 mimarisi kullanılmıştır. EfficientNet-B0, daha karmaşık yapısı sayesinde en yüksek doğruluk (%94.42) ve F1 (%96.69) skorlarını elde etmiştir. Ancak eğitim süresi 35.84 dakikaya çıkarak %46 artış göstermiştir. ResNet18 ise daha az parametreye sahip olup daha kısa sürede benzer doğruluk sunarak maliyet-etkin bir seçenek olarak öne çıkmıştır.



Şekil 5: EfficientNet-B0 modeline dair temsili görsel.

5. Sonuç

Bu çalışma, FaceForensics++ C23 veri seti üzerinde kapsamlı deneylerle transfer öğrenmenin deepfake tespitine etkilerini ortaya koymuştur. Veri artırımı ile özgüllüğün gerilediği “Veri Artırımı Paradoksu” tespit edilmiş; öğrenme oranının düşürülmesinin ise bu sorunu büyük ölçüde giderdiği bulunmuştur. Ayrıca EfficientNet-B0 en yüksek performansı sunarken, klasik ResNet18 daha düşük eğitim maliyetiyle rekabetçi doğruluk ve daha yüksek özgüllük sağlamıştır.

BÖLÜM 2: TABLO AKTARIM

Ek A: Deney Takip Matrisi

Deney ID	Amaç	Değişken	Sonuçlar (Acc, Spec)	Çıkarım
EXP001	Baseline	LR=0.001	Acc:91.84, Spec:69.54	Sınıf dengesizliği sorunlu
EXP002	Augmentation	Flip/Rotate/ColorJitter	Acc:88.99, Spec:36.51	Veriler sığa benzer izler taşıdı
EXP003	Öğrenme Hızı	LR=0.0001	Acc:94.12, Spec:88.51	Düşük LR sorunları çözdü
EXP004	Optimizatör	AdamW	Acc:91.65, Spec:52.51	Adam daha iyi performans gösterdi
EXP005	Mimari	EfficientNet	Acc:94.42, Spec:85.90	En yüksek doğruluk, maliyet yüksek

Ek B: Detaylı Deney Takip Matrisi

Sorumlu Kişi	Kader Terik
Deney ID	EXP001, EXP002, EXP003, EXP004, EXP005
Deney Tarihi	09.07.2026
Kullanılan Veri Seti (Dataset)	FaceForensics++ (FF++) C23 – Önceden kırılmış yüz görüntüleri
Veri Ön İşleme & Hazırlık	Resize 224x224, ImageNet Normalizasyonu. EXP002'de ek: RandomFlip, Rotate 15°, ColorJitter
Eğitilen Model & Mimari	EXP001–EXP004: ResNet18 (Transfer Learning) EXP005: EfficientNet-B0 (Transfer Learning)
Deneyin Amacı / Hipotez	Hiperparametre (LR, Optimizer, Augmentation) ve mimari değişikliklerinin deepfake tespit performansına etkisini tek değişkenli izolasyon yöntemiyle ölçmek

Kullanılan Ölçüm Metrikleri	Accuracy, Precision, Recall, Specificity, F1-Score, ROC-AUC, Eğitim Süresi (dakika)
Elde Edilen Sonuçlar (Performans)	EXP001 (Baseline): Acc:%91.84 Spec:%69.54 F1:%95.22 AUC:0.950 EXP002 (Aug.): Acc:%88.99 Spec:%36.51 F1:%93.82 AUC:0.911 EXP003 (LR=0.0001): Acc:%94.12 Spec:%88.51 F1:%96.49 AUC:0.978 EXP004 (AdamW): Acc:%91.65 Spec:%52.51 F1:%95.25 AUC:0.944 EXP005 (EfficientNet): Acc:%94.42 Spec:%85.90 F1:%96.69 AUC:0.977
Oluşturulan Görseller & Grafikler	04_EXP001_Sonuclar.pdf, 05_EXP002_Sonuclar.pdf, 06_EXP003_Sonuclar.pdf, 07_EXP004_Sonuclar.pdf, 08_EXP005_Sonuclar.pdf (Her PDF: Eğitim Kayıp Eğrisi + Karmaşıklık Matrisi + ROC Eğrisi)
Deneyin Getirdiği Yenilik / Fark	"Veri Artırımı Paradoksu" keşfedildi: Basit RGB augmentasyon, cropped yüz setinde Specificity'yi %69→%36'ya düşürdü. Öğrenme oranını düşürmek (LR=0.0001) bu sorunu %88'e çıkardı.
Karşılaşılan Sorunlar / Dezavantajlar	Ağır sınıf dengesizliği (Gerçek:Sahte $\approx$ 1:6). EXP002'de augmentation paradoksu. EXP004'te AdamW kısa eğitimde dezavantajlı çıktı. EXP005'te eğitim süresi %46 arttı.
Gelecek Adım / Aksiyon Planı	Latent uzay tabanlı augmentasyon denenecek. Sınıf ağırlıklı öğrenme (Class-Weighted Loss) ile dengesizlik giderilecek. Daha fazla epoch ile EfficientNet test edilecek.
Deneyi Yürüten Kişi	Kader Terik
Sonuçlar Hangi Grafiklerle Görselleştirildi?	Eğitim & Test Kayıp Eğrisi, Karmaşıklık Matrisi (Isı Haritası), ROC-AUC Eğrisi
Grafik / Görsel Dosya Linki	04_EXP001_Sonuclar.pdf → 08_EXP005_Sonuclar.pdf
Çıkarım / Yorum	En kritik müdahale öğrenme oranını düşürmek (LR=0.001→0.0001) olmuştur. Augmentation veri setinin yapısına (cropped yüzler) uygun değildi. ResNet18+LR=0.0001, EfficientNet'e kıyasla %46 daha hızlı ve daha yüksek Specificity sunmaktadır.
Karşılaşılan Problemler	Sınıf dengesizliği modeli Sahte sınıfına yöneltti. EXP002 augmentation paradoksu. EXP004 AdamW kısa eğitimde yavaş adaptasyon.
Kod / GitHub Linki	04_EXP001.ipynb, 05_EXP002.ipynb, 06_EXP003.ipynb, 07_EXP004.ipynb, 08_EXP005.ipynb
Durum	TAMAMLANDI

Notlar

Tüm deneyler Google Colab (CUDA GPU) ortamında, aynı veri bölünmesiyle (train/test split) çalıştırılmıştır. Sonuçlar `experiment_log.csv` dosyasına kayıt edilmiştir.