



BAUN CENG

FaceForensics++ C23

1. Giriş

Deepfake teknolojileri, yapay zekâ ve derin öğrenme alanındaki gelişmelerle birlikte son yıllarda büyük ilerleme göstermiştir. Özellikle Generative Adversarial Networks (GAN) tabanlı yöntemler sayesinde gerçekçi sahte görüntü ve videolar üretilebilmekte, bu içerikler insanların gerçekte söylemediği veya yapmadığı olayları gerçekleştirmiş gibi gösterebilmektedir. Deepfake teknolojileri eğlence, sinema ve medya gibi alanlarda faydalı kullanım senaryolarına sahip olsa da yanlış bilgi yayılması, kimlik sahteciliği, manipülasyon ve güvenlik tehditleri gibi ciddi problemlere de yol açabilmektedir. Bu nedenle deepfake içeriklerin tespit edilmesi, günümüzde bilgisayarlı görü ve siber güvenlik alanlarında önemli bir araştırma konusu haline gelmiştir.

Deepfake tespit sistemlerinin geliştirilmesinde kullanılan veri setleri büyük önem taşımaktadır. Kullanılan veri setinin gerçekçi manipülasyonlar içermesi, farklı deepfake tekniklerini barındırması ve yeterli çeşitliliğe sahip olması model başarısını doğrudan etkileyebilmektedir. Bu çalışmada, deepfake tespit çalışmalarında yaygın olarak kullanılan FaceForensics++ veri setinin C23 sürümü incelenmiştir. Veri setinin yapısı, içerdiği manipülasyon türleri, sınıf dağılımları ve genel özellikleri değerlendirilmiş; ayrıca keşifsel veri analizi ile veri setine ilişkin temel çıkarımlar elde edilmiştir.

2. Veri Setini Anlama

Bu çalışmada FaceForensics++ (FF++) veri setinin C23 sürümü kullanılmıştır. FaceForensics++, deepfake ve yüz manipülasyonu tespit çalışmaları amacıyla geliştirilmiş, görüntü ve video tabanlı geniş ölçekli bir veri setidir. Veri seti, gerçek videolar ile farklı manipülasyon teknikleri kullanılarak oluşturulmuş sahte videolardan oluşmaktadır. Literatürde en yaygın kullanılan deepfake veri setlerinden biri olması nedeniyle, deepfake detection çalışmalarında önemli bir benchmark veri seti olarak kabul edilmektedir. Veri seti içerisinde hem orijinal videolar hem de çeşitli yüz manipülasyon yöntemleriyle oluşturulmuş sahte videolar bulunmaktadır. FaceForensics++ C23 veri seti temel olarak DeepFakes, Face2Face, FaceSwap, NeuralTextures, Original, DeepFakeDetection ve Csv olmak üzere sekiz adet kategoriden oluşmaktadır.

Veri seti toplamda 1000 adet orijinal (gerçek) videodan oluşmaktadır ve bu videolar üzerinde farklı manipülasyon teknikleri uygulanarak yaklaşık 6000 adet sahte video üretilmiştir; görseldeki bilgilere göre veri setinin klasör yapısı ve içeriği bu şekilde organize edilmiştir.

- **Original:** 1000 adet gerçek video içermektedir.
- **DeepFakes:** GAN (Generative Adversarial Networks) tabanlı modeller kullanılarak yüz değiştirme yöntemiyle üretilmiş sahte videolardır.
- **Face2Face:** Bir kişinin yüz ifadelerinin gerçek zamanlı olarak başka bir kişinin yüzüne aktarıldığı manipülasyon tekniğidir.

- **FaceShifter:** Yüksek kaliteli ve gerçekçiliği artırılmış yüz değiştirme yöntemidir. Bu teknik, kaynak yüzün kimliğini koruyarak hedef videodaki yüz ifadeleri ve ışık koşullarına uyum sağlayacak şekilde daha gerçekçi ve doğal görünümlü sahte yüzler üretir.
- **FaceSwap:** Bilgisayar grafikleri ve derin öğrenme yöntemleri kullanılarak yüzlerin değiştirildiği bir sahtecilik yöntemidir.
- **NeuralTextures:** Yüzün özellikle ağız ve çevresindeki bölgelerin yapay zeka ile yeniden modellenerek manipüle edildiği tekniktir. Bu yöntem, daha çok yüz ifadelerini değiştirmeye odaklanır ve ince detaylarda yapaylık izleri bırakabilir.
- **DeepFakeDetection:** Deepfake tespit algoritmalarını eğitmek amacıyla oluşturulmuş ek veri seti videolarını içermektedir. Bu veri seti, farklı manipülasyon tekniklerini içeren videolar sayesinde modellerin sahte içerikleri ayırt etme performansını artırmayı hedefler.
- **Csv:** Verilerin satır ve sütunlar halinde düzenlendiği, her sütunun genellikle virgül ile ayrıldığı basit dosya formatıdır. Veri setlerinde etiketleme ve tablo şeklinde veri saklamak için kullanılır.




FaceForensics++ veri seti farklı sıkıştırma seviyelerine sahiptir. Bunlar raw, c23 ve c40 sürümleridir. C23 sıkıştırma seviyesi, sosyal medya ve çevrim içi platformlarda karşılaşılan gerçek dünya video senaryolarına daha yakın bir yapı sunduğu için deepfake detection çalışmalarında yaygın şekilde tercih edilmektedir.

- **Raw:** Hiç sıkıştırılmamış, en yüksek kalite (en büyük dosya boyutu).
- **C23 (HQ):** "Yüksek Kalite" (Constant Rate Factor 23). Gerçek hayatta sosyal medya platformlarında (YouTube, Facebook vb.) sıkça karşılaşılan video kalitesine yakındır. Araştırmalarda en çok tercih edilen sürümdür.
- **C40 (LQ):** "Düşük Kalite". Videonun kalitesi ciddi oranda düşürülmüştür; bu sürüm, tespit algoritmalarının zorlu koşullarda ne kadar başarılı olduğunu test etmek için kullanılır.

3-Keşifsel Veri Analizi (EDA)


Bu çalışmada FaceForensics++ veri setinin yapısını daha iyi anlayabilmek amacıyla keşifsel veri analizi gerçekleştirilmiştir. Analiz sürecinde veri setindeki sınıf dağılımları, manipülasyon türleri, örnek görüntüler ve çeşitli görsel özellikler incelenmiştir. Gerçek ve manipüle edilmiş görüntüler arasındaki temel farklılıkları gözlemleyebilmek amacıyla çeşitli grafikler ve görselleştirme yöntemlerinden yararlanılmıştır.



Grafikte sunulan veri yapısı incelendiğinde, projenin temel girdisinin videolar olduğu görülmektedir. Her bir video karesi, bilgisayar tarafından piksel değerlerinden oluşan büyük sayısal matrisler olarak temsil edilmekte olup bu durum verinin nümerik bir yapıya sahip olduğunu göstermektedir. Bununla birlikte, videolara ait “original” ve “deepfakes” gibi sınıf etiketleri ise CSV dosyaları aracılığıyla elde edilen kategorik verilerdir ve modelin öğrenme sürecinde her örneğin hangi sınıfa ait olduğunu tanımlamaktadır. Sonuç olarak, kullanılan veri seti mixed (karma) bir yapıdadır; çünkü model hem ham piksel tabanlı sayısal verileri hem de bu verileri tanımlayan kategorik etiketleri birlikte kullanarak öğrenme gerçekleştirmektedir.


FaceForensics++ veri setindeki kategoriler incelendiğinde, her kategori türünün yaklaşık eşit sayıda video örneği içerdiği görülmektedir. Original, DeepFakes, FaceSwap, Face2Face, NeuralTextures, FaceShifter ve DeepFakeDetection kategorilerinin her biri yaklaşık 1000 video içermektedir. Bu durum, kategori türleri arasında dengeli bir dağılım bulunduğunu göstermektedir. Bununla birlikte veri seti genel olarak değerlendirildiğinde, sahte (fake) içeriklerin toplam sayısının gerçek (original) içeriklerden daha fazla olduğu görülmektedir. Bu nedenle veri seti, binary sınıflandırma açısından değerlendirildiğinde tam dengeli bir yapıya sahip değildir. Bu durum modelleme aşamasında modelin sahte sınıfa daha yatkın öğrenmesine neden olabilir.

Ayrıca görseldeki veri dağılımı, veri setinin bir sınıflandırma verisi olduğunu net bir şekilde ortaya koymaktadır. Regresyon analizi sürekli sayısal değerleri tahmin etmeye odaklanırken, bu grafikte görüldüğü üzere veriler "Original", "FaceSwap" ve "Deepfakes" gibi birbirinden bağımsız ve kesin sınırlarla ayrılmış kategorilere bölünmüştür.



Şekilde sunulan çubuk grafik, farklı deepfake üretim tekniklerinin (FaceSwap, Deepfakes, NeuralTextures vb.) görüntüler üzerinde bıraktığı hata seviyelerini karşılaştırmalı olarak göstermektedir. Bu grafik, her bir yöntemin geride bıraktığı “yakalanabilir iz” miktarını temsil etmekte olup, bazı tekniklerin daha profesyonel ve düşük hata izine sahip olduğu, bazı yöntemlerin ise daha belirgin ve yüksek hata izleri bıraktığı görülmektedir.

Hata seviyeleri, her bir manipülasyon yöntemine ait videolar üzerinde ortalama değer alınarak hesaplanmıştır. Örneğin, FaceSwap yöntemiyle üretilmiş birden fazla video analiz edilerek bu videolardaki hata parlaklık değerleri toplanmış ve video sayısına bölünerek ortalama bir hata seviyesi elde edilmiştir. Aynı işlem Deepfakes, NeuralTextures ve diğer yöntemler için de tekrarlanmıştır. Elde edilen bu ortalama değerler karşılaştırılarak her yöntemin grafikteki çubuk yüksekliği belirlenmiştir.




FaceForensics++ (C23) veri kümesine ait histogram analizinde, gerçek ve sahte görüntüler arasında belirgin istatistiksel farklılıklar gözlemlenmiştir. Gerçek görüntüler daha düşük yoğunluklarda yoğunlaşırken, sahte görüntüler daha yüksek yoğunluklara kaymış ve daha düzensiz bir dağılım göstermiştir. Bu durum, deepfake üretiminde kullanılan GAN tabanlı yöntemlerin görüntülerin doğal ışık dengesini bozduğunu ve çeşitli sıkıştırma kaynaklı bozulmalar oluşturduğunu göstermektedir. Ancak histogram analizi tek başına yeterli değildir, çünkü yalnızca piksel yoğunluğunu dikkate alır ve uzamsal bilgiyi göz ardı eder. Bu nedenle daha güvenilir tespit için gelişmiş derin öğrenme ve uzamsal analiz yöntemleriyle desteklenmesi gerekmektedir.

Analiz Edilen Yüz



Renk Kanalları (RGB) Histogram Analizi



Görüntüdeki kırmızı (R), yeşil (G) ve mavi (B) renk kanallarına ait değerlerin dağılımı analiz edilerek sayısal histogram grafiklerine dönüştürülmüştür. Bu işlemin temel amacı, görüntüdeki renk yoğunluklarını matematiksel olarak incelemektir. Yapay zeka tabanlı modeller, özellikle insan teni gibi doğal yüzeylerdeki renk geçişlerini ve ışık yansımalarını her zaman tam doğrulukla taklit edemeyebilir. Bu nedenle yapılan histogram analizi, gözle fark edilmesi zor olan yapay renk dağılımlarını ve tonlama hatalarını ortaya çıkarmak için kullanılmıştır. Böylece görüntüdeki olası yapaylıklar sayısal olarak tespit edilebilir hale getirilmiştir.

Orijinal Kare



Sahte (Deepfake) Kare




ELA Analizi (Dijital Değişim İzleri)



Video 634.mp4 İçin Manipülasyon Analizi


Değişim İzleri (%8.2)



Orijinal Doku (%91.8)

Orijinal kare ile sahte kare arasındaki piksel farkları hesaplanarak görüntüdeki değişimler analiz edilmiştir. Bu işlemin temel amacı, bir görüntüye dışarıdan müdahale edildiğinde oluşan dijital sıkıştırma izlerini tespit etmektir. Çünkü manipülasyon yapılan bölgelerde, orijinal alanlara kıyasla farklı piksel dağılımları ortaya çıkar. Bu sayede yapay zekânın yüzün hangi bölgelerine (göz, ağız, burun vb.) müdahale ettiği görsel olarak belirlenebilmiştir. Ayrıca her video karesi için oluşturulan pasta grafiği analizi standart bir yapı göstermemektedir. Yapay zekânın müdahale ettiği bölgenin kapsamı (örneğin sadece ağız çevresi ya da tüm yüz) ve kullanılan sıkıştırma kalitesi bu oranları doğrudan etkilemektedir.

Bu durum, her videonun kendine özgü bir dijital parmak izi taşıdığını ve manipülasyon izlerinin değişkenlik gösterdiğini ortaya koymaktadır.



Analiz sürecinde elde edilen teknik parametreler (ELA skoru, renk sapması, yüz boyutu vb.) arasındaki ilişkileri incelemek amacıyla bir korelasyon matrisi oluşturulmuş ve bu ilişkiler ısı haritası (heatmap) ile görselleştirilmiştir. Elde edilen sonuçlara göre, hata seviyesi (ELA) ile sahtelik olasılığı arasında 0.90–0.98 aralığında yüksek pozitif korelasyon tespit edilmiştir. Bu durum, ELA skorundaki artışın sahte video olasılığını güçlü şekilde artırdığını göstermektedir. Benzer şekilde, renk kanallarındaki (RGB) sapmaların da manipülasyon tespiti ile doğrudan ilişkili olduğu ve özellikle FaceSwap yönteminde bu sapmaların daha belirgin hale geldiği gözlemlenmiştir. Buna karşılık, yüz boyutu (çözünürlük) ile sahtelik tespiti arasındaki ilişkinin daha zayıf olduğu ve özellikle düşük çözünürlüklü görüntülerin manipülasyon izlerini kısmen gizleyebildiği belirlenmiştir. Bu analiz, farklı özellikler arasındaki ilişkileri ortaya koyarak modelin hangi parametrelere daha duyarlı olduğunu göstermeyi amaçlamaktadır. Elde edilen bulgular, sistemde ELA skoru ve renk sapması gibi özelliklerin daha belirleyici olduğunu, yüz boyutu gibi değişkenlerin ise daha sınırlı etkiye sahip olduğunu ortaya koymaktadır. Böylece korelasyon analizi, modelin güvenilirliğini değerlendirmede önemli bir “doğruluk göstergesi” olarak kullanılmaktadır.

4-Örnek Uygulama

Su an analiz edilen dosya: 769.mp4

Rastgele Veri Örnekleme ile Çoklu Aktör Analizi



Kare Örnekleme aşamasında, videoların tüm kareleri yerine belirli zaman aralıklarıyla seçilen örnek kareler kullanılmıştır. Örneğin her 30. kare alınarak video içeriğini temsil eden görüntüler elde edilmiştir. Bu yöntemin tercih edilme nedeni, standart videoların saniyede ortalama 30 kare içermesi ve tüm karelerin tek tek işlenmesinin yüksek işlem gücü ile zaman gerektirmesidir. Bu nedenle analiz sürecini hızlandırmak ve bilgisayar kaynaklarını (RAM/CPU) daha verimli kullanmak amacıyla, videoyu temsil eden en uygun kareler üzerinden işlem gerçekleştirilmiştir.

Su an analiz edilen şanslı video: 767.mp4



Analiz Edilecek Yüz Bölgesi



Yüz Tespiti ve Kırpma aşamasında, görüntü işleme algoritmaları kullanılarak videolardaki insan yüzleri tespit edilmiş ve yalnızca yüz bölgesi analiz için odak noktası olarak kırpılmıştır. Bu yöntemin uygulanmasının temel nedeni, deepfake manipülasyonlarının çoğunlukla yüz bölgesinde gerçekleştirilmesidir. Arka plan, kıyafet veya çevresel detayların analize dahil edilmesi veri gürültüsü oluşturarak modelin doğruluğunu olumsuz etkileyebilmektedir. Bu nedenle yalnızca yüz bölgesine odaklanılarak manipülasyon izlerinin daha hassas ve doğru şekilde tespit edilmesi amaçlanmıştır.

5-Analitik Değerlendirme

FaceForensics++ C23 veri seti, farklı deepfake üretim yöntemlerini içermesi ve geniş video çeşitliliği sunması nedeniyle deepfake tespit çalışmalarında güçlü bir benchmark veri setidir. Veri seti üzerinde yapılan histogram, RGB dağılımı, edge ve ELA analizlerinde sahte videolarda renk bozulmaları, sıkıştırma artefaktları ve yapısal düzensizlikler gözlemlenmiştir.

Bununla birlikte veri setinde yaklaşık 6000 sahte videoya karşılık 1000 gerçek video bulunması sınıf dengesizliği oluşturmaktadır. Ayrıca verilerin kontrollü ortamda üretilmiş olması, gerçek dünya senaryolarını tam olarak yansıtmayabilir.

6-Sonuç

FaceForensics++ veri seti, literatürde deepfake detection, yüz manipülasyonu analizi ve görüntü adli bilişimi çalışmalarında yaygın olarak kullanılmaktadır. Veri setine ilişkin temel çalışmalar arasında Andreas Rössler ve çalışma arkadaşları tarafından yayımlanan FaceForensics++ tanıtım çalışması yer almaktadır. Özellikle CNN tabanlı deepfake detection modelleri ve görüntü işleme yöntemleri bu veri seti üzerinde test edilmektedir.

Bu çalışmada ise literatürdeki birçok çalışmadan farklı olarak doğrudan model eğitimi yapılmamış, öncelikle veri setinin yapısı ve görsel özellikleri analiz edilmiştir. Histogram, RGB

dağılımı ve ELA incelemeleri ile veri setindeki manipölasyon izleri değerdendirilmiştir. İlerleyen çalışmalarda ise modeller kullanılarak deepfake tespit performanslarının karşılaştırılması mümkündür.

7-Kaynakça

- [S. B. C. Soundarya, G. H. L. ve N. K. C. M., "A Framework for Deepfake Detection using Convolutional Neural Network and Deep Features," *Procedia Computer Science*, 2025.](#)
- <https://www.kaggle.com/datasets/xdxd003/ff-c23>