



**Derin Sahte Medya: Deepfake Tespit Yöntemlerine
Yönelik Kapsamlı Bir Literatür İncelemesi ve
Gelecek Perspektifleri**

1. Giriş ve Kavramsal Çerçeve

Bu raporun amacı, deepfake teknolojisini; üretim süreçlerini, tespit metodolojilerini ve karşılaşılan temel zorlukları akademik düzlemde kapsamlı biçimde irdelemektir. Rapor bu doğrultuda üç ana eksenle ilerlemektedir:

- Deepfake üretim teknolojilerinin ve yüz manipülasyon türlerinin tanımlanması,
- Mevcut tespit yaklaşımlarının görüntü/video (öznitelik ve derin öğrenme tabanlı) ile ses (audio) boyutlarında multimodal bir vizyonla karşılaştırmalı biçimde ele alınması,
- Benchmark veri setlerinin ve alanın gelecek yönelimlerinin değerlendirilmesi.

2. Yüz Manipülasyonu Türleri

Literatürde yüz manipülasyonu dört ana kategoride incelenmektedir. Bu sınıflandırma, manipülasyonun kapsam ve derinliğine göre yapılmakta olup her kategorinin kendine özgü teknik gereksinimleri, kullanılan veri setleri ve tespit güçlükleri bulunmaktadır.

2.1 Bütünsel Yüz Sentezi (Entire Face Synthesis)

Bütünsel yüz sentezi, gerçekte var olmayan kişilere ait fotografik gerçeklikte yüz görüntüleri üretmeyi hedeflemektedir. Bu kategori; eğlence sektörü ve dijital avatar uygulamalarında geniş kullanım alanları bulmakla birlikte, adli bilişim ve tespit açısından en zorlu alanlardan birini oluşturmaktadır. Söz konusu yaklaşımda, psikolojik "tekinsiz vadi" (*uncanny valley*) etkisini aşma güçlükleri ve gerçekçiliğin tam anlamıyla korunması henüz bütünüyle çözülmüş değildir; sentezlenen yüzler bazen insan algısından kaçamayacak derecede doğal olmayan anomaliler içerebilmektedir.

- **Kullanılan Teknolojiler ve Mimariler:** Bu kategoride en yaygın kullanılan mimariler ProGAN, StyleGAN, StyleGAN2-Ada ve CycleGAN'dir. StyleGAN, ara özelliklerde ve gizli uzayda (*latent space*) zengin anlamsal bilgileri kodlayarak üretilen yüzlerin nitelik, kalite ve çeşitliliğini belirgin ölçüde artırmıştır. StyleGAN2-Ada ise sınırlı veri rejimlerinde eğitimi stabilize eden uyarlanabilir ayırt edici artırma (*adaptive discriminator augmentation*) mekanizmasıyla dikkat çekmektedir
- **Temel Veri Setleri:** *100K-Generated Images (100K-Faces)*, *iFakeFaceDB* ve *DFFD*, bu kategori için oluşturulmuş başlıca açık erişimli veri setleridir.

2.2 Kimlik Değiştirme (Identity Swap)

Kimlik değiştirme, bir kişinin yüz özelliklerinin başka birinin fotografik veya video içeriğindeki yüzüyle kolayca değiştirilmesiyle gerçekleştirilmektedir. Bu kategori, deepfake teknolojisinin toplumsal zararları ve manipülasyon potansiyeli açısından en çok tartışılan alanıdır. Zira gerçekçi bir kimlik değiştirme; siyasetçileri veya ünlüleri hedef alarak hiçbir zaman gerçekleşmemiş olayların içerisindeymiş gibi göstermekte oldukça etkili olmakta, sosyal medyada taciz ve sahte pornografi yayılımı gibi kötü niyetli amaçlara hizmet etmektedir.

- **Kullanılan Teknolojiler ve Mimariler:** Gelişmiş derin öğrenme algoritmaları bu doğrultuda özelleştirilmiş olup Faceswap, DeepFake, DeepFaceLab ve FSGAN (Face Swapping GAN) en yaygın kullanılan araçlar arasında yer almaktadır. FSGAN, herhangi bir yüz çifti için özgül bir eğitim sürecine ihtiyaç duymadan (*subject-agnostic*) çalışabilmesi; poz, ifade varyasyonlarını ve tıkanıklıkları (*occlusion*) eş zamanlı yönetebilmesiyle öne çıkmaktadır.
- **Temel Veri Setleri:** *UADFV*, *FaceForensics++ (FF++)*, *Celeb-DF*, *Deepfake TIMIT* ve *DFDC Preview* bu alanda geliştirilmiş temel benchmark veri setleridir.

2.3 Öznitelik Manipülasyonu (Attribute Manipulation)

Öznitelik manipülasyonu, mevcut bir yüzün belirli görsel özelliklerini (saç rengi, ten tonu, cinsiyet, yaş veya gözlük gibi aksesuarlar) hassas bir biçimde değiştirirken kimliğin genel yapısını koruma üzerine kurulu bir yaklaşımdır. Bu kategori, teknik açıdan kimlik değiştirmeden daha yerel görünse de bütünsel yüz değiştirmeye kıyasla çok daha ince artifaktlar bıraktığı için ayırt edilmesi oldukça güç olan sistemlerin kurulmasını gerektirir.

- Kullanılan Teknolojiler ve Mimariler:** StarGAN, StarGAN-V2, Glow ve Inter-FaceGAN bu kategoride öncü mimari konumundadır. Öne çıkan yapılardan StarGAN, çoklu alanların tek bir üretici üzerinden görüntüden görüntüye çevrilmesini (*multi-domain image-to-image translation*) mümkün kılmaktadır. FaceApp gibi tüketici odaklı popüler düzenleme araçları da bu teknolojiyi arkasına alarak yaşlandırma veya cinsiyet değiştirme gibi özellikleri kitlelere sunmaktadır.
- Temel Veri Setleri:** DFFD, ND-IIITD ve FFHQ (Inter-FaceGAN ile manipüle edilmiş versiyonu) öznitelik manipülasyonu araştırmaları için kullanılan başlıca veri tabanlarıdır.

2.4 Yüz Yeniden Canlandırma ve İfade Değiştirme (Face Reenactment / Expression Swap)

Yüz yeniden canlandırma, bir kaynak kişinin duygusal ifadelerini, bakışlarını ve mimiklerini kusursuz bir biçimde hedef kişinin yüzü üzerine yansıtarak ifadeleri değiştirmeyi amaçlamaktadır. Bu teknik, literatürde 'kukla ustası' (*puppet-master*) veya konuşan kafalar (*talking heads*) olarak adlandırılan uygulamalarda kritik bir rol üstlenmekte ve bir başkasının adına tamamen gerçekçi videolar üretilmesini sağlamaktadır. Siyasi dezenformasyon ve kitleleri yanıltma senaryoları açısından son derece kritik bir tehdit oluşturmaktadır.

- Kullanılan Teknolojiler ve Mimariler:** Bu süreç, duygusal ifadelerin dakika düzeyindeki detaylarını yakalamak ve bunları hedef yüz üzerinde doğru bir şekilde yeniden üretmek için gelişmiş GAN ve CNN mimarilerinin ortak çalışmasına dayanmaktadır. FSGAN da yine bu alanda yaygın olarak canlandırma amacıyla kullanılan güncel araçlardandır.
- Temel Veri Setleri:** Raporda belirtilen en çarpıcı bulgulardan biri, bu altyapının kısıtlılığına ilişkindir. Yazarların araştırmalarına göre, bu kategorideki çalışmalar için literatürde yaygın olarak erişilebilen ve referans kabul edilen neredeyse tek kapsamlı benchmark kaynağı, FaceForensics'in gelişmiş bir versiyonu olan FaceForensics++ veri setidir.

Tablo 1: Dört Yüz Manipülasyon Kategorisinin Karşılaştırılması

Kategori	Temel Teknik	Tespit Güçlüğü	Kullanım Alanı	Örnek Veri Seti
Bütünsel Yüz Sentezi	ProGAN, StyleGAN	Yüksek	Derin sahteler, anonim yüzler	100K-Faces, DFFD
Kimlik Değiştirme	DeepFake, FSGAN	Cok Yuksek	Siyasi manipülasyon, pornografik içerik	FaceForensics++, Celeb-DF
Nitelik Manipülasyonu.	StarGAN, FaceApp	Orta-Yuksek	Sosyal medya filtresi, kimlik tahrifi	DFFD, ND-IIITD
Yüz Yeniden Canlandırma	GAN + CNN	Yuksek	Puppet-master, siyasi propaganda	FaceForensics++




Table 1 Public database (Entire Face)

Dataset	Real	Fake	Count	GAN	References
100 K-Generated images	–	Yes	100,000	StyleGAN	[22]
DFFD	–	Yes	100,000	StyleGAN	[7]
100 K-Faces	–	Yes	100,000	StyleGAN ProGAN	[13]
iFakeFaceDB	–	Yes	250,000	StyleGAN ProGAN	[4]
Vox-DeepFake	–	Yes	–	FS-GAN	[31]
NIST MFC2018	Yes	–	50,000	ProGAN	[32]
Own	Yes	Yes	70k	StarGAN, Glow, ProGAN, StyleGAN	[6]
DFFD	–	Yes	200,000	ProGAN	[7]

Table 2 Public datasets (Identity swap)

Dataset	Real count	Real source	Fake count	Manipulation
UADFV [33]	49	Youtube	49	FaceApp
FF++[27]	1000	Youtube	2000	Faceswap, DeepFake
Celeb-DF [34, 35]	590	Youtube	5639	DeepFake
DFDC Preview [36]	1131	Celebrities	4119	–
Deepfake TIMIT [10]	–	–	620	Faceswap
DFD [37]	–	Actors	3000	DeepFake

Table 3 Public database (Attribute Manipulation)

Database	Source	Count	GAN
DFFD [38]	Youtube	92,000	FaceApp/StarGAN
ND-IITD [39]	Celebrity	1000	StarGAN
FFHQ [11]	Youtube	25,576	Inter-FaceGAN

Table 4 Other manipulation techniques

Face manipulation direction	Description
Age Progression/Regression	Techniques for simulating aging or reversing aging in facial images
Gender Transformation	Altering facial features to make individuals appear as the opposite gender
Makeup Transfer	Makeup products transfer from one surface to another, leaving marks or stains
Face Morphing	Blending facial features from multiple images to create a smooth transition between faces
Face De-Identification	Removing identity information from face images or videos to protect privacy, often through methods like blurring or providing different identities

3. Deepfake Üretiminde Kullanılan Temel Teknolojiler

Deepfake üretiminin ve adli tespitleme süreçlerinin teknolojik temelini oluşturan mimariler, birçok farklı derin öğrenme paradigmasından beslenmektedir. Bu bölümde en etkili yaklaşımlar değerlendirilmekte ve bunların sahte medya ekosistemindeki rolleri analitik biçimlerde ele alınmaktadır.

3.1 Varyasyonel Otokodlayıcılar (Variational Autoencoders - VAE)

VAE'ler, yüksek boyutlu verileri alt uzay temsillerine kodlayan ve bu gizli temsillerden yeni örnekler üreten üretici modellerdir. VAE'lerin temel matematiksel hedef fonksiyonu, yeniden yapılandırma hatasını en aza indirirken kanıt alt sınırını (*evidence lower bound - ELBO*) en üst düzeye çıkarmaktır. Deepfake üretiminde geniş ölçekli adli veri seti üretim senaryolarının öncülerinden olan bu mimari, *DeeperForensics-1.0* veri setindeki 60.000 adet sahte videonun titizlikle üretilmesini sağlayan uçtan uca DF-VAE yönteminin temelini oluşturmuştur.

3.2 Üretici Çekişmeli Ağlar (Generative Adversarial Networks- GAN)

GAN'lar, deepfake teknolojisinin temelini oluşturan ve bu alandaki gelişmeleri yönlendiren en güçlü mimariler arasında yer almaktadır. GAN yapısı, üretici (generator) ve ayırt edici (discriminator) ağların rekabetçi biçimde eğitilmesine dayanır. Üretici ağ gerçeğe yakın içerikler üretmeye çalışırken, ayırt edici ağ gerçek ve sahte verileri ayırt etmeye çalışır. Bu süreç ilerledikçe üretilen içeriklerin gerçekçiliği önemli ölçüde artmaktadır.

Son yıllarda PG-GAN, StyleGAN ve StyleGAN2 gibi gelişmiş GAN modelleri, daha yüksek çözünürlükte ve fotogerçekçi yüz üretimi sağlayarak deepfake teknolojisini ileri taşımıştır. Özellikle StyleGAN2 ile üretilen yüzlerin gerçek görüntülerden ayırt edilmesi oldukça zor hâle gelmiştir. BigGAN yüksek çeşitlilikte görüntü üretimi sağlasa da belirli yüz özelliklerini bağımsız şekilde değiştirmede sınırlı kalmaktadır. CycleGAN ise eşleştirilmiş veri gerektirmeden farklı görsel alanlar arasında dönüşüm yapabilmesiyle dikkat çekmektedir. Bunun yanında FSGAN ve RSGAN gibi modeller, yüksek kaliteli yüz değiştirme ve yüz yeniden canlandırma işlemlerinde başarılı sonuçlar vermektedir.

3.3 Konvolüsyonel Sinir Ağları (CNN) ve Hibrit Mimariler

CNN tabanlı mimariler hem deepfake üretiminde hem de deepfake tespitinde temel yapı taşlarından biri olarak kullanılmaktadır. Üretim aşamasında GAN modelleriyle entegre çalışan CNN'ler, özellik çıkarımı ve manipülasyon kalitesinin artırılmasında önemli rol oynamaktadır. Tespit aşamasında ise XceptionNet, VGG16, ResNet ve EfficientNet gibi önceden eğitilmiş CNN mimarileri, transfer öğrenme yaklaşımıyla deepfake sınıflandırma problemlerine uyarlanmaktadır.

Bunun yanında CNN ve LSTM kombinasyonu, özellikle video tabanlı deepfake tespitinde önemli avantaj sağlamaktadır. CNN katmanları her karedeki uzamsal özellikleri çıkarırken, LSTM katmanları bu bilgilerin zamansal tutarlılığını analiz etmektedir. Böylece yalnızca tekil karelerdeki manipülasyonlar değil, video boyunca oluşan zamansal anomaliler de başarılı şekilde tespit edilebilmektedir.

3.4 Transformer Tabanlı Yaklaşımlar

Transformer mimarileri, piksel düzeyindeki yerel bağımlılıkların ötesine geçerek görüntünün global bağlamını inceleme yeteneğiyle deepfake adli analizine yeni bir soluk getirmiştir. **Convolutional Vision Transformer (ViT)** entegrasyonuna dayanan son dönem çalışmaları, CNN bileşenlerinin

yerel öznitelik yakalama gücü ile Vision Transformer mimarisinin global ilişki kurma yeteneğini birleştirmektedir. Bu yenilikçi modeller, DFDC veri seti üzerinde eğitildiğinde %91.5 gibi yüksek bir doğruluk oranı, 0.91 AUC ve 0.32 log-kayıp (*log-loss*) değeri elde ederek global düzeydeki yapısal ve anlamsal deepfake tutarsızlıklarını yakalamada üstün bir performans ortaya koymuştur.

4. Deepfake Tespit Yöntemlerinin Karşılaştırmalı Analizi

Deepfake tespiti, bir yüz veya ses girdisinin gerçek mi yoksa yapay olarak sentezlenmiş mi olduğunu belirlemeyi amaçlayan bir ikili sınıflandırma (*binary classification*) problemi olarak tanımlanmaktadır. Tespit yöntemleri literatürde genel olarak üç ana kategoride ele alınmaktadır: öznitelik tabanlı (*feature-based*) yöntemler, derin öğrenme tabanlı yöntemler ve ses deepfake tespiti yöntemleri.

4.1 Öznitelik Tabanlı (Feature-Based) Tespit Yöntemleri

Öznitelik tabanlı yaklaşımlar, deepfake tespitinin ilk evrelerini oluşturmakta ve üretici modellerin bıraktığı kusurları biyometrik, model veya medya özellikleri aracılığıyla belirlemeye çalışmaktadır. Bu yöntemlerin en büyük avantajı açıklanabilir ve yorumlanabilir olmalarıdır. Ancak GAN varyasyonlarının hızla gelişmesi ve gerçeğe yakın üretimler yapması, bu geleneksel yöntemlerin başarısını zamanla sınırlandırmaktadır.

- Göz Kırpma ve Biyometrik Analizler:** Erken dönem GAN modellerinin gerçekçi göz kırpma refleksini (frekans ve süreklilik bağlamında) taklit edemediği gözlemlenmiştir. Göz Çevresi Boyut Oranı (*Eye Aspect Ratio - EAR*) ölçümüne dayanan **DeepVision** sistemi, bu yaklaşımla %87.5 doğruluk oranına ulaşmıştır. Sonraki çalışmalarda kaş hareketlerinin dinamik analizi (UADFV veri setinde DenseNet, LightCNN, ResNet ve SqueezeNet entegrasyonu ile 0.984 AUC), iris piksel tutarsızlıkları (MLP ile %85.1 AUC) ve göz bebeği anomalileri de tespit kriteri olarak literatüre dahil edilmiştir.
- Biyolojik Sinyaller (Kalp Ritmi Takibi):** Deepfake videolar üretilirken yüz bölgesinin sahte katmanlarla kaplanması, insan tenindeki kılcak kan akışının neden olduğu milisaniyelik renk değişimlerini (fotopletismografi - rPPG sinyallerini) bozmaktadır. Bu anomaliden yola çıkan **Fake-Catcher** (0.0215 kayıp değeri) ve **DeepFakesON-Phys** (%98 doğruluk) gibi sistemler kalp atış hızını tahmin ederek sahteciliği tespit etmektedir. Benzer şekilde **DeepRhythm** sistemi, dikkat mekanizmalı evrişimli ağlar kullanarak hemoglobin değişimlerini izlemiş ve FF++ ile DFDC-Preview veri setlerinde %98 başarı yakalamıştır.
- 3D Kafa Pozisyonu Kestirimi:** Sentezlenen yüz maskelerinin orijinal videodaki gövde ve arka plan üzerine yerleştirilmesi sırasında üç boyutlu kafa açıları ve yüz işaret noktalarında (*landmarks*) geometrik uyumsuzluklar meydana gelmektedir. Kafa pozisyonlarındaki bu tutarsızlıkları SVM sınıflandırıcısı ile inceleyen çalışmalar, UADFV veri seti üzerinde %84.3 tespit doğruluğuna ulaşmıştır.

Tablo 2: Özellik Tabanlı Tespit Yöntemlerinin Karşılaştırılması

Çalışma	Özellik	Yöntem	Veri Seti	Performans
DeepVision	Göz kırpması örüntüsü	EAR analizi	Özel video	%87.5
Matern et al.	Göz rengi tutarsızlığı	Lojistik Reg. + MLP	Özel veri seti	AUC %85.1
Yang et al.	3D bas pozu	SVM	UADFV	%84.3
Fake-Catcher	Biyolojik sinyal (nabız)	RIPPG	Özel	Loss 0.0215

Çalışma	Özellik	Yöntem	Veri Seti	Performans
DeepFakesON-Phys	Nabız oranı	Dikkat CNN	Celeb-DF + DFDC	%98
DeepRhythm	Deri tonu nabız ritmi	Dikkat CNN	FF++ + DFDC-P	%98

4.2 Derin Öğrenme Tabanlı Tespit Yöntemleri

Derin öğrenme tabanlı yaklaşımlar, günümüz literatüründe en yüksek performansı gösteren ve en yaygın koşturulan kategoridir. Bu yöntemler, elle özellik tasarımı yapmaya gerek kalmaksızın doğrudan veri kümeleri üzerinden sahtecilik izlerini öğrenebilmekte ve bilinmeyen manipülasyon türlerine karşı daha esnek bir genelleme performansı sunmaktadır.

- **Renk Kusurları ve SVM:** İlk çalışmalarda, gerçek kameraların yakaladığı renk profilleri ile GAN modellerinin ürettiği renk dağılımları arasında doğrusal farklar olduğu keşfedilmiştir. NIST MFC2018 veri setinde doğrusal SVM ile yapılan testlerde %70 AUC elde edilirken; **FaceNet** modeliyle desteklenen güncel aşamalarda CelebA-HQ ve FFHQ veri tabanlarında %84.7 doğruluğa ulaşılarak renk analizinin sınırları genişletilmiştir.
- **Dikkat Mekanizmaları (Attention CNN):** Dang ve arkadaşları tarafından yürütülen çalışmada, XceptionNet ve VGG16 ağlarına dikkat mekanizmaları entegre edilmiştir. Bütünsel yüz sentezi kategorisinde yapılan testlerde, FaceForensics++, FFHQ ve CelebA veri setlerinde %100 AUC ve %0.1 EER gibi kusursuz bir adli başarı elde edilmiştir.
- **Uzamsal-Zamansal (CNN+LSTM) Hibrit Yapılar:** Videolardaki kareler arası tutarsızlıkları yakalamak için en kararlı çözümdür. Sabir ve ekibi RCNN mimarisiyle FF++ üzerinde %96+ AUC bildirirken; Hashmi ve ekibinin CNN+LSTM modeli DFDC veri setinde %97.60 doğruluğa ulaşmıştır. Alanın temel referanslarından kabul edilen Güera ve Delp çalışması ise, CNN ile kare özniteliklerini çıkarıp LSTM ile dizi tanımlayıcı oluşturarak HOHA veri setinde %97.2 doğruluk yakalamıştır.
- **Alan Değişmez Temsil Öğrenimi (DIRL):** Bilinmeyen veri kümelerine karşı genelleme sorununu çözmek amacıyla geliştirilen bu yaklaşım; Özellik Dağılımı Tutarsızlığı Minimizasyonu (FDDM) ve Optimal Sınıflandırıcı Mesafesi Minimizasyonu (OCDM) bileşenlerinden oluşur. DIRL yöntemi, FF++ üzerindeki hata oranlarını (HETR) %2.54 ile %7.15 aralığına düşürerek testlerde yüksek direnç göstermiştir.
- **Hibrit Evrişimli Vision Transformer (CvT):** CNN katmanlarının yerel pikselleri yakalama gücü ile Vision Transformer (ViT) mimarisinin global öz-dikkat (*self-attention*) mekanizmasını birleştirmektedir. Bu model, yanlış tahminleri yüksek ceza puanıyla değerlendiren *LogLoss* metriğini kullanarak DFDC veri setinde %91.5 doğruluk ve 0.91 AUC elde etmiştir.

Tablo 3: Derin Öğrenme Tabanlı Tespit Yöntemlerinin Karşılaştırılması

Referans	Yöntem	Sınıflandırıcı	Veri Seti	Performans
Dang et al.	Dikkat mekanizmalı yüz analizi	XceptionNet + VGG16	FF++, FFHQ, CelebA	AUC %100 / EER %0.1
Vaswani et al.	GAN boru hattı öznitelikleri	KNN, SVM, LDA	AttGAN, StyleGAN2	%99.81
Hashmi et al.	Derin uzamsal-zamansal öznitelikler	CNN + LSTM	DFDC + Özel	%97.60
Cao et al.	Üç sınıflandırılmalı adli analiz	AFDM- (dikkat)	FF++ + Celeb-DF	FF++:%99.40 / Celeb:%99.87

Referans	Yöntem	Sınıflandırıcı	Veri Seti	Performans
De Lima et al.	Spatiotemporal konvolüsyon	I3D Ağı	Celeb-DF	%98.26 / %99.73
Yang et al.	Dokusal artefakt tespiti	ResNet18	FF++	%99.9
Wodajo et al. (CvT)	Hibrit Vision Transformer	CNN+ViT	DFDC	%91.5
Suratkar et al.	Ölçeklenebilir transfer öğrenme	EfficientNet	FF, FF++, DFDC, DFD	%94
Guera Delp &	Ardışık zamansal boru hattı	CNN + LSTM	HOHA	%97.2

5. Benchmark Veri Setleri

Deepfake tespit araştırmalarının ve adli modellerin gelişimi, kapsamlı, yüksek kaliteli ve çeşitli benchmark veri setlerinin varlığına doğrudan bağlıdır. Bu bölümde mevcut en önemli veri setleri, yapısal detayları ve kalitatif özellikleri bağlamında ele alınmaktadır.

5.1 Video Veri Setleri

- **FaceForensics++ (FF++):** Deepfake tespit araştırmalarının temel referans noktası konumundaki en yaygın kullanılan veri setlerinden biridir. 2019 yılında Rössler ve arkadaşları tarafından geliştirilen bu veri tabanı, YouTube'dan derlenen 1000 orijinal video ile FaceSwap ve DeepFake gibi bilgisayar grafikleri/derin öğrenme teknikleriyle oluşturulan 1000+ sahte videoyu içermektedir. Verilerin ham, düşük ve yüksek sıkıştırma seviyeleriyle sunulması, adli modellerin gerçek dünya senaryolarındaki dayanıklılığını ölçmek açısından büyük bir esneklik tanımaktadır.
- **Celeb-DF ve Celeb-DF v2:** İlk nesil veri setlerinde gözlemlenen düşük yüz çözünürlüğü, belirgin tahrifat izleri ve videolardaki aşırı yüz titremesi/flicker gibi kalitatif sorunlara bir yanıt olarak geliştirilmiştir. Celeb-DF v2; 59 farklı demografik geçmişe sahip ünlü kişiyi içeren 890 gerçek YouTube videosundan ve renk tutarsızlıkları gibi kronik sorunları büyük ölçüde gideren geliştirilmiş bir DeepFakes algoritmasıyla üretilen 5639 yüksek kaliteli sahte videodan oluşmaktadır.
- **DFDC (DeepFake Detection Challenge) Preview:** Facebook öncülüğünde, endüstri ortakları ve akademik kurumların iş birliğiyle sıfırdan inşa edilmiştir. Sosyal medya taramalarına dayanmak yerine, 66 ücretli aktörün rızasıyla kaydedilen 1131 gerçek videoyu ve kimliği belirtilmeyen varyasyonel tekniklerle üretilen 4119 sahte videoyu barındırır. Bu veri setinin en ayırt edici yönü; yaş, cinsiyet ve ten tonu açısından gerçekçi bir demografik çeşitlilik sunmasıdır.
- **DeeperForensics-1.0:** İstatistikî hacim açısından literatürün en kararlı derin öğrenme eğitim alanlarından birini sunmaktadır. Toplam 60.000 video ve 17.6 milyon kareden oluşan devasa bir yapıya sahiptir. Net bir 1:5 gerçek-sahte video oranına sahip olan bu veri setinde sahte içerikler, uçtan uca çalışan gelişmiş bir DF-VAE (Varyasyonel Otokodlayıcı tabanlı) modeliyle titizlikle üretilmiştir.
- **ForgeryNet ve KoDF:** Küresel dezenformasyon takibinde çoğunlukla göz ardı edilen iki kritik boyutu (zengin etiketleme ve etnik köken temsili) hedeflemektedir. ForgeryNet; 99.630

gerçek ve 121.617 sahte video içeren muazzam hacminin yanında, hem imge hem de video düzeyinde sunulan çok katmanlı açıklamaları (annotations) ile öne çıkmaktadır. KoDF ise, deepfake veri havuzlarında sıklıkla gözlemlenen Asyalı yüz siması eksikliğini gidermek adına, 403 farklı Koreli karaktere ait 62.166 gerçek ve 175.776 yapay videodan oluşan dengeli bir veri mimarisi sunar.

- ForgeryNIR: Geleneksel görünür ışık (RGB) spektrumunun dışına çıkan nadir ve yenilikçi bir veri kümesidir. Yakın Kızılötesi (Near-Infrared - NIR) görüntüleme yöntemleriyle kaydedilmiş 50.000'den fazla kimliğe ait gerçek ve sahte verileri barındırarak kızılötesi tabanlı biyometrik yüz doğrulama ve sahtecilik analizleri için güçlü bir adli araç sunmaktadır.

5.2 Veri Seti Boyutları ve Kalitatif Özellikler

Tablo 4: Temel Benchmark Veri Setlerinin Karşılaştırmalı Özeti

Veri Seti	Gerçek Video	Sahte Video	Toplam	Öne Çıkan Ayırt Edici Özellik / Modalite
HOHA	300	300	600	Popüler filmlerden alınmış, insan eylemlerine odaklanan gerçekçi sekanslar
Faceswap-GAN	320	320	640	Literatürdeki ilk açık erişimli, GAN tabanlı deepfake video seti
UADFV	49	49	98	Göz kırpma parametrelerine ve fizyolojik ipuçlarına odaklanan yapı
Deepfake-TIMIT	VidTIMIT Kaynağı	640	640	32 aktör üzerinden manuel eşleme; düşük ve yüksek çözünürlük kısıtlımı
FaceForensics	1.004 Video	500K+ görüntü	1.004 video	Kaynak-Hedef canlandırma analizleri ve adli segmentasyon odağı
FaceForensics++	1.000	4.000+	5.000+	Sektör standardı referans benchmark; 4 farklı manipülasyon algoritması
DFDC Preview	1.131	4.119	5.250	Ücretli aktörlerle yapay ortam kaydı; yüksek etnik ve demografik çeşitlilik
DeeperForensics-1.0	~10.000	~50.000	60.000	En yüksek video hacmi; kararlı 1:5 gerçek/sahte dengesi ve DF-VAE üretimi
Celeb-DF v2	890	5.639	6.529	Geliştirilmiş yapay zeka algoritması; sıfıra indirilmiş yüz titreme artefaktları
ForgeryNet	99.630	121.617	221.247	Hem imge hem video düzeyinde zengin etiketleme düzeni
KoDF	62.166	175.776	237.942	403 Koreli aktör; adli arama modellerinde Asyalı sima temsili dengesi

Veri Seti	Gerçek Video	Sahte Video	Toplam	Öne Çıkan Ayırt Edici Özellik / Modalite
ForgeryNIR	>50.000	>50.000	>100.000	Yakın Kızılötesi (NIR) modalitesi ile karanlık/gece adli analiz simülasyonu

6. Mevcut Zorluklar

Deepfake teknolojisinin tespiti ve üretimi arasındaki asimetrik yarış, adli bilişim araştırmacılarının önünde dinamik bir engel oluşturmaktadır. Raporda öne çıkan bulgular doğrultusunda, mevcut tespit metodolojilerinin karşı karşıya kaldığı temel kısıtlamalar ve aşılması gereken teknik zorluklar şu başlıklar altında incelenmektedir:

6.1 Genelleme Sorunu

Mevcut adli modellerin büyük bir çoğunluğu, üzerinde eğitildikleri veri tabanının özneliliklerine aşırı uyum sağlama (overfitting) eğilimindedir. Bir modelin belirli bir veri setinde (örneğin FaceForensics++) %100'e yakın bir başarı göstermesine karşın, tamamen farklı bir boru hattıyla üretilmiş başka bir veri kümesine (örneğin Celeb-DF) aktarıldığında kararlılığını kaybetmesi alanın en kronik sorunudur. Bu durum, sınıflandırıcıların gerçek sahtecilik izlerini ayırt etmek yerine, veri tabanına özgü çözünürlük, ışık veya kamera sensör gürültüsü gibi istatistiksel kalıpları ezberlediğini göstermektedir. Alan değişmez temsil öğrenimi (DIRL) gibi gelişmiş yaklaşımlar bu bariyeri aşmayı hedeflese de adli modellerin genelleme kapasitesi henüz optimal sınırların gerisindedir.

6.2 Zamansal Tutarlılık

Video tabanlı deepfake üretiminde, kare bazlı (*frame-by-frame*) manipülasyon tekniklerinin her bir karede makul çıktılar üretmesine rağmen, ardışık kare dizilimlerinde zamansal bütünlüğü koruyamaması kritik bir yapısal zafiyettir. Videolarda gözlemlenen ani titreme (*flickering*), kayma ve seğirme (*jittering*) anomalileri, yapay zekanın zamansal sürekliliği tam olarak formüle edememesinden kaynaklanır. CNN + LSTM ve ardışık evrişimli yapılar kareler arası kronolojik bağımlılıkları inceleyerek bu anomalileri avlamada kısmi bir çözüm sunsa da yüksek çerçeve oranlı (*high-FPS*) ve uzun süreli videolarda hesaplama maliyetinin muazzam ölçüde artması pratik real-time kullanım senaryolarını zorlaştırmaktadır.

6.3 İllüminasyon ve Renk Tutarsızlıkları (Illumination Stipulations)

Deepfake veya yüz değiştirme (*replacement*) algoritmaları, sentezlenen sahte yüz katmanını kurbanın orijinal gövdesi ve arka planı üzerine yerleştirirken ortamın gerçek ışık kırılımlarını ve renk profillerini birebir eşitleyememektedir. Özellikle iç mekân ve dış mekan senaryoları arasındaki ani ışık değişimleri, sahte yüz hatlarının sınırlarında renk uyumsuzlukları ve anormal görsel gölgelenmeler bırakmaktadır. Ancak yeni nesil GAN modellerinin gelişmiş küresel aydınlatma ve renk harmonizasyon yetenekleri kazandıkça, adli modellerin bu ışık kusurları üzerinden sahtecilik yakalama kabiliyeti giderek zayıflamaktadır.

6.4 Göz ve Dudak Gerçekçiliğinin Eksikliği (Lack of Realism in Eyes & Lips)

İnsan yüzündeki mikro ifadeleri, doğal konuşma mekaniğini, istemsiz duraksamaları ve senkronize biyomekanik hareketleri modellemek günden güne gelişen üretici yapay zekâ mimarileri için bile

halen ciddi bir engeldir. Yapay sinir ağıları tarafından üretilen deepfake içeriklerde; sese tam olarak oturmeyen dudak senkronizasyon hataları, doğal olmayan yapay göz kırpma ritimleri veya göz bebeklerindeki dairesel geometrik bozulmalar sıkça saptanan temel adli izleri oluşturmaktadır. Erken dönem biyometrik tabanlı tespit sistemlerinin (örneğin *EAR analizi*) tamamı doğrudan bu biyomekanik taklit eksikliğini hedef almaktadır.

6.5 Kimlik Sızıntısı (Identity Leakage)

Özellikle yüz yeniden canlandırma (face reenactment) ve kukla ustası (puppet-master) görevlerinde, hedef kimliğin yapısal yüz hatlarını (kemik yapısı, mesafe oranları) tamamen sabit tutarken, kaynak aktörün duygusal mimiklerini ve kafa hareketlerini kusursuzca aktarmak teknik olarak son derece güçtür. Eğitim süreçlerinde, sürüş kimliği ile hedef kimlik arasındaki anlamsal verilerin birbirine karışması, yüz sınırlarında doku yırtılmalarına veya kimlik sızıntısı (identity leakage) adı verilen görsel katman bozulmalarına neden olmaktadır. Bu durum hem dezenformasyonun inandırıcılığını düşürmekte hem de adli dedektörlerin işini kolaylaştırmaktadır.

6.6 Çok Görevli Mimariler (Multitasking) ve Üçlü Eğitim (Triplet Training)

Literatürdeki deepfake koruma sistemlerinin ezici bir çoğunluğu, girdiyi yalnızca "gerçek" veya "sahte" olarak etiketleyen sıg ikili sınıflandırma mantığına dayanmaktadır. Oysa sahteciliğin tespitiyle birlikte videodaki manipüle edilmiş yerel alanların tam koordinatlarını bulanıklaştırmadan saptayan sahtelik lokalizasyonu (forgery localization) süreçlerinin eş zamanlı yürütülmesi (çok görevli mimariler), dedektörlerin gerçek dünya direncini artıracak yenilikçi bir yaklaşımdır. Bununla birlikte, özellik uzayında aynı kategoriye ait (gerçek-gerçek veya sahte-sahte) örnekler arasındaki mesafeyi en aza indirirken, farklı kategorideki özelliklerin mesafesini kararlı bir şekilde maksimize etmeyi amaçlayan Üçlü Eğitim (Triplet Training) yaklaşımı, gelecekteki deepfake dedektörlerinin genelleme ve direnç sorunlarını çözmede en umut verici akademik yönelimlerden biri olarak kabul edilmektedir.

7. Teknolojik Paradigmaların Evrimi: Öznitelik Mühendisliğinden Multimodal ve Transformer Yaklaşımlarına Geçiş

Deepfake tespit alanının tarihsel gelişimi, üretici modellerin fotorealizm yeteneklerine paralel bir olgunlaşma ve adli direnç sürecini yansıtmaktadır. Literatürdeki bu evrimsel döngü; öznitelik mühendisliği dönemi (2018–2020), derin öğrenme egemenlik dönemi (2020–2022) ve güncel multimodal/transformer dönemi (2022–Günümüz) olmak üzere üç ana başlık altında metodolojik olarak analiz edilebilir:

7.1 Öznitelik Mühendisliği Dönemi (2018–2020)

Deepfake tespitinin ilk anlamlı akademik çalışmalar 2018 yılında ortaya çıkmıştır. Bu dönem, elle tasarlanmış (hand-crafted) özelliklerin egemenliğindedir: göz kıpması kalıpları, bas pozu kestirimindeki tutarsızlıklar ve renk histogramları ilk tespit girişimlerinin temelini oluşturmıştır. Özellik tabanlı yöntemlerin avantajı yorumlanabilirlikleri ve görece düşük hesaplama gereksinimleridir; ancak bu yöntemler, GAN kalitesinin kısa süre içerisinde bu doluluk noktası asмага başlamasıyla yetersiz kalmaya başlamıştır. LBP (Local Binary Pattern) ve SIFT (Scale-Invariant Feature Transform) gibi klasik bilgisayarla görü teknikleri de bu dönemde denenmiş; ancak sınırlamaları hızla görülmüştür.

7.2 Derin Öğrenme Egemenlik Dönemi (2020–2022)

Transfer öğrenme ile adaptasyon edilen CNN mimarilerinin (XceptionNet, VGG16, ResNet, EfficientNet) hızla benimsenmesi, bu dönemi belirleyen en temel gelişme olmuştur. Önceden

egitilmiş büyük modellerin deepfake veri setlerine ince ayar yapılarak uyarlanması, hem veri etkinliğini artırmış hem de test doğruluğunu belirgin ölçüde yükseltmiştir. CNN+LSTM hibritleri, zamansal bilgiyi işleme kapasitesiyle video deepfake tespitinde standart haline gelmiştir. Bu dönem aynı zamanda alan değişmezlik yöntemlerinin (DIRL) ve yeni sınıflandırma paradigmalarının (uçlu sınıflandırma, ikili akis ağırları) ortaya çıkmasına sahne olmuştur.

7.3 Multimodal ve Transformer Dönemi (2022–Günümüz)

Güncel adli bilişim araştırmalarının ağırlık merkezi, tek bir veri modalitesine (sadece görüntü veya sadece video) bağımlı kalmak yerine, görsel ve işitsel (ses) sinyallerini eş zamanlı olarak değerlendiren multimodal (çoklu modlu) yaklaşımlar ile transformer tabanlı mimarilere kaymıştır.

Evrimsel Vision Transformer (CvT) gibi hibrit modeller, CNN katmanlarının yerel piksellerdeki dokusal ve geometrik artefaktları yakalama gücü ile Vision Transformer mimarisinin global öz-dikkat (self-attention) mekanizmasını tek bir potada eritmektedir. FakeAVCeleb gibi eş zamanlı ses-görüntü içeren benchmark veri setlerinin literatüre kazandırılması multimodal araştırmaları hızlandırmıştır. Bununla birlikte, siber güvenlik ekosisteminde ses ve görsel analiz entegrasyonunun, tekil modalite yaklaşımlarına kıyasla doğruluk oranlarını ne ölçüde optimize ettiğini geniş ölçekli çapraz testlerle değerlendiren çalışmalar halen sınırlı düzeydedir.

7.4 Güncel Eğilimlerin Özeti (Key Takeaways)

- CNN tabanlı mimariler, tek başlarına yeterli olmaktan giderek uzaklaşmakta; bu nedenle transformer tabanlı ve hibrit modellerle desteklenmeleri önemli bir gereklilik hâline gelmektedir.
- Günümüzde araştırmaların odağı, yalnızca tek bir veri setinde yüksek doğruluk elde etmekten ziyade farklı veri setlerine karşı güçlü genelleme yapabilen modeller geliştirmeye kaymaktadır.
- Gerçek zamanlı (real-time) deepfake tespiti, özellikle sosyal medya ve güvenlik uygulamaları açısından en kritik araştırma başlıklarından biri olarak öne çıkmaktadır.
- Demografik çeşitliliği daha iyi temsil eden veri setlerine duyulan ihtiyaç, KoDF ve ForgeryNIR gibi çalışmalarla kısmen karşılanmaya başlanmış olsa da, mevcut veri setlerinde hâlen önemli eksiklikler bulunmaktadır.

8. Gelecek Çalışma Yönelimleri

Deepfake tespit ekosistemi, tehdit aktörlerinin ve adli bilişim uzmanlarının karşılıklı hamleleriyle şekillenen dinamik bir yapıya sahiptir. Raporda sunulan çıkarımlar doğrultusunda, alanın gelişim yönünü belirleyecek ve gelecek çalışmalara yön verecek öncelikli araştırma gündem maddeleri şu şekildedir:

8.1 Genelleştirilebilir Tespit Modelleri (Generalizable Models)

Mevcut adli sınıflandırıcıların kapalı laboratuvar ortamlarındaki veri setlerinin dışına çıktığında sergilediği ciddi performans kayıpları, araştırmacıları mimari bağımlılıklardan arındırılmış çözümlere zorlamaktadır. Gelecek çalışmaların, belirli bir GAN veya VAE boru hattının istatistiksel gürültülerini ezberlemek yerine, dijital manipülasyonların evrensel ve temel matematiksel izlerini yakalayabilen esnek modeller üzerine kurulması beklenmektedir. Bu hedef doğrultusunda; meta-öğrenme (*meta-learning*), az örnekli öğrenme (*few-shot learning*) ve alan uyarlama (*domain adaptation*) metodolojileri, sınırları genişletilmiş adli direnç oluşturmada en umut verici yaklaşımlar olarak değerlendirilmektedir.

8.2 Gerçek Zamanlı (Real-Time) Tespit Sistemleri

Sosyal medya platformlarında veri akış hızıyla eş zamanlı dezenformasyon takibi yapabilmek ve canlı yayın hizmetlerinde manipülasyonları anlık yakalayabilmek, pratik bir siber güvenlik mimarisi için zorunludur. Bu pratik gereksinim, yüksek hesaplama maliyeti ile adli doğruluk oranları arasındaki hassas dengenin optimize edilmesini gerektirir. Gelecek çalışmalarda, daha az parametre ve bellek yüküyle çalışan hafif evrişimli sinir ağları (SqueezeNet, MobileNet) ile karmaşık öğretmen modellerin bilgisini daha kompakt yapılara aktaran model damıtma (*knowledge distillation*) tekniklerinin real-time koruma duvarlarında ön plana çıkacağı öngörülmektedir.

8.3 Açıklanabilir Yapay Zeka (XAI) ile Entegrasyon

Adli bilişim modellerinin ürettiği kararların, hukuki süreçlerde delil niteliği taşıyabilmesi ve etik zeminlerde kabul görmesi için kararların şeffaf olması kritik bir gereksinimdir. Sınıflandırıcının bir içeriği neden "sahte" veya "gerçek" olarak etiketlediğini, hangi piksellere veya frekans aralıklarına ağırlık verdiğini açık ve anlaşılır biçimde aktarabilmesi gerekmektedir. Öz-dikkat (self-attention) haritalarını, belirginlik haritalarını (saliency maps) ve açıklanabilirlik katmanlarını adli tespit algoritmalarıyla entegre eden hibrit yapılar, modellerin kullanıcılar tarafından okunabilirliğini ve güvenilirliğini artırmadaki ilk adımları temsil etmektedir.

8.4 Demografik ve Spektral Çeşitliliği Artırılmış Veri Setleri

Asyalı yüzlerin veya baskın olmayan demografik grupların yetersiz temsil edildiği mevcut veri setlerinin bu eksikliğini giderilmesi hem tespit modellerinin adalet hem de performans tutarlılığı açısından zorunludur. KoDF ve ForgeryNIR bu yöndeki girişimlerin öncüsü konumundadır; ancak daha geniş bir demografik yelpazeyi kapsayan veri setlerine ihtiyaç sürdürülmektedir.

10. Sonuç ve Genel Değerlendirme (Conclusion)

Gelecek dönem adli bilişim araştırmalarının ve endüstriyel yatırımların öncelikli olarak şu beş temel eksende şekillenmesi kaçınılmaz bir akademik zorunluluktur:

1. **Genelleştirilebilir ve Veri Kümesinden Bağımsız Tespit Mimarileri:** Belirli bir üretici ağın ayak izlerini ezberlemek yerine, manipülasyonun evrensel matematiksel imzalarını yakalayabilen dirençli modeller tasarlamak.
2. **Gerçek Zamanlı ve Hesaplama Verimliliği Yüksek Sistemler:** Sosyal medya ve canlı yayın platformlarındaki muazzam veri akışını gecikmesiz tarayabilecek hafif sınıflandırıcılar ve bilgi damıtma yöntemleri geliştirmek.
3. **Kapsamlı Çoklu Modlu (Multimodal) Çerçeveler:** Ses ve görüntü sinyallerini eş zamanlı ve çapraz doğrulamalı işleyerek hibrit dezenformasyon senaryolarını bertaraf etmek.
4. **Açıklanabilir Yapay Zeka (XAI) Entegrasyonu:** Adli kararların arkasındaki piksel ve frekans ağırlıklarını şeffaflaştırarak, üretilen tespit raporlarının hukuki süreçlerde geçerli birer dijital delil olmasını sağlamak.
5. **Demografik ve Spektral Çeşitliliği Sağlanmış Büyük Ölçekli Veri Setleri:** Etnik köken önyargılarını kıran ve görünür ışığın dışındaki (kızılötesi gibi) modaliteleri de içeren zengin benchmark veri havuzları inşa etmek.

Makale Linki: https://link.springer.com/article/10.1007/s42452-025-08174-9?utm_source=getftr&utm_medium=getftr&utm_campaign=getftr_pilot&getft_integrator=clarivate