

MAKALE ANALİZ RAPORU

Sorumlu Kişi	Kader Terik
Araştırma Grubu	Deepfake Detection — AISC
Makale Türü	Derleme / Review Makalesi (Open Access, CC BY 4.0)

Makale Bilgileri

Makale Adı: Deepfake detection: critical review of state-of-the-art approaches and future perspectives

Yazarlar: B. C. Soundarya, H. L. Gururaj

Kurum: Manipal Institute of Technology Bengaluru, Manipal Academy of Higher Education, Manipal, India

Yayınlandığı Dergi: Discover Applied Sciences (Springer Nature)

Yayın Yılı / Cilt-Sayı-Sayfa: 2026 / Vol. 8, No. 1, Article 201

DOI / Link: <https://doi.org/10.1007/s42452-025-08174-9>

Geliş Tarihi / Kabul Tarihi: 29 Eylül 2025 / 22 Aralık 2025

Anahtar Kelimeler: Deepfake, Detection, Deep learning, Generative adversarial networks

Finansman: Fon alınmamıştır (Open access: Manipal Academy tarafından karşılanmıştır).

Kaynakça (APA): Soundarya, B. C., & Gururaj, H. L. (2026). Deepfake detection: critical review of state-of-the-art approaches and future perspectives. *Discover Applied Sciences*, 8(1), 201. <https://doi.org/10.1007/s42452-025-08174-9>

== BÖLÜM 1 : ANLATI RAPORU ==

1. Çalışmanın Amacı

Bu çalışma, yapay zeka ve derin öğrenme teknolojilerinin hızla gelişmesiyle birlikte üretilmesi giderek kolaylaşan ve inandırıcılığı artan deepfake içeriklerine (görüntü, video ve ses) ilişkin kapsamlı, eleştirel bir literatür taraması sunmayı amaçlamaktadır. Makale, dört temel hedef etrafında şekillenmektedir:

- Farklı deepfake oluşturma araçlarını ve bunların yüz/ses manipülasyon tekniklerini tanıtmak.
- Deepfake tespiti için kullanılan benchmark ve geleneksel veri setlerini tartışmak.
- GAN (Generative Adversarial Network) tabanlı deepfake üretim mekanizmalarını açıklamak.
- Görüntü, video ve ses modalitelerindeki deepfake tespit tekniklerini derlemek ve karşılaştırmak.

Temel motivasyon, deepfake içeriklerin ünlülere yönelik sahte pornografik videolardan (2017) siyasi dezenformasyona, kimlik dolandırıcılığından ses yoluyla CEO taklidi ile yapılan para transferi dolandırıcılığına (2019) uzanan geniş bir kötüye kullanım alanına yayılmasıdır. İkili sınıflandırma (gerçek/sahte) problemi olarak tanımlanan bu alan, mevcut detektörlerin bilinmeyen/yeni nesil sahteciliklere karşı genellenebilirlik sorunu yaşaması nedeniyle güncel araştırmaların odağında yer almaktadır.

2. Problem Tanımı ve Literatür Bağlamı

Deepfake terimi, 'derin öğrenme (deep learning)' ve 'sahte (fake)' sözcüklerinin birleşiminden türemiştir. Özellikle GAN'lar aracılığıyla üretilen yüz görüntülerinin son derece gerçekçi bir görünüme sahip olması (StyleGAN, StyleGAN2, StyleGAN2-Ada), bu içeriklerin insan gözüyle ayırt edilmesini neredeyse imkânsız kılmaktadır. Mevcut tespit sistemleri büyük çoğunlukla ikili sınıflandırma (real vs. fake) üzerine kurulmuş olup dört temel yüz manipülasyon kategorisine karşı geliştirilmiştir:

- Tam Yüz Sentezi (Entire Face Synthesis): Gerçek bir kişiye ait olmayan, tamamen sıfırdan üretilmiş yüz görüntüleri (ProGAN, StyleGAN, BigGAN vb.).
- Kimlik Değiştirme (Identity Swap): Bir kişinin yüzünün başka birinin yüzüyle değiştirilmesi (FaceSwap, DeepFaceLab, FSGAN, FaceShifter).
- Özellik Manipülasyonu (Attribute Manipulation): Saç rengi, ten rengi, yaş, cinsiyet, aksesuar gibi yüz özelliklerinin değiştirilmesi (StarGAN, FaceApp, CycleGAN).
- Yüz Yeniden Canlandırma (Face Reenactment / Expression Swap): Kaynak yüzdeki ifadelerin hedef yüze aktarılması; FaceForensics++ bu kategorinin temel veri setidir.

Temel problem; GAN modellerinin eğitim veri setine özgü kalıpları öğrenmesi ve bu nedenle farklı oluşturma yöntemleri veya ortam koşullarıyla üretilmiş deepfake'leri genellenebilir biçimde tespit edememesidir. Veri kaynakları; IEEE Xplore, ScienceDirect, ACM Digital Library, Taylor & Francis Online, Scopus ve Web of Science veri tabanlarından derlenen bilimsel yayınlardır.

3. Kullanılan Veri Setleri

Makale, özgün bir veri seti üretmek yerine literatürdeki benchmark veri setlerini kapsamlı biçimde kataloglar. Aşağıda her kategori için temel veri setleri, boyutları ve teknik özellikleri sunulmaktadır.

3.1 Tam Yüz Sentezi Veri Setleri

Veri Seti	Boyut	GAN Mimarisi	Referans
100K-Generated Images	100.000 sahte	StyleGAN	[22]
DFFD	100.000 / 200.000 sahte	StyleGAN, ProGAN	[7]
100K-Faces	100.000 sahte	StyleGAN, ProGAN	[13]
iFakeFaceDB	250.000 sahte	StyleGAN, ProGAN	[4]
NIST MFC2018	50.000 gerçek	ProGAN	[32]
Özel Koleksiyon	70.000 (gerçek+sahte)	StarGAN, Glow, ProGAN, StyleGAN	[6]

3.2 Kimlik Değiştirme (Identity Swap) Veri Setleri

Veri Seti	Gerçek Video	Sahte Video	Kaynak	Manipülasyon Yöntemi
UADFV	49	49	YouTube	FakeApp
FaceForensics++ (FF++)	1.000	2.000	YouTube	FaceSwap, DeepFake
Celeb-DF v1	590	5.639	YouTube	DeepFake
Celeb-DF v2	890	5.639	YouTube (59 ünlü)	Gelişmiş DeepFake

				algoritması
DFDC Preview	1.131	4.119	Ücretli aktörler	Bilinmeyen teknikler
Deepfake-TIMIT	—	640	VidTIMIT dataset	GAN tabanlı FaceSwap
DFD (Google)	—	3.000	Aktörler	DeepFake

3.3 Büyük Ölçekli & Kapsamlı Benchmark Veri Setleri

Veri Seti	Toplam Video/içerik	Çözünürlük	FPS	Öne Çıkan Özellik
HOHA	600 (300 gerçek + 300 sahte)	360×240	24 fps	Popüler filmlerden gerçek klipler
Faceswap-GAN	640 (320×64px + 320×128px)	64×64, 128×128	Değişken	İlk GAN tabanlı kamuya açık deepfake veri seti; VidTIMIT'ten 16 çift
FaceForensics	1.004 video, ~500.000 manipüle frame	≥854×480	Değişken	Eğitim:1.408 / Doğrulama:300 / Test:300 video
DeeperForensics-1.0	60.000 video, 17,6 milyon kare	Değişken	Değişken	1:5 gerçek-sahte oranı; DF-VAE yöntemi
FFIW-10K	20.000 (10k gerçek + 10k sahte)	Değişken	Değişken	Çok kişili sahnelerde yüz sahteciliği
ForgeryNet	221.247 (99.630 gerçek + 121.617 sahte)	Değişken	Değişken	Görüntü + video düzeyinde zengin anotasyon
KoDF	237.942 (62.166 gerçek + 175.776 sahte)	Değişken	Değişken	403 Koreli karakter; Asya yüzü temsili
ForgeryNIR	>100.000 kimlik	Değişken	Değişken	Yakın kızılötesi (NIR) modalitesinde sahte kimlik; CASIA NIR-VIS 2.0 kaynağı
Vox-DeepFake	Değişken	64×64, 128×128	Değişken	VoxCeleb'den türetilmiş; FaceShifter, FS-GAN, DeepFake ile üretilmiş

Tüm veri setleri RGB modalitesinde sunulmakta, yalnızca ForgeryNIR Yakın Kızılötesi (NIR) modalitesini kapsayan nadir bir istisnadır. Makale, doğrudan veri ön işleme (normalizasyon, augmentation) adımlarını uygulamadığı için bu konuda özgün istatistik içermemektedir; ancak incelenen çalışmaların önemli bir kısmında Albumentations kütüphanesi ile veri artırımı (augmentation) yapıldığı raporlanmıştır (bkz. [76]).

4. Kullanılan Yöntemler ve Modeller

Makale özgün bir model sunmamakla birlikte, literatürdeki deepfake üretim ve tespit yöntemlerini sistematik biçimde üç temel kategoride incelemektedir.

4.1 Deepfake Üretim Ağları (GAN Ailesi)

Deepfake üretiminde kullanılan temel GAN yapıları şunlardır:

- VAE (Variational Autoencoder): Yüksek boyutlu veriyi kodlamak ve çözmek için tasarlanmış üretici modeller; temel amaç fonksiyonu ELBO (Evidence Lower Bound) maksimizasyonudur.

- GAN (Generative Adversarial Network): Üretici (Generator) ve Ayırıştırıcı (Discriminator) arasındaki minimax oyunu.
- PG-GAN / ProGAN: Düşük çözünürlükten başlayarak aşamalı katman eklemeyeyle eğitilen, yüksek çözünürlüklü gerçekçi yüzler üreten model.
- StyleGAN / StyleGAN2 / StyleGAN2-Ada: Latent uzayda yüz özelliklerini denetimli biçimde düzenleyebilen, insan gözüyle ayırt edilmesi son derece güç görseller üreten NVIDIA mimarileri.
- CycleGAN: Eşlenmemiş (unpaired) görüntüden görüntüye dönüşüm; döngüsel tutarlılık kaybını kullanır.
- RSGAN (Region-Separative GAN): Latent uzayda yüz ve saç özelliklerini kodlayarak yüksek kaliteli yüz değiştirme.
- FSGAN (Face-Swapping GAN): Herhangi bir yüz çiftine özel eğitim gerektirmeyen, RNN tabanlı poz ve ifade varyasyonlarını yöneten model.
- TL-GAN: Latent uzayın sürekliliğini kullanarak istenilen yüz özelliklerine yönlendirme imkânı sunar.
- Ses Sentezi: WaveNet (Google), Tacotron, AdobeVoco, SV2TTS (çok aşamalı LSTM) gibi modeller.

4.2 Deepfake Tespit Yöntemleri

Makale, tespit yöntemlerini üç ana başlıkta ele almaktadır:

A) Özellik Tabanlı Yöntemler (Feature-Based Detection):

- Göz Kırpma Analizi (EAR — Eye Aspect Ratio): DeepVision, göz kırpma sayısı, süresi ve aralığını özellik olarak kullanarak %87.5 doğruluk elde etmiştir.
- EAR Formülü: $EAR = (||P2-P6|| + ||P3-P5||) / (2||P1-P4||)$ | $EAR_i = (EAR1+EAR2)/2$
- Göz Rengi Tutarsızlığı: İris pikselleri üzerinde Lojistik Regresyon ve MLP ile AUC = 85.1%.
- Kaş Biyometrisi: DenseNet, LightCNN, ResNet, SqueezeNet kullanılarak UADFV'de AUC=0.984, Celeb-DF'de AUC=0.712.
- Biyolojik Sinyal (PPG/rPPG): Fake-Catcher (deri rengindeki kan akışı varyasyonları) ve DeepFakesON-Phys (kalp atış hızı tahmini) — Convolutional Attention Network ile %98 doğruluk.
- 3B Kafa Pozu Tahmini: SVM ile UADFV'de %84.3 doğruluk; sentezlenmiş yüz referans noktalarındaki tutarsızlıkları tespit eder.
- Deri Rengi / DeepRhythm: FF++, DFDC-P veri setlerinde Attention CNN ile %98 doğruluk.
- Göz-İzleme + EEG: FakeET veri seti üzerinde AUC=0.88, EER=%20.7.

B) Derin Öğrenme Tabanlı Yöntemler:

- Renk Özellikleri + Doğrusal SVM: NIST MFC2018'de AUC=%70.0.
- FaceNet + SVM: CelebA-HQ ve FFHQ'da %84.7 doğruluk (InterFaceGAN ve StyleGAN sahtelerine karşı).
- XceptionNet + VGG16 + Attention Mekanizması (Dang et al.): FaceForensics++, FFHQ, CelebA veri setlerinde AUC=%100, EER=%0.1.
- KNN + SVM + LDA (GAN Pipeline Features): AttGAN, GDWCT, StarGAN, StyleGAN, StyleGAN2 sahtelerine karşı %99.81 doğruluk.
- RCNN (Sabir et al.): Sıfırdan eğitilen yinelemeli evrişimsel ağ; FF++' üzerinde AUC > %96.
- CNN + LSTM (Hashmi et al.): DFDC + özel veri setinde %97.60 doğruluk.
- AFDM + Çift Akış Ağı (Cao et al.): FF++ üzerinde %99.40, Celeb-DF'de %99.87.
- DIRM (Domain-Invariant Representation Learning): FDDM + OCDM bileşenleri; FF++' üzerinde HETR %2.54-%7.15.

- ASCA-SqueezeNet (Aquila Sine Cosine Algorithm + DCNN): Dice Katsayısı tabanlı birleştirme; %98 doğruluk.
- CvT (Convolutional Vision Transformer): CNN + ViT hibrit; DFDC'de %91.5 doğruluk, AUC=0.91, Loss=0.32. Log-loss: $-1/n * \sum [y * \log(y) + \log(1-y) * \log(1-y)]$
- AMTEN (Adaptive Manipulation Traces Extraction Network) + CNN: Manipülasyon izlerini içerik baskılayarak ön işlemede çıkaran katman; Hibrit Sahte Yüz veri setinde %95.17.
- CNN (YCbCr + Gamma Düzeltme + Canny kenar) + opsiyonel PCA: PCA'sız CNN, %93.16'ya karşın daha iyi (%74.26 ile başlayan PCA'li sürüme kıyasla).
- fCNN (Frekans Evrişimli Ağ, 3 katman): Video karelerini frekans domenine dönüştürerek %0.597 (FF++ + Celeb-DF v2).
- NoiseDF (RIDNet denoiser + Multi-Head Relative-Interaction): FF++' üzerinde %84.36.
- OuterFace (Kimlik GÜdümlü): Vox-DeepFake'te %90.12.
- Cross-Modality Knowledge Distillation (ForgeryNIR): %87.45.
- ADD (Attention-Based): Celeb-DF V2'de %98.3.
- I3D (Uzamsal-Zamansal): Celeb-DF'de %98.26 – %99.73.
- EfficientNet (Transfer Learning): FF, FF++, DFDC, DFD'de %94.
- CNN + LSTM (Dual-Level, Pu et al.): Celeb-DF'de %98.9, FF++' de %85.6.
- ResNet-18 + Saliency Map + Yönlendirilmiş Filtreler: FF++' de %99.9.
- Füzyon (Xception + Capsule + DSP-FWA): UADFV, FF++, Celeb-DF v2 üzerinde AUC=%99.
- CNN + LSTM (Güera & Delp): HOHA veri setinde %97.2 doğruluk.

C) Ses Deepfake Tespit Yöntemleri:

- Q-SVM (Quadratic SVM): Yapay ses ile gerçek insan sesini binary sınıflandırma; %97.56 doğruluk, %2.43 yanlış sınıflandırma oranı. Karşılaştırma: Ağırlıklı KNN, Doğrusal/Karesel Diskriminant, Doğrusal SVM, Boosted Tree Ensemble, LR.
- Siamese CNN + 1-CNN (Lei et al.): GMM tabanlı Siamese CNN ve log-olasılık girişli 1-CNN.
- FakeAVCeleb üzerinde unimodal sınıflandırıcı karşılaştırması: EfficientNet-B0=%50 (en kötü), önerilen sınıflandırıcı=%76. Mesolnception-4, Meso-4, Xception, VGG16 de test edilmiştir.
- SVM + Gradient Boosting + VGG-16: Fake-or-Real veri seti üzerinde en iyi sonuçlar.
- TCN + STN (Melspectrogram tabanlı): Fake-or-Real (FoR)'da en iyi test doğruluğu %92.
- CNN (cCNN + VGG16 + MobileNet): FoR-combined veri setinde %97.23.
- RES-EfficientCNN + EfficientCNN: Hafif, az parametrelili CNN mimarileri.
- SENet + DNN (CQCC özellikleri + log güç büyüklük spektrasi): ASVspoof 2019'da sentetik ses tespitinde %17 iyileşme; ancak mantıksal erişim senaryosunda aşırı öğrenmeden dolayı t-DCF=0 ve EER=0.
- ELTP + LFCC + DBiLSTM: Uzatılmış yerel üçlü örüntü + doğrusal frekans kepsral katsayıları + derin çift yönlü LSTM; ASVspoof 2019'da LA saldırılarına karşı etkili.
- HuBERT (Self-Supervised) Fine-Tuning: PyTorch ile 1.000 sahte + 1.000 gerçek ses üzerinde eğitim; 500+500 test setinde %97 hassasiyet (precision).
- Özellik Temsilleri: MFCC, Mel-Spektrogram, Log Güç Spektrogramı, LFCC, Prosodik Özellikler, Fonetik Özellikler.

5. Sonuçlar ve Değerlendirme

5.1 Performans Metrikleri

Literatürde kullanılan temel ölçüm metrikleri:

- Accuracy (Doğruluk): En yaygın kullanılan; ancak dengesiz veri setlerinde yanıltıcı olabilir.
- AUC (Area Under the ROC Curve): Eşik bağımsız genel performans; özellikle farklı doğruluk/hata dengeleri gerektiren durumlar için kritik.
- EER (Equal Error Rate): Yanlış kabul oranının (FAR) yanlış red oranına (FRR) eşit olduğu nokta; ses ve biyometrik sistemlerde yaygın.
- Precision & Recall: GAN tabanlı görüntü değerlendirmelerinde (ör. BIGGAN: P=0.909, R=0.865).
- Log-Loss: CvT modeli; güvenli yanlış tahminleri cezalandırır.
- t-DCF (Total Detection Cost Function): ASVspoof değerlendirmelerinde kullanılır.

5.2 Öne Çıkan Sayısal Sonuçlar (Veri Setine Göre)

Model / Yöntem	Veri Seti	Performans	Referans
KNN+SVM+LDA (GAN Pipeline)	AttGAN, GDWCT, StarGAN, StyleGAN, StyleGAN2	%99.81 Doğruluk	[17]
XceptionNet + VGG16 + Attention	FaceForensics++, FFFHQ, CelebA + ProGAN/StyleGAN	AUC=%100, EER=%0.1	[69]
AFDM (Çift Akış + RGB)	FaceForensics++	%99.40	[71]
AFDM (Çift Akış + RGB)	Celeb-DF	%99.87	[71]
ResNet-18 + Saliency Maps	FaceForensics++	%99.9	[82]
CNN + LSTM (Dual-Level)	Celeb-DF	%98.9	[52]
ADD (Attention-Based)	Celeb-DF V2	%98.3	[24]
I3D (Spatiotemporal)	Celeb-DF	%98.26 – %99.73	[80]
DeepFakesON-Phys (Convolutional Attention)	Celeb-DF + DFDC	%98	[65]
DeepRhythm (Attention CNN)	FF++, DFDC-P	%98	[50]
CNN + LSTM (Hashmi et al.)	DFDC + Özel	%97.60	[70]
CNN + LSTM (Güera & Delp)	HOHA	%97.2	[29]
HuBERT Fine-Tuned (Ses)	Özel 1k fake+1k real	%97 Precision	[96]
Q-SVM (Ses)	Yapay/İnsan Sesi	%97.56 Doğruluk	[85]
EfficientNet (Transfer Learning)	FF, FF++, DFDC, DFD	%94	[81]
cCNN + VGG16 + MobileNet (Ses)	FoR-combined	%97.23	[93]
ASCA-SqueezeNet	Özel Görüntü	%98	[73]
CvT (CNN + ViT Hibrit)	DFDC	%91.5 Doğruluk, AUC=0.91, Loss=0.32	[76]
RCNN (Sabir et al.)	FaceForensics++	AUC > %96	[18]
OuterFace (Kimlik Gündümlü)	Vox-DeepFake	%90.12	[31]
Kaş Biyometrisi (LightCNN/ResNet/DenseNet/SqueezeNet)	UADFV	AUC=0.984	[56]
Kaş Biyometrisi	Celeb-DF	AUC=0.712	[56]
Göz Rengi (Logistic Reg. + MLP)	Özel	AUC=%85.1	[15]
DeepVision (Göz Kırpması)	Kendi Video Karesi	%87.5	[61]
3D Kafa Pozu (SVM)	UADFV	%84.3	[66]
Colour Features + Linear SVM	NIST MFC2018	AUC=%70.0	[32]
TCN + Melspectrogram (Ses)	FoR	Test Acc=%92	[48]
WGAN (VGG tabanlı, Ses benzeri)	Ünlü Yüz Görüntüsü	WGAN-98	[47]
Göz-İzleme + EEG	FakeET	AUC=0.88, EER=%20.7	[68]

5.3 Teknik Yorum

Sonuçların genel değerlendirmesi:

- Derin öğrenme tabanlı yaklaşımlar (özellikle CNN tabanlı hibrit mimariler) bilinen benchmark veri setlerinde tutarlı biçimde %95+ doğruluk sağlamaktadır.

- Ağların yalnızca eğitildikleri veri setine özgü GAN manipölasyon kalıplarını öğrenmesi, cross-dataset değerlendirmelerde ciddi performans düşüşlerine yol açmaktadır (ör. FF++'dan Celeb-DF'ye geçişte önemli AUC kaybı).
- Tek kare (frame-level) analizi yapan modeller, ardışık kareler arasındaki zamansal tutarsızlıkları (temporal incoherence) tespit edememektedir.
- Ses tespitinde Q-SVM ve CNN tabanlı yaklaşımlar %92-%97 aralığında başarı gösterirken, unimodal dedektörlerin çapraz modalite sahtelerine (görüntü+ses) karşı yetersiz kaldığı gözlemlenmektedir.

6. Literatüre Katkıları (Contributions) ve Kısıtlar / Dezavantajlar

6.1 Literatüre Katkıları

- Görüntü, video ve ses modalitelerindeki deepfake üretim ve tespit yaklaşımlarının tek bir çerçevede sunulduğu kapsamlı, multimodal bir derleme oluşturulmuştur.
- Tüm temel benchmark veri setleri (boyut, çözünürlük, modalite, üretim yöntemi) sistematik tablolar halinde kataloglanmıştır.
- Gerçek dünya deepfake vakaları (Pelosi videosu 2020, DeepNude 2019, Tom Cruise TikTok 2021, Zelensky 2022, CEO ses dolandırıcılığı 2019) belgeler halinde sunulmuştur.
- Deepfake oluşturma araçları (ZAO, FaceApp, FSGAN, DeepFaceLab vb.) ve ses araçları (Adobe Audition, Descript, Lyrebird AI, DeepVoice, SV2TTS vb.) envanteri çıkarılmıştır.
- Özellik tabanlı ve derin öğrenme tabanlı tespit yöntemleri için subjektif performans karşılaştırma tabloları (Tablo 6, 7) hazırlanmıştır.
- Gelecekteki araştırmalar için Genelleştirme, Triplet Eğitim ve Çoklu Görev başlıklarında yol haritası sunulmuştur.

6.2 Kısıtlar ve Dezavantajlar

- **Genelleme Sorunu (Generalization):** Modellerin performansı ağırlıklı olarak kendi eğitim veri setlerine bağımlıdır; farklı GAN mimarisi, aydınlatma veya sıkıştırma koşulları altında doğruluk ciddi biçimde düşmektedir.
- **Zamansal Tutarsızlık (Temporal Coherence):** Çoğu model tek kare düzeyinde analiz yaptığından, deepfake videolarındaki kare-arası titreşme (flickering) ve tutarsızlıkları yakalayamamaktadır.
- **Aydınlatma Koşulları (Illumination):** İç/dış mekân geçişleri veya aydınlatma değişiklikleri, deepfake çıktısında renk tutarsızlıklarına ve anormal görünümlere yol açmaktadır.
- **Göz ve Dudak Gerçekçiliği:** Doğal göz/dudak hareketi senkronizasyonunu sağlamak hâlâ güçtür; yanlış veya eksik ifadeleri tespit etmek için biyometrik çözümler yetersiz kalabilir.
- **Kimlik Sızıntısı (Identity Leakage):** Özellikle yüz canlandırma (reenactment) görevlerinde, kaynak/hedef kimlik bilgilerinin eğitim sürecine sızması başarıyı olumsuz etkilemektedir.
- **Çoklu Görev Zorluğu (Multi-tasking):** Sahte bölge lokalizasyonu ile deepfake tespitinin aynı anda gerçekleştirilmesi pratik doğruluk iyileştirmeleri sunmakla birlikte mimari karmaşıklığı önemli ölçüde artırmaktadır.
- **Unimodal Tespit Yetersizliği:** Ses ve görüntünün ayrı ayrı değerlendirilmesi; çapraz modal uyumsuzluklara (ses-dudak senkronu hataları gibi) karşı kör kalmaktadır.
- **Makale Özgün Model Sunmamaktadır:** Derleme niteliğinde olduğu için nicel katkı (özgün model doğruluğu vb.) yoktur; sonuçlar tamamen başka çalışmalardan aktarılmıştır.

7. Proposed Method Diagram Analizi

Makale, kendine ait bir model mimarisi sunmamaktadır. Ancak iki önemli kavramsal diyagram içermektedir:

7.1 Multimodal Deepfake Tespit Çerçevesi

Video ve ses izlerinin ayrıştırılması ve işlenmesini gösteren kavramsal genel bakış. Bu diyagram, ses (audio) ve görsel (visual) akışların ayrı 'spoof detection' ve 'deepfake detection' modüllerine yönlendirildiği, ardından birleştirildiği uçtan uca bir çerçeveyi temsil etmektedir.

7.2 Ses Deepfake Tespit Çerçevesi

HuBERT tabanlı çalışmada [96] kullanılan uçtan uca çerçevenin blok diyagramıdır:

- Giriş: Ham ses kaydı
- Katman 1 — Özellik Evrişim Katmanı (Feature Convolutional Layer): Ham sesten vektör temsilleri çıkarımı
- Katman 2 — Akustik Özellik Kümesi: MFCC, Mel-Spektrogram, Log Güç Spektrogram, LFCC, Prosodik ve Fonetik Özellikler
- Katman 3 — Bağlamsal Gömme (Contextual Embeddings): Transformer/CNN/RNN katmanları
- Çıkış: İkili sınıflandırma — Gerçek (Real) / Deepfake

7.3 Özellik Haritası Tekniği

Ses-görüntü sahteciliği tespiti için hiyerarşik özellik çıkarımını betimleyen diyagram; ses ve görüntü özelliklerinin ayrıca çıkarıldıktan sonra aralarındaki ilişkiyi belirlemek amacıyla birleştirildiği ve sınıflandırıldığı akışı göstermektedir.

7.4 AMTEN Ön İşleme Mekanizması (Şekil ilgili bölüm)

AMTENnet için kullanılan Adaptive Manipulation Traces Extraction Network yapısı:

- RGB giriş → AMTEN Konvolüsyon 1 → Özellik haritası (Feature Map)
- Orijinal görüntüden çıkarılarak düşük seviyeli manipülasyon izleri (Fmt) elde edilir
- Fmt yeniden kullanılarak kararlı yüksek seviyeli manipülasyon izleri (Freu) üretilir
- Freu → Sonraki konvolüsyon katmanları (hiyerarşik özellik çıkarımı) → Tam bağlantılı katmanlar → Softmax sınıflandırma

8. AISC Perspektifi: Bu Çalışma Üzerine Ne Yapılabilir?

Bu derleme makalesi, AISC Deepfake Detection grubu için kapsamlı bir teorik temel ve yol haritası sunmaktadır. Aşağıda doğrudan bu makaleden beslenen potansiyel katkı ve yönelimler özetlenmektedir:

8.1 Tespit Edilen Boşluklar

- Genelleştirme: Mevcut modeller, kendi eğitim dağılımının dışındaki deepfake tiplerine karşı kırılgandır. Cross-dataset adaptasyon mekanizmaları (domain adaptation, meta-learning) araştırılabilir.
- Zamansal Modelleme: Tekil kare analizinden video akışı boyunca tutarsızlık tespitine (kare-arası optik akış, temporal attention) geçiş yapılabilir.
- Multimodal Yaklaşım: Görüntü + ses sinyal uyumsuzluklarını (dudak senkronu hatası, ses tonu-yüz ifade tutarsızlığı) birlikte değerlendiren bir çerçeve kurulabilir.
- Hafif Mimari İhtiyacı: Gerçek zamanlı sosyal medya taraması için EfficientCNN ve SqueezeNet benzeri düşük parametre sayılı ağlar optimize edilebilir.

8.2 AISC Projesine Doğrudan Katkılar

- Veri Seti Seçimi: FaceForensics++ (karşılaştırma için standart baseline), Celeb-DF v2 (gerçekçilik testi) ve DeeperForensics-1.0 (büyük ölçekli eğitim) kombinasyonu önerilir.
- Biyolojik Sinyal Entegrasyonu: PPG/rPPG tabanlı kalp atış hızı analizi (Fake-Catcher benzeri) ya da EAR temelli göz kırpma özelliği, mevcut pipeline'a eklenti olarak değerlendirilebilir.
- AMTEN benzeri ön işleme: Manipülasyon izlerini içerikten ayırtıran adaptif konvolüsyon katmanı, mevcut CNN backbone'una önceki aşama olarak entegre edilebilir.
- Ses-Görüntü Füzyonu: FakeAVCeleb veri seti ve HuBERT fine-tuning yaklaşımı, mevcut görüntü dedektörüne ses modalitesi eklemek için başlangıç noktası olarak kullanılabilir.
- Domain-Invariant Training: DIRM (FDDM + ODDM) veya Triplet Loss tabanlı eğitim stratejisi, cross-dataset genelleştirme sorununu azaltmaya yönelik deneysel çalışmalar için referans alınabilir.

== BÖLÜM 2 : TABLO AKTARIM BLOĞU ==

Başlık	Değer
Sorumlu Kişi	Kader Terik
Atıf No	100
Makale Türü	Review / Derleme Makalesi (Open Access — CC BY 4.0)
Makale Adı	Deepfake detection: critical review of state-of-the-art approaches and future perspectives
Yıl	2026
Yazarlar	B. C. Soundarya; H. L. Gururaj
Yayınlandığı Dergi-Konferans	Discover Applied Sciences (Springer Nature) — Vol.8, No.1, Article 201
DOI-Link	10.1007/s42452-025-08174-9 https://doi.org/10.1007/s42452-025-08174-9
Kaynakça Bilgisi (APA)	Soundarya, B. C., & Gururaj, H. L. (2026). Deepfake detection: critical review of state-of-the-art approaches and future perspectives. Discover Applied Sciences, 8(1), 201. https://doi.org/10.1007/s42452-025-08174-9
Kullanılan Veri Seti	HOHA, Faceswap-GAN, UADFV, Deepfake-TIMIT, FaceForensics, FaceForensics++, Celeb-DF, Celeb-DF v2, DFDC Preview, DeeperForensics-1.0, Vox-DeepFake, FFIW-10K, ForgeryNet, KoDF, ForgeryNIR, DFFD, iFakeFaceDB, 100K-Faces, NIST MFC2018, FFHQ, ND-IIITD, FakeAVCeleb, FoR (Fake-or-Real), ASVspoof 2019, FakeET
Dataset Kaynağı-Linki	YouTube, VidTIMIT dataset, VoxCeleb dataset, CASIA NIR-VIS 2.0, CelebA, Ücretli aktörler (DFDC); Kamuya açık kaynaklardır. Tek link: Makalede belirtilmemiş.
Veri Seti Detayı	Görüntü (RGB, NIR), video ve ses modalitelerini kapsayan; tam yüz sentezi, kimlik değiştirme, özellik manipülasyonu ve yüz canlandırma kategorilerindeki gerçek ve sahte içeriklerden oluşan çoklu benchmark veri setleri. En büyüğü: ForgeryNet (221.247 içerik), KoDF (237.942 video), DeeperForensics-1.0 (60.000 video, 17,6 milyon kare).
Dataset Boyutu	Veri setine göre değişir. HOHA: 600 video; Faceswap-GAN: 640 video; UADFV: 49 video; Deepfake-TIMIT: 640 video; FaceForensics: ~500.000 frame (1.004 video); FaceForensics++: 6.529 video; DFDC Preview: 5.250 video; DeeperForensics-1.0: 60.000 video / 17,6M frame; ForgeryNet: 221.247 video; KoDF: 237.942 video; ForgeryNIR: >100.000 kimlik.
Train-Test-Validation Ayrımı	FaceForensics: Eğitim 1.408 / Doğrulama 300 / Test 300 video. Diğer veri setleri için makale spesifik oran belirtmemiştir.
Kullanılan Model-Yöntem	Review makalesi; özgün model önerilmemiştir. İncelenen yöntemler: VAE, GAN (PG-GAN, StyleGAN, StyleGAN2, BigGAN, CycleGAN, RSGAN, FSGAN), CNN, RCNN, CNN+LSTM, ViT, CvT, AMTEN, NoiseDF, ADD, DIRM, ASCA-SqueezeNet, Q-SVM, Siamese CNN,

	SENet+DNN, HuBERT (ses), TCN, DBiLSTM.
Model Mimari Detayı	Özgün mimari yoktur. Öne çıkan mimariler: XceptionNet+VGG16+Attention (AUC=%100, EER=%0.1); CvT: CNN+ViT hibrit; AMTEN: adaptif konvolüsyon → Fmt çıkarımı → Freu → FC → Softmax (p=2 nöron); CNN+LSTM: özellik vektörü → LSTM → sınıflandırma; HuBERT: ham ses → özellik konvolüsyon katmanı → bağlamsal gömme → sınıflandırma.
Çalışmanın Amacı	Görüntü, video ve ses deepfake teknolojilerinin üretim süreçlerini (GAN mimarileri), tespit yöntemlerini (özellik tabanlı, derin öğrenme, ses tespiti), kullanılan benchmark veri setlerini ve gelecekteki araştırma yönelimlerini kapsamlı biçimde incelemek.
Ölçüm Metrikleri	Accuracy, AUC (Area Under the ROC Curve), EER (Equal Error Rate), Precision, Recall, Log-Loss, t-DCF (Total Detection Cost Function)
Veri Ön İşleme Adımları	Makale doğrudan veri ön işleme uygulamaz. İncelenen çalışmalarda: YCbCr renk uzayı dönüşümü, Gamma düzeltme, Canny kenar tespiti, frekans domenine dönüşüm (fCNN), EAR hesaplaması, PPG/rPPG sinyalleri çıkarımı, AMTEN manipülasyon izi çıkarımı.
Data Augmentation Kullanıldı mı?	Makale kendi augmentation uygulamamıştır. İncelenen çalışmalarda Alumentations kütüphanesiyle augmentation; ADD çalışmasında 'facial close-up' ve 'facial shut-off' augmentation yöntemleri kullanılmıştır.
Çalışmanın Sonuçları	En yüksek doğruluk: %99.81 (KNN+SVM+LDA — StyleGAN/AttGAN veri setleri). XceptionNet+VGG16+Attention: AUC=%100, EER=%0.1 (FaceForensics++/ProGAN/StyleGAN). Ses: Q-SVM %97.56, HuBERT %97 precision, CNN %97.23 (FoR-combined). Genel bulgu: Derin öğrenme modelleri bilinen veri setlerinde yüksek başarı gösterse de cross-dataset genelleştirme yetersizliği ana açık problem olarak öne çıkmaktadır.
Kıyaslanan Modeller	ResNet-18, XceptionNet, VGG16, LightCNN, DenseNet, SqueezeNet, EfficientNet, SVM (Linear/Q), KNN, LDA, RCNN, CNN+LSTM, ViT, CvT, AMTEN, NoiseDF, I3D, FaceNet, Capsule Network, DSP-FWA.
Review Makale İse İncelediği Yöntemler	Yüz Sentezi (ProGAN, StyleGAN, StyleGAN2, BigGAN, TL-GAN, RSGAN), Kimlik Değiştirme (FaceSwap, DeepFaceLab, FSGAN, FaceShifter), Özellik Manipülasyonu (StarGAN, CycleGAN, FaceApp, GDWCT, AttGAN), Yüz Canlandırma (Face2Face, NeuralTextures), Ses Sentezi (WaveNet, Tacotron, AdobeVoco, SV2TTS, Lyrebird AI), Tespit: Özellik tabanlı (EAR, PPG, 3D kafa pozu, göz rengi) + DL tabanlı (CNN, LSTM, ViT, AMTEN, DURL) + Ses (Q-SVM, Siamese CNN, SENet, HuBERT, DBiLSTM).
Kullanılan Görseller-Grafikler	Şekil 1: Deepfake Sınıflandırması; Şekil 2: Multimodal Tespit Çerçevesi; Şekil 3: Multimodal (Görüntü/Video/Ses) Deepfake Sınıflandırması; Şekil 4: Tam Yüz Sentezi Örnekleri; Şekil 5: Kimlik Değiştirme Örnekleri; Şekil 6: Özellik Manipülasyonu Örnekleri; Şekil 7: İfade Değiştirme Örnekleri; Şekil 8: GAN Ağ Yapısı; Şekil 9: Göz Kırpma Analizi Çerçevesi; Şekil 10: Özellik Haritası Tekniği; Şekil 11: Ses Deepfake Tespit Uçtan Uca Çerçevesi; Şekil 12: Benchmark Veri Seti Karşılaştırması. Tablolar: 12 adet (Veri seti listeleri, araç envanteri, performans karşılaştırmaları, zorluklar, gerçek dünya vakaları).
Getirdiği Yenilikler-Novelty	Özgün model/yöntem önerilmemiştir (Review). Katkısı: Görüntü+video+ses modalitelerini kapsayan nadir çok-modaliteli kapsamlı derleme; gerçek dünya deepfake vakalarının belgelenmesi; tüm benchmark veri setlerinin teknik özelliklerinin tek tabloda sunulması; gelecek araştırma yönelimleri (Genelleştirme, Triplet Training, Multi-tasking) için rehber niteliği.
Dezavantajlar-Kısıtlar	Özgün model bulunmamaktadır; Cross-dataset genelleştirme sorunu çözülmemiştir; Zamansal tutarlılık (kare-arası flickering) problemleri yeterince ele alınmamıştır; Aydınlatma/ortam koşullarına duyarlılık; Göz ve dudak gerçekçiliği sorunları; Kimlik sızıntısı (identity leakage); Unimodal tespitçilerin multimodal sahteciliklere karşı yetersizliği.
Projeye Katkısı-Bizim İçin Önemi	AISC için: FaceForensics++ + Celeb-DF v2 + DeeperForensics-1.0

	veri seti seçim rehberi; Cross-dataset genelleştirme için DIRT/Triples Loss eğitim stratejisi referansı; Temporal coherence problemi için optik akış/temporal attention kullanım motivasyonu; Multimodal (görüntü+ses) dedektör entegrasyonu için FakeAVCeleb + HuBERT yaklaşımı; AMTEN ön işleme katmanının mevcut backbone'a entegrasyon potansiyeli; Gerçek zamanlı tespit için hafif mimari (EfficientCNN, SqueezeNet) yönlendirmesi.
Kod-GitHub Linki	Makalede belirtilmemiştir.
Durum	İncelendi
Notlar	32 sayfalık kapsamlı review makalesi. Makale, görüntü+video+ses olmak üzere tüm modaliteleri tek çerçevede ele alması ve gerçek dünya deepfake vakalarını belgelemesiyle dikkat çekmektedir. AISC projesinde teorik altyapı ve veri seti seçimi için birincil referans kaynağı olarak kullanılabilir. Geliş: 29 Eylül 2025 / Kabul: 22 Aralık 2025. Finansman yok. IEEE Xplore, ScienceDirect, ACM, Taylor&Francis, Scopus, Web of Science taranmıştır.