

MAKALE ANALİZ RAPORU

Sorumlu Kişi	Kader Terik
Araştırma Grubu	Deepfake Detection — AISC
Makale Türü	Özgün Araştırma (Benchmarking / Kıyaslama)

Makale Bilgileri

Makale Adı: Frame Selection Strategies for Video Deepfake Detection: Benchmarking Accuracy and Runtime Trade-Offs

Yazarlar: Artūras Serackis, Mindaugas Jankauskas, Anastasija Grubinskienė, Vytautas Abromavičius

Kurumlar: Department of Electronic Systems, Vilnius Gediminas Technical University, Litvanya

Yayınlandığı Dergi: Applied Sciences (Appl. Sci.)

Cilt / Yıl / DOI: Vol. 16, 2026 | DOI: 10.3390/app16115364

Anahtar Kelimeler: deepfake detection, frame selection, landmark sampling, reusable frame cache, frame detectors

Kaynakça (APA): Serackis, A., Jankauskas, M., Grubinskienė, A., & Abromavičius, V. (2026). Frame Selection Strategies for Video Deepfake Detection: Benchmarking Accuracy and Runtime Trade-Offs. *Applied Sciences*, 16, 5364. <https://doi.org/10.3390/app16115364>

== BÖLÜM 1 : ANLATI RAPORU ==

1. Çalışmanın Amacı

Deepfake (derin sahte) tespit algoritmaları genellikle videoları tek tek kareler (frame) halinde işler. Ancak pratikte çoğu kare birbirinin kopyası (tekrarlı), kalitesiz veya yüz ifadeleri açısından tamamen aynıdır. Çalışmanın temel amacı, model (dedektör) ağırlıklarını sabit tutarak, çıkarım (inference) aşamasında kullanılacak "kare seçimi" (frame selection) stratejilerinin ve seçilen kare sayısının (bütçesinin), tespit doğruluğu (accuracy/AUC) ve çalışma süresi (runtime) üzerindeki etkisini detaylı bir şekilde kıyaslamaktır (benchmarking).

2. Problem Tanımı ve Literatür Bağlamı

Literatürde tespit modellerinin mimarilerine (CNN, Transformer vs.) çokça odaklanılırken, çıkarım sırasında videodan hangi karelerin seçileceği detayı çoğunlukla göz ardı edilmiştir:

- **Kare Seçimi Sadece Bir Ön İşlem Değildir:** Araştırmacılar genellikle videolardan rastgele veya eşit aralıklı (uniform) sabit sayıda (ör. 32 kare) seçim yapmaktadır. Oysa modelin karar mekanizması, doğru karelerin (ör. ağız hareketinin en belirgin olduğu, göz kırpma hatalarının görüldüğü anların) seçilmesinden doğrudan etkilenmektedir.
- **Maliyet ve Hız Dengesi (Trade-off):** Canlı veya büyük ölçekli sistemlerde her video için 32 veya 64 kare işlemek donanım maliyetini ve gecikmeyi (latency) devasa oranda artırmaktadır. Model performansından çok az ödün vererek (örneğin %1) kare sayısını 8'e düşürmek gerçek dünya uygulamaları için kritiktir.

3. Kullanılan Veri Seti

Testlerin tamamen kontrollü ve şeffaf yapılması için "Ortak Kare Önbelleği (Shared Cache)" protokolü kurulmuştur.

- **Kapsamlı Faktöriyel Kıyaslama Seti (Primary Benchmark):** Celeb-DF-v2, Celeb-DF++ ve FaceForensics++ veri setlerinden 100'er adet olmak üzere toplam 300 video (150 gerçek, 150 sahte) seçilmiştir. Bu set, 32 kare referansını da içeren tam analiz için kullanılmıştır.
- **Genişletilmiş Doğrulama Seti (Expanded Validation):** 1180 adet tekilleştirilmiş (deduplicated) Celeb-DF++ ve FaceForensics++ videosundan oluşur. Düşük bütçeli (2, 4, 8 kare) stratejilerin örneklem büyüklüğüne karşı direncini test etmek için eklenmiştir.

Kareler çıkartıldıktan sonra RetinaFace ile yüzler bulunmuş, kırılmış ve 380x380 boyutuna getirilerek önbelleğe (cache) kaydedilmiştir.

4. Kullanılan Yöntem / Stratejiler

Çalışmada sıfırdan bir dedektör eğitilmemiş; bunun yerine çok bilinen 4 pretrained (önceden eğitilmiş) SOTA dedektör sabit tutularak (frozen) kare stratejileri denenmiştir. Dedektörler: SBI, FSBI, GenConViT ve GenD (CLIP tabanlı).

4.1 12 Farklı Kare Seçim Stratejisi (Frame Selection Strategies)

- Uniform: Videodan eşit zaman aralıklarıyla kare seçer (Temel / Klasik).
- Diversity: Görsel olarak birbirinden en farklı olan kareleri seçer.
- Quality: Görüntü kalitesi puanı (referanssız kalite algoritması) en yüksek kareleri seçer.
- Motion: Temporal değişimin (hareketin) en yüksek olduğu anları seçer.
- Shot-aware: Tek bir sahneye kilitlenmemek için sahneleri (shots) böler ve dağıtır.
- Face utility: Yüzün boyutu, ortalanması, keskinliği ve pozlamasına göre puanlama yapar.
- Landmark cluster: Yüz duruşu (pose) eşitlendikten sonra, 68 landmark geometrisini kümelendirerek (cluster) en farklı mimik/poz geometrilerini seçer.
- Landmark + quality: Önce geometriye göre kümeleme yapar, sonra o kümedeki en kaliteli resmi alır (En başarılılardan biri).
- Kalanlar: TP-guided, Landmark diversity, Landmark + motion, Random.

4.2 Kare Bütçeleri (Frame Budgets)

Seçilen Stratejiler sırasıyla her video için 2, 4, 8, 16 ve 32 adet kare (budget) seçecek şekilde çalıştırılmıştır.

5. Sonuçlar ve Değerlendirme (Kıyaslama Analizi)

5.1 Kare Bütçesinin Etkisi (Azalan Verim Kanunu)

- Mutlak başarı her dedektör için 32 kare seçiminde en yüksek olmuştur (Ortalama 0.9257 AUC).
- Ancak, 8 kare (0.9189 AUC) ve 16 kare (0.9218 AUC) seçimi, 32 karenin sunduğu başarının %99.3 ile %99.6'sını yakalayabilmiştir.
- Çalışma süresi (runtime) açısından 8 kare seçimi, 32 kareye oranla zamanın yalnızca %25'ini almaktadır. Bu durum, 8 ve 16 karenin verimlilik (efficiency) açısından "sweet spot" (optimum nokta) olduğunu kanıtlar.

5.2 Strateji Performansları

- Ortalamada en yüksek başarıyı veren strateji Landmark + quality (0.9197 AUC) olmuştur.
- Hemen ardında Quality (0.9191 AUC), Shot-aware (0.9190) ve Landmark cluster (0.9183) gelmektedir.
- Dedektör bazında incelendiğinde; SOTA olan GenD (CLIP) modeli en yüksek AUC'yi (0.9607) Shot-aware stratejisi ile almıştır. GenConViT Diversity ile, FSBI Uniform ile, SBI ise Landmark Cluster ile en iyi sonucu üretmiştir.

5.3 Pareto Maliyet-Fayda (Cost-Benefit) Analizi

- Uniform (Eşit Aralıklı) yöntem, çalışma süresi açısından açık ara en ucuz (en hızlı) olanıdır (32 kare için 18.7 dk).
- Landmark temelli yöntemler (ör. Landmark + motion) süre olarak Uniform'dan neredeyse 5-6 kat daha fazla (118.9 dk) zaman harcamakta ama karşılığında accuracy olarak Uniform'u geçememekte ya da çok az geçmektedir. Yazar, Uniform'un hala en güçlü verimlilik temeli olduğunu belirtmektedir.

6. Literatüre Katkıları ve Kısıtlar

6.1 Özgün Katkıları

- Derin sahte tespitinde "kare seçimi stratejisinin" salt bir ön işlem değil, modelin doğrudan başarısını değiştiren bir değişken olduğu standardize edilerek ispatlanmıştır.
- Shared Cache (Ortak Önbellek) mantığı ile dedektör kıyaslamalarındaki adalet sağlanmıştır.

6.2 Kısıtlar (Sınırlılıklar)

- Çalışma yalnızca görsel veriye dayanmaktadır; ses (audio) ve dudak senkronizasyonu stratejileri denememiştir.
- Sadece 4 pretrained model denenmiştir.

7. AISC Perspektifi: Bu Çalışma Üzerine Ne Yapılabilir?

- **Optimum Kare Sayısı Kararı (Çok Kritik):** Bizim sistemimizin çıkarım (inference) aşamasında performansı yormamak için her videodan 32 veya 64 kare almak yerine, maksimum 8 veya 16 kare almalıyız. Bu makale ispatlıyor ki 8 kare, alınabilecek maksimum başarının (AUC) %99'unu zaten veriyor, fazlası donanım/sunucu masrafı.
- **Landmark + Quality Stratejisi Uyarlaması:** Sistemimiz videodan 8 kare seçerken düz (uniform) almak yerine, bu makalenin önerdiği gibi; yüz landmarklarına göre poz farklılıklarını bulup, en

farklı pozlardan da görüntü kalitesi (blur olmayan) en iyi olanları seçersek, Deepfake tespit başarımız doğrudan artacaktır.

- **Shot-Aware (Sahne Farkındalığı):** Sistem, videonun tamamı tek sahneden (shot) oluşmuyorsa, kareleri sahneler arası homojen dağıtılmalıdır. (Özellikle GenD gibi modeller bu sayede başarı rekoru kırmıştır).

== BÖLÜM 2 : TABLO AKTARIM BLOĞU (Google Sheets) ==

Başlık	Değer
Sorumlu Kişi	Kader Terik
Atıf No	Makalede Belirtilmemiştir (2026 Yayını)
Makale Türü	Özgün Araştırma (Benchmarking)
Makale Adı	Frame Selection Strategies for Video Deepfake Detection: Benchmarking Accuracy and Runtime Trade-Offs
Yıl	2026
Yazarlar	Artūras Serackis, Mindaugas Jankauskas, Anastasija Grubinskienė, Vytautas Abromavičius
Yayınlandığı Dergi-Konferans	Applied Sciences (Appl. Sci.), Vol. 16, 5364
DOI-Link	10.3390/app16115364
Kaynakça Bilgisi (APA)	Serackis, A., Jankauskas, M., Grubinskienė, A., & Abromavičius, V. (2026). Frame Selection Strategies for Video Deepfake Detection: Benchmarking Accuracy and Runtime Trade-Offs. Applied Sciences, 16, 5364. https://doi.org/10.3390/app16115364
Kullanılan Veri Seti	Celeb-DF-v2, Celeb-DF++ ve FaceForensics++
Dataset Kaynağı-Linki	Açık veri setleri. (Atıf 9, 35, 36)
Veri Seti Detayı	Tam faktöriyel analiz için 3 veri setinden karma 300 video. Genişletilmiş analiz (sample size robustness) için 1180 tekilleştirilmiş video (Celeb-DF++ ve FaceForensics++).
Dataset Boyutu	300 (Primary Benchmark) + 1180 (Expanded Validation) Video.
Train-Test-Validation Ayrımı	Eğitim yapılmamış (inference-only). Önceden eğitilmiş (frozen) ağırlıklar doğrudan test edilmiştir.
Kullanılan Model-Yöntem	Model eğitimi değil, Kare Seçim (Frame Selection) Benchmarking'i yapılmıştır. Test edilen Modeller: SBI, FSBI, GenConViT, GenD (CLIP). Kare stratejileri: Uniform, Quality, Landmark cluster vb. 12 adet.
Model Mimari Detayı	Modeller pretrained bırakılmıştır. Çıkarım aşamasında 2, 4, 8, 16, 32 frame (kare) limitleri ile modellerin doğruluk/zaman (accuracy/runtime) trade-off'u incelenmiştir.
Çalışmanın Amacı	Deepfake videolarını tespit ederken videodan kaç kare ve hangi strateji ile (kalite mi, mimik farklılığı mı, hareket mi) kare alınması gerektiğinin maliyet/fayda analizini çıkarmak.
Ölçüm Metrikleri	Frame Mean AUC, Balanced Accuracy, Runtime (Çalışma süresi/dk)
Veri Ön İşleme Adımları	RetinaFace ile yüz tespiti ve kırpma, 380x380 piksel çözünürlüğe ölçekleme. Ortak Ön bellek (Shared Selection Cache) mimarisine kayıt.
Data Augmentation Kullanıldı mı?	Kullanılmadı (Eğitim yapılmadı).
Çalışmanın Sonuçları	En yüksek başarıya 32 karede ulaşılsa da, 8 ve 16 kare ile başarının %99.3 ile %99.6'sı kurtarılmakta, ancak çalışma süresi (runtime) %75 kısalmaktadır. Landmark + Quality stratejisi en başarılı yöntem çıkmıştır.
Kıyaslanan Modeller	Uniform (eşit aralıklı) stratejinin hız/maliyet bakımından Landmark tabanlı stratejilere kafa tuttuğu Pareto analizi ile kıyaslanmıştır.
Review Makale İse İncelediği Yöntemler	İlgili değil
Kullanılan Görseller-Grafikler	Şekil 1-2: Stratejilerin seçtiği kareleri gösteren film şeritleri. Şekil 3-4-5: Frame bütçelerine göre AUC trendleri. Şekil 6-7: Runtime maliyetleri ve Pareto optimum haritası.
Getirdiği Yenilikler-Novelty	Tespit mimarisinden bağımsız olarak, sadece doğru kareleri doğru sayıyla (budget) seçmenin başarıyı ve hızı nasıl optimize edeceğini kanıtlayan kapsamlı ilk kıyaslamalardan biri.

Dezavantajlar-Kısıtlar	Analiz sadece görüntü tabanlıdır, ses/multimodal veri analizi yapılmamıştır.
Projeye Katkısı-Bizim İçin Önemi	
Kod-GitHub Linki	Yok
Durum	İncelendi
Notlar	Gerçek zamanlı sunucu maliyetini/gecikmesini (latency) düşürmek isteyen bizim gibi projeler için harika bir benchmarking rehberi.