

MAKALE ANALİZ RAPORU

Sorumlu Kişi	Kader Terik
Araştırma Grubu	Deepfake Detection — AISC
Makale Türü	Özgün Araştırma (Original Research)

Makale Bilgileri

Makale Adı: Hybrid Facial Deepfake Detection Framework Using Swin V2 Vision Transformers and Multi-Scale Textural Descriptors

Yazarlar: Shivaprakash S. J., Akshat Chauhan, Sabireen H., Abdul Quadir Md.

Kurumlar: Vellore Institute of Technology (VIT), Chennai, India | Sri Sivasubramaniya Nadar College of Engineering, Tamil Nadu, India

Yayınlandığı Dergi: Signal, Image and Video Processing (Springer)

Cilt / Yıl / DOI: Vol. 20, No. 233, 2026 | DOI: 10.1007/s11760-026-05279-5

Anahtar Kelimeler: Deepfake Detection, Swin Transformer, Textural Descriptors, Digital Forensics, Generative Adversarial Networks

Kaynakça (APA): Shivaprakash, S. J., Chauhan, A., Sabireen, H., & Abdul Quadir, M. (2026). Hybrid Facial Deepfake Detection Framework Using Swin V2 Vision Transformers and Multi-Scale Textural Descriptors. *Signal, Image and Video Processing*, 20(233). <https://doi.org/10.1007/s11760-026-05279-5>

BÖLÜM 1 : ANLATI RAPORU

1. Çalışmanın Amacı

Sosyal medya platformlarında hızla yayılan GAN ve difüzyon tabanlı deepfake içerikleri bireysel gizlilik, kurumsal itibar ve medyaya güven açısından büyük tehdit oluşturmaktadır. Mevcut derin öğrenme modelleri (çoğunlukla CNN tabanlı) yeni manipülasyon tekniklerine veya farklı sıkıştırma seviyelerine genelleme yapmakta zorlanmaktadır.

Bu araştırmanın temel amacı, Swin V2 Vision Transformer ile çok ölçekli dokusal tanımlayıcıları (textural descriptors) birleştirerek, hem büyük ölçekli uzamsal (makro-semantik) ilişkileri hem de küçük piksel düzeyindeki (mikro-dokusal) manipülasyon anormalliklerini aynı anda yakalayabilen yüksek doğruluklu hibrit bir deepfake tespit çerçevesi geliştirmektir.

2. Problem Tanımı ve Literatür Bağlamı

Temel Sorun:

- **Modellerin Kör Noktaları:** CNN'ler piksel seviyesindeki anormallikleri tespit etmekte iyidir ancak uzun mesafeli uzamsal ilişkileri (global content) kaçırmalar. Buna karşılık, Vision Transformer'lar uzun mesafeli ilişkileri (self-attention) iyi yakalarken, adli soruşturmalar (digital forensics) için kritik olan küçük dokusal (textural) anormallikleri gözden kaçırabilirler.

Literatürde öne çıkan ilgili çalışmalar:

- **Guo et al. (LDFNet):** Hafif model mimarilerinde küresel dokusal bilgiyi ve yerel kalıntıları (artifacts) birleştirme üzerine çalışmıştır.
- **Wang et al. (WATCHER):** Dalgacık tabanlı (wavelet) doku özellikleri kullanarak modelin genellenebilirliğini (generalizability) artırmayı hedeflemiştir. Sadece CNN kullanmanın aşırı uyuma (overfitting) yol açtığını göstermiştir.
- **Çoklu-Özellik Birleşimi (Multi-Feature Fusion):** Zhang et al., yüz dönüm noktaları (landmarks), spektrum ve dokusal özellikleri ağlara ileterek füzyon tabanlı tespitler yapmıştır.

3. Kullanılan Veri Seti

Eğitim ve değerlendirme, derin sahte tespiti için yaygın kullanılan iki benchmark veri setinde gerçekleştirilmiştir:

- **Celeb-DF V2:** Gelişmiş sahte içerik üreten büyük ölçekli ve yüksek kaliteli veri seti. 500 Gerçek ve 500 Deepfake video örneği alınmıştır.
- **FaceForensics++ (FF++):** 4 farklı manipülasyon tekniği içerir (DeepFake, Face2Face vb.). c40 sıkıştırma seviyesindeki (yüksek sıkıştırma/düşük kalite) videolar kullanılmıştır. 700 Gerçek ve 750 Deepfake video örneği alınmıştır.

Veri Ön İşleme (Data Preparation):

- Örneklenen her videodan 30 kare (frame) çıkarılmıştır.
- Yüz tespiti ve hizalaması için MTCNN (Multi-Task Cascaded Convolutional Networks) kullanılmıştır.
- Yüz kırpıntıları (crops), SwinV2 transformatörünün gereksinimi olan 224x224 piksel boyutuna yeniden ölçeklendirilmiştir.
- Veri setleri eğitim, doğrulama ve test olarak Frame bazında (80/10/10 veya benzer) ayrılmıştır.

4. Kullanılan Yöntem / Model (Hibrit Mimari)

Önerilen sistem, çift kollu (dual-branch) bir yapıdan (Swin V2 + Doku Tanımlayıcıları) ve bir yoğun (dense) sinir ağı birleştiricisinden oluşur.

4.1 Birinci Kol: Swin V2 Vision Transformer

- **Makro-Semantik Bilgi Çıkarımı:** Görüntü örtüşmeyen (non-overlapping) yama (patch) dizilerine bölünür (ör. 4x4 veya 16x16).
- **Shifted-Window Self-Attention:** Standart Vision Transformer'daki yüksek hesaplama maliyetini azaltan ve farklı pencereler (windows) arasında çapraz bağlantılar kurarak yerel ve küresel bağlamı yakalayan mekanizma (Equation 2).

4.2 İkinci Kol: Çok Ölçekli Doku Tanımlayıcıları (Textural Descriptors)

Dört farklı aileden dokusal çıkarım yapılır:

- **LBP (Local Binary Patterns):** Piksellerin komşularıyla yoğunluk farklarını karşılaştırarak yerel doku hissini ikili (binary) ve ondalık değerlere döker (Equation 3-4).
- **Wavelet Transform (Dalgacık Dönüşümü):** Görüntüyü düşük ve yüksek geçişli (LL, LH, HL, HH) filtrelerle sokarak frekans ve detay katsayılarını çıkarır.
- **GLCM (Gray Level Co-occurrence Matrix):** Piksel yoğunluklarının uzamsal (spatial) ilişkilerine dayalı istatistiksel doku özelliklerini (kontrast, korelasyon, enerji, homojenlik, vb.) ölçer.
- **Gabor Filters:** Farklı frekans ve yönelimlerde (orientations) tepkiler alarak enerji ve entropi özellikleri çıkarır (Equation 5).

4.3 Füzyon ve Sınıflandırma

Swin V2'den gelen Transformer yerleştirmeleri (embeddings) ve dokusal tanımlayıcılardan gelen istatistiksel vektörler birleştirilerek, hafif bir Tam Bağlı (Fully Connected) yoğun sinir ağı üzerinden geçirilir ve İkili (Real/Fake) sınıflandırma çıktısı üretilir.

5. Sonuçlar ve Değerlendirme

Metrikler: Doğruluk (Accuracy), Hassasiyet (Precision), Geri Çağırma (Recall), F1-Skoru ve ROC-AUC.

5.1 Modellerin Bağımsız Performansı

- Sadece Doku Özellikleri (Textural): Celeb-DF V2 (Acc: 0.780, F1: 0.770), FF++ (Acc: 0.890, F1: 0.899).
- Sadece Swin V2: Celeb-DF V2 (Acc: 0.904, F1: 0.902), FF++ (Acc: 0.926, F1: 0.932).
- Önerilen (Hibrit): Her ikisini geride bırakmıştır.

5.2 Önerilen Hibrit Sistemin Sonuçları

- **Celeb-DF V2:** Accuracy: 97.44%, Precision: 97.95%, Recall: 96.99%, F1-Score: 97.47%, ROC-AUC: 0.9962.
- **FaceForensics++ (c40):** Accuracy: 96.98%, Precision: 96.36%, Recall: 98.22%, F1-Score: 97.28%, ROC-AUC: 0.9929.

5.3 SOTA Modelleriyle Karşılaştırma

- Önerilen model, LDFNet (ROC: 0.967) ve Forgery-Domain-Supervised (ROC: 0.921) modellerini, özellikle zorlu FF++ (c40) setinde geride bırakmıştır.
- WATCHER modeline karşı rekabetçidir. WATCHER Celeb-DF V2'de 0.990 ile biraz daha iyi doğruluk sağlarken, önerilen model FF++'ta çok daha üstündür (Önerilen: 0.969 vs WATCHER: 0.923).

5.4 Cross-Dataset (Çapraz Veriseti) Performansı

- FF++'ta eğitilip Celeb-DF V2'de test edilen model: Acc 0.49 (çökmüştür).
- Celeb-DF V2'de eğitilip FF++'ta test edilen model: Acc 0.59.
- Sonuç olarak, intra-dataset başarı oranları harika olsa da, cross-dataset (genelleme) performansında ciddi performans kayıpları tespit edilmiştir.

6. Literatüre Katkılar ve Kısıtlar

6.1 Özgün Katkılar

- Vision Transformer hiyerarşik yapıları ile 4 farklı geleneksel dijital adli bilişim (textural) tekniğini birleştiren ilk modellerden biridir.
- Açıklanabilirliğe (interpretability) doğru güçlü bir adımdır, çünkü doku tanımlayıcıları (texture descriptors), deepfake manipölasyonunun izlerinin neden ve nerede (hangi frekansta/dokuda) oluştuğuna dair sinyaller taşır.

6.2 Kısıtlar (Sınırlılıklar)

- Sadece 'yüz' deepfake'lerine odaklanmıştır. Yüz dışı üretken manipölasyonlar kapsamamıştır.
- Hesaplama sınırlamaları nedeniyle pikseller düşük çözünürlüğe (72 PPI) ölçeklenmiştir. Bu durum çok ince (fine-grained) anormallik delillerinin kaybolmasına yol açabilir.
- Cross-Dataset genelleştirme yeteneği düşüktür.
- Sadece 'kare' (frame) düzeyinde çalışır; video kareleri arasındaki zamansal (temporal) uyumsuzlukları hesaba katmaz.
- Frame düzeyindeki veri ayrımı (train/test), ardışık benzer karelerin (near-duplicate frames) veri sızıntısına yol açarak başarıyı (intra-dataset'te) yapay olarak şişirmiş olabilir.

7. AISC Perspektifi: Bu Çalışma Üzerine Ne Yapılabilir?

- **Hafif Özellik Çıkarımı Entegrasyonu (Feature Extraction):** Mevcut AISC modeliniz ağırlıklı olarak CNN veya ViT kullanıyorsa, LBP ve GLCM gibi geleneksel ama oldukça hafif ve hesaplaması ucuz özellikleri ikinci bir kol olarak ağınıza bağlayabilirsiniz. Böylece dijital adli tıp (forensics) bakış açısını modelinize kazandırabilirsiniz.
- **Gerçekçi Veri Sızıntısı (Data Leakage) Önlemi:** Makalede belirtilen 'kare bazlı bölme kaynaklı sızıntı' hatasına düşmemek için AISC veri hazırlama sürecinde kimlik bazlı (identity-level) veya video bazlı Train/Test ayrımı (split) yapmalısınız.
- **Temporal Boyut Eksikliği:** Bu makaledeki model temporal özellikleri kullanamıyor. AISC'te kareleri bir LSTM veya 3D-CNN ile birleştirip, ayrıca doku (texture) özelliklerini eklerseniz, literatürdeki büyük bir boşluğu doldurmuş olursunuz.

== BÖLÜM 2 : TABLO AKTARIM BLOĞU (Google Sheets) ==

Başlık	Değer
Sorumlu Kişi	Kader Terik
Atıf No	Makalede belirtilmemiş (2026 yılı taze yayını)
Makale Türü	Özgün Araştırma (Original Research)
Makale Adı	Hybrid Facial Deepfake Detection Framework Using Swin V2 Vision Transformers and Multi-Scale Textural Descriptors
Yıl	2026
Yazarlar	Shivaprakash S. J., Akshat Chauhan, Sabireen H., Abdul Quadir Md.
Yayınlandığı Dergi-Konferans	Signal, Image and Video Processing (Springer), Vol. 20, No. 233, s.1-10
DOI-Link	10.1007/s11760-026-05279-5
Kaynakça Bilgisi (APA)	Shivaprakash, S. J., Chauhan, A., Sabireen, H., & Abdul Quadir, M. (2026). Hybrid Facial Deepfake Detection Framework Using Swin

	V2 Vision Transformers and Multi-Scale Textural Descriptors. Signal, Image and Video Processing, 20(233). https://doi.org/10.1007/s11760-026-05279-5
Kullanılan Veri Seti	Celeb-DF V2, FaceForensics++ (FF++) [c40 sıkıştırılmış]
Dataset Kaynağı-Linki	Makalede açık link verilmemiş; 22 ve 23 numaralı atıflara gönderim yapılmış.
Veri Seti Detayı	Sadece yüz derin sahteleri (facial deepfakes). FF++ için c40 (yüksek sıkıştırılmış) videolar.
Dataset Boyutu	Celeb-DF V2: 500 Gerçek, 500 Fake. FF++: 700 Gerçek, 750 Fake video (Her videodan 30 kare). Toplamda dengeli (~50/50) sınıf dağılımı.
Train-Test-Validation Ayrımı	Frame bazında 90/10 Train/Test. Train kendi içinde 80/20 Train/Validation.
Kullanılan Model-Yöntem	Hibrit Model: Swin V2 Vision Transformer + Doku Tanımlayıcıları (Textural Descriptors)
Model Mimari Detayı	Makro seviye için Swin V2 (Shifted Window Self-Attention, hiyerarşik yapı, 224x224 grid). Mikro piksel düzeyi için 4 doku ailesi (LBP, Dalgacık Dönüşümü, GLCM, Gabor Filtresi). Ortak füzyon ağı (Dense NN).
Çalışmanın Amacı	Makro seviyedeki global-semantik bilgi eksikliği (CNN'lerde) ile mikro seviyedeki doku delillerinin eksikliğini (Transformer'larda) birbirini tamamlayan bir hibrit ağ yapısıyla gidererek tespit başarısını artırmak.
Ölçüm Metrikleri	Accuracy, Precision, Recall, F1-Score, ROC-AUC.
Veri Ön İşleme Adımları	MTCNN ile yüz çıkarma, 224x224'e yeniden boyutlandırma, 72 PPI çözünürlük kısıtı. Pikselleri düzleştirme ve LBP histogramları çıkarma.
Data Augmentation Kullanıldı mı?	Belirtilmemiştir.
Çalışmanın Sonuçları	Intra-dataset: Celeb-DF V2 (Acc: 97.4%, AUC: 0.996). FF++ (Acc: 96.9%, AUC: 0.992). Doku tek başına (Acc ~89%), Swin V2 tek başına (Acc ~92%). İkinin birleşimi %97'ye ulaştı. Cross-dataset başarımları zayıf kalmıştır (Acc: ~49%-59%).
Kıyaslanan Modeller	WATCHER, Forgery-Domain-Supervised, LDFNet. Önerilen model LDFNet'i büyük farkla geçmiş, WATCHER ile başa baş rekabet etmiştir.
Review Makale İse İncelediği Yöntemler	İlgili değil
Kullanılan Görseller-Grafikler	Şekil 1: Vi-TexFusion Mimarisi (Çift kollu akış), Şekil 2: Eğitim ve Doğrulama (Loss/Acc) eğrileri, Şekil 3: AUC-ROC Eğrileri.
Getirdiği Yenilikler-Novelty	Derin öğrenme (Swin V2) ile klasik dijital forensik yöntemlerinin (LBP, Gabor, Wavelet, GLCM) eşzamanlı kullanılması (Dual-Branch Framework).
Dezavantajlar-Kısıtlar	Video içi temporal (zamansal) dinamikleri incelemez. Sadece yüzlere odaklı. Cross-dataset genelleme performansı düşük. Kare (frame) bazlı split nedeniyle near-duplicate frame kaynaklı veri sızıntısı şüphesi barındırmaktadır.
Projeye Katkısı-Bizim İçin Önemi	AISC modelinin 'açıklanabilirliği (interpretability)' için Doku (Texture) tabanlı klasik çıkarımların kullanılabileceğini kanıtlamıştır. Data sızıntısı kısıtlamalarına dair uyarıları metodolojimiz için çok değerlidir.
Kod-GitHub Linki	GitHub kodu tamamlanma aşamasında olup bir sonraki çalışmada yayınlanacağı belirtilmiştir.
Durum	İncelendi
Notlar	Swin V2 ve Textural fusion odaklı başarılı bir makale (Springer 2026).