

# MAKALE ANALİZ RAPORU

|                 |                                                          |
|-----------------|----------------------------------------------------------|
| Sorumlu Kişi    | Kader Terik                                              |
| Araştırma Grubu | Deepfake Detection — AISC                                |
| Makale Türü     | Özgün Araştırma (Original Research) — Open Access, CC BY |

## Makale Bilgileri

**Makale Adı:** Lightweight and hybrid transformer-based solution for quick and reliable deepfake detection

**Yazarlar:** Geeta Rani, Atharv Kothekar, Shawn George Philip, Vijaypal Singh Dhaka, Ester Zumpano, Eugenio Vocaturo

**Kurumlar:** 1) Manipal University Jaipur, Jaipur, Rajasthan, India | 2) DIMES, University of Calabria, Rende, Italy | 3) CNR-NANOTEC, Rende, Italy

**Yayınlandığı Dergi:** Frontiers in Big Data

**Yayın Tarihi / Cilt-Makale No:** 01 Nisan 2025 / Vol.8, Article 1521653

**DOI / Link:** 10.3389/fdata.2025.1521653 | <https://doi.org/10.3389/fdata.2025.1521653>

**Geliş / Kabul / Yayın Tarihi:** 02 Kasım 2024 / 11 Mart 2025 / 01 Nisan 2025

**Anahtar Kelimeler:** deepfake, social safety, transformer, blackmail, computation, generative

**Finansman:** Department of Informatics, Modelling, Electronics and Systems (DIMES), University of Calabria [Grant No: SIMPATICOZUMPARNO]

**Editör / Hakemler:** Editör: Roberto Interdonato (TETIS, France) | Hakemler: Olarik Surinta (Mahasarakham Univ., Thailand), Salem Mohammed (Univ. of Mascara, Algeria)

**Kaynakça (APA):** Rani, G., Kothekar, A., Philip, S. G., Dhaka, V. S., Zumpano, E., & Vocaturo, E. (2025). Lightweight and hybrid transformer-based solution for quick and reliable deepfake detection. *Frontiers in Big Data*, 8, 1521653. <https://doi.org/10.3389/fdata.2025.1521653>

## == BÖLÜM 1 : ANLATI RAPORU ==

### 1. Çalışmanın Amacı

Bu çalışma, GAN'lar ve difüzyon modelleri gibi üretici yapay zeka tekniklerinin sosyal güvenliği tehdit eden sahte video/görüntü üretimine zemin hazırladığı gerçeğinden yola çıkmaktadır. Yayımlanan bir rapora göre (2022) insanların %71'i deepfake videolara inanmakta ve şantaj mağduru olmaktadır. Mevcut tespit sistemleri hesaplama maliyeti yüksek ya da farklı üretim tekniklerine karşı genelleme yapamayan yapılardır.

Makalenin üç temel hedefi vardır:

- Vision Transformer (ViT) ve Linformer modellerini entegre eden hafif hibrit bir model geliştirmek.
- Deepfake tespitinde genelleme kabiliyeti ve sağlamlığı (robustness) artırmak.
- Doğruluğu düşürmeden hesaplama maliyetini (eğitim süresi, GFLOPs) azaltmak — modeli gerçek zamanlı uygulamalara uygun kılmak.

## 2. Problem Tanımı ve Literatür Bağlamı

Makale, alandaki dört temel eksikliği öne çıkarmaktadır:

- **Hesaplama Maliyeti:** CNN, ViT ve Linformer tabanlı mevcut yöntemlerin tamamı yüksek işlem gücü gerektirmekte; bu durum gerçek zamanlı sosyal medya uygulamalarında kullanımı kısıtlamaktadır.
- **Genelleme Yetersizliği:** Mevcut modeller, kendi eğitim dağılımlarına sıkı biçimde bağımlıdır. Bir üretim tekniğiyle oluşturulan deepfake'ler üzerinde eğitilen model, farklı bir teknikle üretilmiş içerikleri tespit edemeyebilmektedir.
- **Video Tespitinin İhmal Edilmesi:** Literatürdeki büyük çoğunluk sahte görüntü tespitine odaklanmış; deepfake video tespiti görece az çalışılmış bir alan olarak kalmaktadır.
- **Standart ViT'in Kuadratik Karmaşıklık:** Standart Self-Attention mekanizması  $O(n^2)$  zaman ve bellek karmaşıklığına sahiptir; bu da büyük ölçekli veya yüksek çözünürlüklü girişlerde çok pahalı hale gelmektedir.

İlgili literatürde öne çıkan çalışmalar:

- **Heo et al. (2023):** CNN özelliklerini ViT çerçevesine patch tabanlı konumlandırmayla entegre eden yöntem; Binary Cross-Entropy ile damıtma token'ı eğitilerek %82.63 doğruluk elde edilmiştir. Yalnızca sahte görüntü tespitine odaklanmıştır.
- **Usmani et al. (2024):** Sığ ViT (Shallow ViT) ile deepfake görüntü tespiti; DFDC veri setinde AUC=%95.9, F1=%91.9. Genelleme yeteneği sınırlıdır.
- **Coccomini et al. (2022):** EfficientNet B0 + ViT karma mimari; DFDC ve FaceForensics++ üzerinde F1=%88.0. Tüm yüz bölgelerini (landmark) işlediğinden hesaplama açısından ağırdır.
- **Ramadhani et al. (2024):** Video Vision Transformer (ViViT) + DSC + CBAM blokları; Celeb-DF v2'de %87.18 doğruluk, F1=%92.52.
- **Lin et al. (2023):** Multi-ölçekli konvolüsyon (EfficientNet + genişletilmiş konvolüsyon) + ViT; Celeb-DF v2 üzerinde değerlendirilmiş, düşük kaliteli veri setlerinde çalışmıştır.

## 3. Kullanılan Veri Seti

### 3.1 Veri Seti Genel Bilgileri

Çalışmada tek bir veri seti kullanılmıştır: Celeb-DF v2 (Li et al., 2020).

| Özellik                    | Detay                                                                                      |
|----------------------------|--------------------------------------------------------------------------------------------|
| Veri Seti Adı              | Celeb-DF v2 (Celeb DeepFake Version 2)                                                     |
| Kaynak / Link              | Li, Y., Yang, X., Sun, P., Qi, H., & Lyu, S. (2020). CVPR 2020.                            |
| Veri Tipi                  | Video (RGB modalitesi)                                                                     |
| Toplam Video Sayısı        | 590 gerçek + 5.639 sahte = 6.229 video                                                     |
| Gerçek Video Kaynağı       | YouTube (59 farklı demografik ünlü — çeşitli yaş, cinsiyet, etnik köken)                   |
| Sahte Video Üretim Yöntemi | Gelişmiş DeepFake algoritması (düşük çözünürlük ve renk tutarsızlığı sorunları giderilmiş) |

|                           |                                                                                                                                            |
|---------------------------|--------------------------------------------------------------------------------------------------------------------------------------------|
| Kullanılan Alt Küme       | 1.000 video (5.639+590 arasından rastgele seçilmiş, dengeli: eşit gerçek/sahte)                                                            |
| Video Özellikleri         | Çeşitli arka plan, hareket, aydınlatma koşulları; saniyelerden dakikalara değişen süre                                                     |
| İşleme                    | Her video kare kare (frame-by-frame) ayrıştırılmış; her kare için 25 yüz işaretçi (landmark) belirlenerek 11×11 piksel bölgeler çıkarılmış |
| Annotasyon                | 68 landmark koordinatı manuel olarak annotate edilmiş; (x,y) tamsayı çiftleri; XML bounding box dosyası                                    |
| Sınıf Dağılımı (alt küme) | Dengeli — Gerçek:Sahte = 1:1                                                                                                               |
| Train/Test Ayrımı         | Makalede kesin oran belirtilmemiştir; eğitim ve test setleri ayrılmıştır                                                                   |

### 3.2 Matematiksel Ön İşleme Adımları

Makale, veri ön işlemede özgün ve detaylı bir boru hattı (pipeline) tanımlamaktadır:

- **Adım 1 — Yüz Tespiti:** Dlib kütüphanesi (Davis, 2009; iBUG 300-W veri seti üzerinde önceden eğitilmiş; 7.764 görüntü, 68 landmark) HOG + SVM ile yüz tespiti yapar. Dlib'in tespit edemediği kareler için CNN tabanlı yüz dedektörü devreye girer.
- **Adım 2 — Landmark Tespiti (Özel Tahmin Edici):** 68 landmark yerine hesaplama maliyetini düşürmek amacıyla 25 kritik landmark'a indirgeme yapılmıştır (Yang et al., 2019). En yüksek AUC değerleri, yüzün merkezi bölgesindeki landmark'ların seçilmesiyle elde edilmiştir (kafa duruşu varyasyonlarından kaynaklı tutarsızlıkları önlemek için). Özel tahmin edici modeli 36 MB .dat dosyası üretir.
- **Adım 3 — Video Karelerini Çerçevelere Dönüştürme:** Tüm videolar bireysel karelere bölünmüştür.
- **Adım 4 — Landmark Ekstraksiyonu ve Kırpma:** Her kare için 25 landmark noktasının her biri etrafında 11×11 piksel kare bölge kesilir.
- **Adım 5 — Birleştirme (Concatenation):** 25 adet 11×11 piksel bölge yan yana birleştirilerek 55×55 piksel boyutunda bir görüntü elde edilir.  $(25 \times [11 \times 11] \rightarrow [55 \times 55 \text{ toplam görüntü}])$ . Bu yaklaşım, tüm kare yerine yalnızca yüz özelliklerine odaklanmayı sağlamaktadır.
- **Adım 6 — Patch'e Bölme (ViT / Hibrit Giriş):** 55×55 görüntü, model mimarisine göre 6×6 veya 11×11 piksel boyutlarında patch'lere ayrılır. Dizi uzunluğu: standart ViT için 64 patch; Linformer için ek class token ile 65'e çıkarılır.

#### Veri Artırımı (Data Augmentation):

Makale açıkça augmentation uyguladığını belirtmemektedir. Ancak genellenebilirliği artırmak amacıyla veri seti kontrast, arka plan ve aydınlatma açısından çeşitli videolardan oluşturulmuştur.

## 4. Kullanılan Yöntem / Model

### 4.1 Vision Transformer (ViT) — Temel Model

ViT, bilgisayar görüşü görevleri için tasarlanmış; giriş görüntüsünü sabit boyutlu patch'lere bölen ve bunları bir transformer encoder'a veren mimaridir. Temel dikkat mekanizması:

- $\text{Attention}(Q, K, V) = \text{softmax} \left( \frac{QK^T}{\sqrt{D}} \right) \cdot V \rightarrow \text{Eq.}(1)$
- Q: Sorgular (Queries), K: Anahtarlar (Keys), V: Değerler (Values), D: Giriş gömme boyutu

ViT bileşenleri ve işlev açıklamaları:

- **Lineer Projeksiyon (Düzleştirilmiş Patch'ler):** Patch vektörleri düzleştirilip lineer projeksiyonla yüksek boyutlu gömmelere dönüştürülür; girişin farklı parçaları arasındaki karmaşık ilişkiler öğrenilir.
- **Konum Gömmeleri (Position Embeddings):** Her patch konumu için gradient inimiyle eğitilen vektörler; patch gömmelere eklenir. Patch'ler kendi başlarına konum bilgisi taşımadığından bu adım zorunludur.
- **Transformer Encoder:** Çok sayıda Self-Attention + Feed-Forward katman yığını; bağlamsal bilgiyi yakalar.
- **Çok Başlı Dikkat (Multi-Head Attention):** Q, K, V projektörleri olan birden fazla paralel dikkat başı; patch'ler arasındaki farklı ilişki boyutlarını öğrenir.
- **MLP Baş (Multi-Layer Perceptron Head):** Katman normalizasyonu + doğrusal katman; sınıf skorlarını üretir. Aktivasyon olarak ReLU yerine GeLU (Gaussian Error Linear Unit) kullanılır. GeLU, negatif değerleri daha yumuşak bastırarak vanishing gradient sorununu azaltır.
- **Ortalama Havuzlama (Mean Pooling):** Transformer çıktısı normalize edilmeden önce ortalama havuzlamaya tabi tutulur.
- **Class Token:** Sınıflandırma görevleri için patch dizisine özel bir sınıf token'ı eklenir.

#### 4.2 Linformer — Lineer Karmaşıklık Self-Attention

Linformer (Wang et al., 2020), standart transformer'ın  $O(n^2)$  zaman ve bellek karmaşıklığını doğrusal  $O(n)$  karmaşıklığa düşüren verimli bir varyantıdır. Bunu, orijinal K ve V matrislerini düşük ranklı bir matris ile projekte ederek gerçekleştirir:

- $A' = \text{softmax}(QK'^T / \sqrt{D}) \cdot V \rightarrow \text{Eq.(2)}$
- Tam Dikkat:  $\text{Attention}(Q, K', V) = \text{softmax}(QK'^T / \sqrt{D}) \cdot V' \rightarrow \text{Eq.(3)}$
- $K'$ : Orijinal K matrisinin düşük boyutlu projeksiyonu (reduced-dimensional key matrix)
- $A'$ : Normalizasyon sonrası elde edilen dikkat matrisi
- Dizi uzunluğu ViT'te 64 iken Linformer için 65'e çıkarılır (ek class token gereksinimi nedeniyle)
- Sonuç: Dikkat matrisinin boyutu azalır  $\rightarrow$  eğitim süresi yarıya iner, bellek kullanımı düşer

#### 4.3 Hibrit Transformer Modeli (Önerilen Model)

Önerilen mimari, ViT'in güçlü özellik çıkarım kapasitesini Linformer'ın verimli self-attention mekanizmasıyla birleştirir. Temel tasarım kararı:

- ViT'teki standart Multi-Head Self-Attention (MHSA) Linformer'ın verimli self-attention ile değiştirilir.
- K ve V matrisleri düşük rankli ayrıştırma (low-rank decomposition) ile projekte edilir; boyut azaltılırken kritik bilgi korunur.
- ViT'in kuadratik ölçeklenmesi lineer karmaşıklığa indirgenir  $\rightarrow$  bellek tüketimi azalır.

#### Hibrit Model İşlem Akışı (Şekil 3):

- Giriş görüntüsü patch'lere bölünür (patch boyutu: 6×6 veya 11×11 piksel).
- Patch'ler lineer projeksiyon ile gömülür (linearly projected).
- Konum kodlama (positional encoding) ile mekansal ilişkiler korunur.
- Kodlanmış patch'ler ViT encoder'ına iletilir; ancak attention mekanizması Linformer tabanlıdır.
- Encoder çıktısı gerçek/sahte ikili sınıflandırması için MLP baş'a verilir.

#### 4.4 Eğitim Detayları

| Parametre                     | Değer                                                                                       |
|-------------------------------|---------------------------------------------------------------------------------------------|
| Programlama Dili / Framework  | Python 3.12, PyTorch 2.0                                                                    |
| İşletim Sistemi               | Ubuntu 22.04                                                                                |
| CPU                           | Intel Core i9-10900K @ 3.70 GHz                                                             |
| GPU                           | NVIDIA GeForce RTX 3080 Ti                                                                  |
| RAM                           | 64 GB                                                                                       |
| Disk                          | 3 TB                                                                                        |
| Batch Size                    | 128                                                                                         |
| Learning Rate (Öğrenme Oranı) | 10e-4 (= 0.0001)                                                                            |
| Seed (Rastgelelik Tohumu)     | 142                                                                                         |
| Optimizör (Optimizör)         | Adam                                                                                        |
| Kayıp Fonksiyonu              | Binary Cross-Entropy (İkili Çapraz Entropi)                                                 |
| Epoch Sayısı                  | 50 (50 epoch sonrası kayıp fonksiyonu sabitlendi — daha fazla eğitim gereksiz)              |
| Yakınsama                     | Hibrit model yalnızca 20 epoch'ta maksimum %98.9 doğruluğa ulaşmıştır                       |
| Yüz Tespiti                   | Dlib (HOG+SVM) + CNN fallback (Dlib başarısız olduğunda)                                    |
| Landmark Modeli               | Özel 25-nokta tahmin edici (36 MB .dat dosyası); iBUG 300-W tabanlı 68-nokta'dan türetilmiş |
| Landmark Bölgesi              | 25 landmark × 11×11 px → 55×55 px birleştirilmiş görüntü                                    |
| Patch Boyutu (Deney 1)        | 6×6 piksel                                                                                  |
| Patch Boyutu (Deney 2)        | 11×11 piksel                                                                                |

#### 5. Sonuçlar ve Değerlendirme

##### 5.1 Performans Metrikleri ve Formülleri

- **Accuracy:**  $Accuracy = (TR + TF) / (TR + TF + FR + FF)$  [Eq.4] — TR: Doğru gerçek tahmini, TF: Doğru sahte tahmini, FR: Gerçeği sahte sanan, FF: Sahteyi gerçek sanan
- **Binary Cross-Entropy Loss:**  $L = -1/N \cdot \sum_j [t_j \cdot \log(p_j) + (1-t_j) \cdot \log(1-p_j)]$  [Eq.5] — N: toplam veri noktası,  $t_j$ : gerçek etiket (0 veya 1),  $p_j$ : Softmax olasılığı
- **F1 Skoru:**  $F1 = 2 \cdot (Precision \cdot Recall) / (Precision + Recall)$  [Eq.6]
- **AUC:** ROC eğrisi altındaki iki boyutlu alan; (0,0)-(1,1) arasında TP ve FP oranlarını çizer.
- **GFLOPs:** Giga Floating Point Operations — modelin hesaplama karmaşıklığını sayısal olarak ölçer.

##### 5.2 DeneySEL Sonuçlar — Tam Karşılaştırma Tabloları

Tablo 1: Patch Boyutu = 6 Piksel

| Mimari                   | Eğitim Süresi | Doğruluk (%) | Loss   | F1    | AUC   |
|--------------------------|---------------|--------------|--------|-------|-------|
| Vision Transformer (ViT) | 5s 5d 6sn     | 90.33        | 0.2363 | 0.905 | 0.967 |
| Hibrit ViT + Linformer   | 4s 27d 54sn   | 93.95        | 0.1774 | 0.939 | 0.984 |

Tablo 1 (Tam): Patch Boyutu = 6 Piksel — Tüm Metrikler

| Mimari                            | Eğitim Süresi | Doğruluk (%) | Loss   | F1 Skoru | AUC   | GFLOPs (Eğitim) |
|-----------------------------------|---------------|--------------|--------|----------|-------|-----------------|
| Vision Transformer (ViT)          | 5s 5d 6sn     | 90.33        | 0.2363 | 0.905    | 0.967 | 1.962           |
| Hibrit ViT + Linformer (Önerilen) | 4s 27d 54sn   | 93.95        | 0.1774 | 0.939    | 0.984 | 882             |

**Tablo 2 (Tam): Patch Boyutu = 11 Piksel — Tüm Metrikler**

| Mimari                            | Eğitim Süresi | Doğruluk (%) | Loss   | F1 Skoru | AUC   | GFLOPs (Eğitim) |
|-----------------------------------|---------------|--------------|--------|----------|-------|-----------------|
| Vision Transformer (ViT)          | 6s 12d 46sn   | 92.83        | 0.2751 | 0.935    | 0.985 | 1.963           |
| Hibrit ViT + Linformer (Önerilen) | 5s 6d 50sn    | 95.25        | 0.2211 | 0.954    | 0.989 | 883             |

### 5.3 Temel Sayısal Bulgular ve Teknik Yorumlar

- **En Yüksek Doğruluk:** Hibrit ViT+Linformer modeli, 11 piksel patch boyutunda %95.25 doğruluk, F1=0.954, AUC=0.989 değerlerine ulaşmıştır. Makale özetinde '%98.9' rakamı yer almaktadır; bu değer 20 epoch'ta elde edilen en yüksek doğruluk olduğu belirtilmekte, ancak tablolarda paylaşılan nihai değer %95.25'tir.
- **GFLOPs Karşılaştırması:** ViT: 1.962-1.963 GFLOPs vs Hibrit: 882-883 GFLOPs. Hibrit model, ViT'e kıyasla yaklaşık %55 daha az hesaplama gerektirir (ViT değerinin yaklaşık yarısı).
- **Eğitim Süresi İyileşmesi (Patch 6, Hibrit vs ViT):** Patch 6'da: Hibrit model ViT'ten %21.4 daha hızlı eğitilmektedir. Patch 11'de: Hibrit model ViT'ten %15.32 daha hızlı.
- **Patch Boyutunun Etkisi — ViT:** Patch boyutu 11'den 6'ya düşürüldüğünde ViT eğitim süresi %22.11 azalmaktadır.
- **Patch Boyutunun Etkisi — Hibrit:** Patch boyutu 11'den 6'ya düşürüldüğünde Hibrit eğitim süresi %14.53 azalmaktadır. Büyük patch boyutu ince detayları (fine-grained features) daha iyi yakalamaktadır.
- **Patch 6'da Hibrit vs ViT İyileşmesi:** %4.00 doğruluk artışı, %3.76 F1 artışı, %1.76 AUC artışı, %24.92 loss azalması.
- **Patch 11'de Hibrit vs ViT İyileşmesi:** %2.61 doğruluk artışı, %2.03 F1 artışı, %0.41 AUC artışı, %17.70 loss azalması.
- **Yakınsama Hızı:** Hibrit model yalnızca 20 epoch'ta maksimum doğruluğa yakınsamaktadır; ViT tüm 50 epoch boyunca eğitim gerektirmektedir.
- **Loss Analizi:** 50 epoch boyunca kayıp fonksiyonu değerinin minimal varyasyon göstermesi, aşırı öğrenme (overfitting) ya da az öğrenme (underfitting) yaşanmadığına işaret etmektedir.

## 6. Literatüre Katkıları (Contributions) ve Kısıtlar / Dezavantajlar

### 6.1 Özgün Katkıları

- **Hibrit Mimari:** ViT ve Linformer'in entegrasyonu ile deepfake tespitine özgü yeni bir hibrit mimari önerilmiştir; bu kombinasyon, literatürde deepfake video tespiti için daha önce denenmemiştir.
- **Hesaplama Verimliliği:** Standart transformer'ın  $O(n^2)$  karmaşıklığı  $O(n)$ 'e indirgenerek GFLOPs yaklaşık %55 azaltılmış, eğitim süresi %21.4 kısaltılmıştır.
- **Özel Landmark Pipeline:** 68-noktalı standart landmark'tan 25-noktalı özel landmark'a indirgeme yapılmış; her landmark için 11×11 piksel bölge çıkarılıp birleştirilerek 55×55 piksel giriş matrisi oluşturulmuştur.

- **Video Tespitine Odaklanma:** Literatürde büyük çoğunluğu görüntü tespitine odaklanırken bu çalışma deepfake video tespitine yönelik tasarlanmıştır.
- **Genellenebilirlik:** Veri seti, kontrast, arka plan ve aydınlatma açısından çeşitli videolardan oluşturularak modelin farklı üretim tekniklerine karşı genelleme kabiliyeti artırılmıştır.

## 6.2 Kısıtlar ve Dezavantajlar

- **Tek Veri Seti:** Yalnızca Celeb-DF v2 kullanılmıştır. FaceForensics++ veya DFDC gibi veri setlerinde çapraz veri seti (cross-dataset) değerlendirme yapılmamıştır; gerçek genellenebilirlik kanıtlanamamıştır.
- **Veri Seti Alt Kümesi:** 6.229 video arasından yalnızca 1.000 video rastgele seçilmiş; tüm veri seti üzerinde eğitim yapılmamış olması sonuçların potansiyelini kısıtlıyor olabilir.
- **Baseline Karşılaştırması:** Yalnızca temel ViT ile karşılaştırma yapılmıştır; literatürdeki en iyi performanslı modeller (XceptionNet, EfficientNet hibridleri vb.) ile kapsamlı bir kıyaslama sunulmamıştır.
- **Ses Modalitesi Yok:** Yalnızca görsel içerik (video kareleri) analiz edilmiştir; ses tabanlı deepfake tespiti kapsam dışındadır.
- **Train/Test Oranı Belirtilmemiş:** Eğitim-test ayrımı için kullanılan kesin oranlar makalede paylaşılmamıştır.
- **Sınırlı Karışıklık Matrisi Analizi:** Karışıklık matrisleri (Şekil 5-8) sunulmuş; ancak gerçek ve sahte sınıfları için ayrı ayrı precision/recall/sensitivity/specificity değerleri raporlanmamıştır.
- **Gerçek Zamanlı Test Eksikliği:** Model 'gerçek zamanlı uygulanabilirlik' iddiasında bulunmakta ancak çıkarım (inference) süre ölçümü veya sosyal medya platformlarında entegrasyon testi sunulmamaktadır.
- **Augmentation Belirsizliği:** Veri artırımı uygulanıp uygulanmadığı açıkça belirtilmemiştir.

## 7. Proposed Method Diagram Analizi

Makale dört temel mimari diyagram içermektedir:

### 7.1 Vision Transformer (ViT) Mimarisi

ViT'in uçtan uca işlem akışını göstermektedir: Giriş görüntüsü → Yeniden düzenleme (rearrangement) → Katman Normalizasyonu → Lineer Projeksiyon (transformer boyutuna) → Katman Normalizasyonu → Konum Gömme → Class Token Ekleme → Transformer Modülü → Ortalama Havuzlama → Normalizasyon → MLP Baş (Katman Norm + Lineer Katman) → Sınıf Skorları

### 7.2 Linformer Mimarisi

Linformer'in orijinal K ve V matrislerinin düşük rankli projeksiyon matrisleriyle küçültüldüğünü göstermektedir. Bu sayede dikkat matrisinin boyutu azalır, bellek ve işlem maliyeti doğrusal karmaşıklığa iner.

### 7.3 Hibrit Transformer Model Mimarisi (Önerilen Mimari)

Önerilen modelin bütünü göstermektedir: Giriş Görüntüsü → Patch'lere Bölme → Lineer Projeksiyon → Konum Kodlama → ViT Encoder (Linformer tabanlı attention ile) → Gerçek/Sahte Sınıflandırma. Bu şekil makalenin temel katkısını (MHSA → Linformer Attention değişimi) görsel olarak ortaya koymaktadır.

### 7.4 Örnek Kare ile Sınırlayıcı Kutu ve Yüz Landmark'ları



Dlib ve CNN tabanlı yüz tespiti sonucunda bir kare üzerinde çizilmiş bounding box ve 25 yüz landmark noktasını göstermektedir. Merkezi bölge landmark'larının seçimi, kafa duruşu varyasyonlarına bağlı tutarsızlıkları azaltmaktadır.

## 7.5 Karışıklık Matrisleri

Dört farklı konfigürasyonda (ViT/Patch 6, ViT/Patch 11, Hibrit/Patch 6, Hibrit/Patch 11) test kümesi üzerindeki TP, TN, FP, FN değerlerini görselleştiren karışıklık matrisleri.

## 8. AISC Perspektifi: Bu Çalışma Üzerine Ne Yapılabilir?

### 8.1 Doğrudan Uygulanabilir Teknikler

- **Hibrit Mimari Entegrasyonu:** ViT+Linformer hibrit yapısı, AISC projesindeki mevcut CNN backbone'una alternatif olarak değerlendirilebilir. Özellikle sınırlı hesaplama kaynağı olan ortamlarda (mobil, gömülü sistemler, sosyal medya API'leri) ciddi avantaj sağlayabilir.
- **25-Nokta Landmark Pipeline:** Tüm kare yerine 25 kritik landmark'tan 11×11 px bölge çıkarma → 55×55 px birleştirme yaklaşımı, modeli kaba arka plan gürültüsünden arındırarak daha verimli özellik öğrenimine zemin hazırlar. Bu pipeline AISC'nin mevcut ön işleme aşamasına eklenebilir.
- **GeLU Aktivasyonu:** ReLU yerine GeLU kullanımının vanishing gradient sorununu azalttığı gösterilmiştir; AISC modelinde de GeLU tercih edilmesi düşünülebilir.

### 8.2 Tespit Edilen Boşluklar — AISC Açısından Fırsatlar

- **Cross-Dataset Genelleştirme:** Bu makale yalnızca Celeb-DF v2 üzerinde test yapılmıştır. AISC, bu modeli FaceForensics++, DFDC ve DeeperForensics-1.0 üzerinde de değerlendirerek gerçek genellenebilirliği ölçebilir; bu doğrudan bir yayın katkısı olabilir.
- **Ses + Görüntü Füzyonu:** Makale yalnızca görsel analiz yapmaktadır. Önerilen mimari, HuBERT veya SENet tabanlı ses tespiti modülüyle birleştirilerek multimodal bir deepfake dedektörü oluşturulabilir.
- **Büyük Veri Seti:** 1.000 video yerine DeeperForensics-1.0 (60.000 video, 17.6 milyon kare) üzerinde eğitim, modelin kapasitesini gerçek anlamda test edecektir.
- **Gerçek Zamanlı Çıkarım Testi:** Eğitim GFLOPs ölçümleri sunulmuş; ancak çıkarım (inference) hızı ölçülmemiştir. AISC, farklı donanımlarda (GPU, CPU, mobil) çıkarım süresini kıyaslayarak gerçek zamanlı uygulanabilirliği kanıtlayabilir.
- **Temporal Modelleme Eksikliği:** Makale, videoları frame-level olarak değerlendirmektedir. Kareler arası zamansal tutarlılık (temporal coherence) modellenmemiştir. AISC, hibrit mimariyi LSTM veya 3D-Conv ile genişleterek video düzeyinde tutarsızlıkları da yakalayan bir sistem geliştirebilir.

## == BÖLÜM 2 : TABLO AKTARIM BLOĞU (Google Sheets) ==

| Başlık       | Değer                                                                                       |
|--------------|---------------------------------------------------------------------------------------------|
| Sorumlu Kişi | Kader Terik                                                                                 |
| Atıf No      | Makalede belirtilmemiş                                                                      |
| Makale Türü  | Özgün Araştırma (Original Research) — Open Access, CC BY                                    |
| Makale Adı   | Lightweight and hybrid transformer-based solution for quick and reliable deepfake detection |
| Yıl          | 2025                                                                                        |
| Yazarlar     | Geeta Rani; Atharv Kothekar; Shawn George Philip; Vijaypal Singh                            |



|                                               |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           |
|-----------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|                                               | Dhaka; Ester Zumpano; Eugenio Vocaturo                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    |
| <b>Yayınlandığı Dergi-Konferans</b>           | Frontiers in Big Data — Vol.8, Article 1521653                                                                                                                                                                                                                                                                                                                                                                                                                                                                            |
| <b>DOI-Link</b>                               | 10.3389/fdata.2025.1521653   <a href="https://doi.org/10.3389/fdata.2025.1521653">https://doi.org/10.3389/fdata.2025.1521653</a>                                                                                                                                                                                                                                                                                                                                                                                          |
| <b>Kaynakça Bilgisi (APA)</b>                 | Rani, G., Kothekar, A., Philip, S. G., Dhaka, V. S., Zumpano, E., & Vocaturo, E. (2025). Lightweight and hybrid transformer-based solution for quick and reliable deepfake detection. Frontiers in Big Data, 8, 1521653. <a href="https://doi.org/10.3389/fdata.2025.1521653">https://doi.org/10.3389/fdata.2025.1521653</a>                                                                                                                                                                                              |
| <b>Kullanılan Veri Seti</b>                   | Celeb-DF v2 (Celeb DeepFake Version 2)                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    |
| <b>Dataset Kaynağı-Linki</b>                  | Li, Y., Yang, X., Sun, P., Qi, H., & Lyu, S. (2020). CVPR 2020. GitHub: <a href="https://github.com/yuezunli/celeb-deepfakeforensics">https://github.com/yuezunli/celeb-deepfakeforensics</a>                                                                                                                                                                                                                                                                                                                             |
| <b>Veri Seti Detayı</b>                       | 590 gerçek + 5.639 sahte video (toplam 6.229). Gerçek videolar: 59 ünlü, YouTube kaynaklı, çeşitli demografik özellikler. Sahte videolar: Gelişmiş DeepFake algoritmasıyla üretilmiş. RGB modalitesi, çeşitli arka plan ve aydınlatma koşulları.                                                                                                                                                                                                                                                                          |
| <b>Dataset Boyutu</b>                         | 6.229 video toplam; çalışmada 1.000 video (dengeli gerçek/sahte) kullanılmıştır.                                                                                                                                                                                                                                                                                                                                                                                                                                          |
| <b>Train-Test-Validation Ayrımı</b>           | Makalede kesin oran belirtilmemiştir. Eğitim ve test setleri ayrılmıştır.                                                                                                                                                                                                                                                                                                                                                                                                                                                 |
| <b>Kullanılan Model-Yöntem</b>                | Hibrit Transformer Modeli: Vision Transformer (ViT) + Linformer (Self-Attention with Linear Complexity). Baseline: Standart ViT.                                                                                                                                                                                                                                                                                                                                                                                          |
| <b>Model Mimari Detayı</b>                    | ViT bileşenleri: Lineer Projeksiyon, Konum Gömme, Transformer Encoder (Multi-Head Attention), MLP Baş (GeLU aktivasyonu), Ortalama Havuzlama, Class Token. Linformer: K ve V matrislerini düşük rankli matris ile projekte eder; $O(n^2) \rightarrow O(n)$ . Hibrit: MHSA $\rightarrow$ Linformer Attention değişimi. Giriş: 55×55 piksel (25 landmark × 11×11 px). Patch: 6×6 veya 11×11 px. Dizi uzunluğu: 64 (ViT) / 65 (Linformer). Eğitim: Batch=128, LR=10e-4, Seed=142, Adam optimizier, Binary CE loss, 50 epoch. |
| <b>Çalışmanın Amacı</b>                       | ViT ve Linformer mimarilerini birleştiren hafif hibrit bir model geliştirerek deepfake video tespitinde hesaplama maliyetini düşürmek, genellenebilirliği artırmak ve yüksek doğruluk sağlamak.                                                                                                                                                                                                                                                                                                                           |
| <b>Ölçüm Metrikleri</b>                       | Accuracy, Loss (Binary Cross-Entropy), F1 Score, AUC (ROC eğrisi altı alan), GFLOPs (hesaplama karmaşıklığı)                                                                                                                                                                                                                                                                                                                                                                                                              |
| <b>Veri Ön İşleme Adımları</b>                | 1) Yüz tespiti: Dlib (HOG+SVM) + CNN fallback 2) 25-nokta özel landmark tespiti (iBUG 300-W tabanlı 68-noktadan indirgeme) 3) Video→kare dönüşümü 4) Her landmark için 11×11 px bölge ekstraksiyonu 5) 25 bölgenin birleştirilerek 55×55 px görüntü oluşturulması 6) Patch'lere bölme (6×6 veya 11×11 px)                                                                                                                                                                                                                 |
| <b>Data Augmentation Kullanıldı mı?</b>       | Makalede açıkça belirtilmemiştir. Genelleme için kontrast/arka plan/aydınlatma çeşitliliği barındıran videolar kullanılmıştır.                                                                                                                                                                                                                                                                                                                                                                                            |
| <b>Çalışmanın Sonuçları</b>                   | Patch 6 — Hibrit: %93.95 doğruluk, Loss=0.1774, F1=0.939, AUC=0.984, GFLOPs=882. Patch 11 — Hibrit: %95.25 doğruluk, Loss=0.2211, F1=0.954, AUC=0.989, GFLOPs=883. Patch 6 — ViT: %90.33, Loss=0.2363, F1=0.905, AUC=0.967, GFLOPs=1.962. Patch 11 — ViT: %92.83, Loss=0.2751, F1=0.935, AUC=0.985, GFLOPs=1.963. Hibrit model ViT'ten %21.4 daha hızlı eğitilir; GFLOPs ~%55 azalır. 20 epoch'ta %98.9 maksimum doğruluğa yakınsama (abstract'ta belirtilmiştir).                                                        |
| <b>Kıyaslanan Modeller</b>                    | Standart Vision Transformer (ViT). Ayrıca ilgili çalışmalar olarak: Heo et al. (%82.63), Usmani et al. (AUC=%95.9, F1=%91.9), Coccomini et al. (F1=%88.0), Ramadhani et al. (%87.18 doğruluk, F1=%92.52) anılmaktadır.                                                                                                                                                                                                                                                                                                    |
| <b>Review Makale İse İncelediği Yöntemler</b> | İlgili değil — Özgün araştırma makalesidir.                                                                                                                                                                                                                                                                                                                                                                                                                                                                               |
| <b>Kullanılan Görseller-Grafikler</b>         | Şekil 1: ViT Mimarisi; Şekil 2: Linformer Mimarisi; Şekil 3: Hibrit Transformer Mimarisi; Şekil 4: Bounding box ve 25 yüz landmark örnek kare; Şekil 5: ViT Patch 6 karışıklık matrisi; Şekil 6: ViT Patch 11 karışıklık matrisi; Şekil 7: Hibrit Patch 6 karışıklık matrisi; Şekil 8: Hibrit Patch 11 karışıklık matrisi. Tablo 1: Patch 6 sonuçları; Tablo 2: Patch 11 sonuçları.                                                                                                                                       |
| <b>Getirdiği Yenilikler-Novelty</b>           | Deepfake video tespiti için ilk ViT+Linformer hibrit mimarisi önerisi. Standart MHSA $\rightarrow$ Linformer attention değişimiyle $O(n^2) \rightarrow O(n)$ karmaşıklık azaltımı. 25-nokta özel landmark + 11×11 px bölge birleştirme pipeline'ı. GFLOPs ~%55 azalması ile eğitim süresi %21.4 kısaltılması.                                                                                                                                                                                                             |

|                                         |                                                                                                                                                                                                                                                                                                                                           |
|-----------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Dezavantajlar-Kısıtlar</b>           | Tek veri seti (Celeb-DF v2 / 1.000 video alt kümesi); Cross-dataset değerlendirme yapılmamıştır; Yalnızca ViT ile kıyaslama (kapsamlı baseline karşılaştırması yok); Ses modalitesi kapsam dışı; Train/test oranı belirtilmemiştir; Çıkarım (inference) süresi ölçülmemiştir; Temporal modelleme (kare-arası tutarlılık) bulunmamaktadır. |
| <b>Projeye Katkısı-Bizim İçin Önemi</b> | Hafif ve hızlı hibrit mimari, AISC'nin gerçek zamanlı sosyal medya tarama hedefiyle doğrudan örtüşüyor. 25-landmark + 55×55 px ön işleme pipeline'ı mevcut sisteme entegre edilebilir. Cross-dataset genelleştirme testi AISC için özgün katkı fırsatı sunar. Ses modülü eklenerek multimodal genişleme mümkündür.                        |
| <b>Kod-GitHub Linki</b>                 | Makalede belirtilmemiştir.                                                                                                                                                                                                                                                                                                                |
| <b>Durum</b>                            | İncelendi                                                                                                                                                                                                                                                                                                                                 |
| <b>Notlar</b>                           | 9 sayfalık özgün araştırma makalesi (Frontiers in Big Data). Geliş: 02.11.2024 / Kabul: 11.03.2025 / Yayın: 01.04.2025. Finansman: DIMES, Üniversite di Calabria [SIMPATICOZUMPARNO]. Donanım: RTX 3080 Ti, i9-10900K, 64GB RAM, Ubuntu 22.04. Generative AI kullanılmamıştır (yazar beyanı).                                             |