

MAKALE ANALİZ RAPORU

Sorumlu Kişi	Kader Terik
Araştırma Grubu	Deepfake Detection — AISC
Makale Türü	Özgün Araştırma (Original Research) — Open Access, CC BY 4.0

Makale Bilgileri

Makale Adı: MEViT: Generalization of Deepfake Detection With Meta-Learning EfficientNet Vision Transformer

Yazarlar: Van-Nhan Tran, Hoanh-Su Le, Piljoo Choi, Suk-Hwan Lee, Ki-Ryong Kwon

Kurumlar: Pukyong National University (Güney Kore), University of Economics and Law (Vietnam), Dong-A University (Güney Kore)

Yayınlandığı Dergi: IEEE Open Journal of the Computer Society

Cilt / Yıl / DOI: Vol. 6, 2025 | DOI: 10.1109/OJCS.2025.3568044

Anahtar Kelimeler: Deep learning, deepfake detection, GAN, generalization, meta-learning, video forensics.

Kaynakça (APA): Tran, V.-N., Le, H.-S., Choi, P., Lee, S.-H., & Kwon, K.-R. (2025). MEViT: Generalization of Deepfake Detection With Meta-Learning EfficientNet Vision Transformer. *IEEE Open Journal of the Computer Society*, 6, 789-800. <https://doi.org/10.1109/OJCS.2025.3568044>

== BÖLÜM 1 : ANLATI RAPORU ==

1. Çalışmanın Amacı

Mevcut deepfake tespit yaklaşımlarının (çoğunlukla CNN tabanlı) bilinen manipülasyon tekniklerinde yüksek başarı gösterirken, yeni ve görülmemiş (unseen) üretken modellere karşı zayıf genelleme (generalization) performansı sergilemesi temel bir problemdir.

Bu çalışmanın amacı, bu genelleme eksikliğini aşmak için meta-öğrenme (meta-learning) çerçevesiyle güçlendirilmiş, EfficientNet ve Vision Transformer (ViT) mimarilerini birleştiren MEViT modelini önermek ve özel kayıp fonksiyonları (PDL, DAL) ile alan (domain) kaymalarını azaltmaktır.

2. Problem Tanımı ve Literatür Bağlamı

Temel Sorunlar:

- **Dağılım Kayması (Distribution Shift):** Farklı deepfake üreticilerinin (GAN türevleri, FaceSwap, Face2Face vb.) yarattığı izler, eğitim ve test veri setleri arasında belirgin bir alan farkı oluşturmaktadır.
- **Overfitting (Aşırı Uyum):** CNN modellerinin manipülasyon yöntemlerine ezberlemesi sonucu unseen (görülmemiş) domain'lerde büyük başarı düşüşü yaşanması.

Literatürde öne çıkan ilgili çalışmalar:

- **CNN Sınıflandırıcılar (Xception, EfficientNet):** Sadece kapalı setlerde yüksek performans.
- **Domain Generalization (DG) ve Meta-Öğrenme:** MAML, MLDG gibi çalışmalar (örn. Sun et al. - Learning-to-Weight) modelin domainler arası geçişte genellenebilmesini amaçlar ancak deepfake probleminin özel dinamiklerinde tek başlarına yetersiz kalabilirler.

3. Kullanılan Veri Seti

Testler, yaygın benchmark'ların Domain Generalization (DG) için uyarlanmış alt setlerinde yapılmıştır:

- **FaceForensics++ (FF++):** 4 manipülasyon yöntemi: DeepFake (DF), Face2Face (F2F), FaceSwap (FS), NeuralTexture (NT). Yüksek ve düşük kalite olmak üzere 2 sıkıştırma seviyesi (c23 ve c40).
- **Celeb-DF-v2:** Daha yüksek kaliteli sahte videolar, genelleme testi için Target Domain olarak kullanılmıştır.

Deney Kurguları (Benchmarks):

- **IDFF (Intra-dataset FaceForensics):** FF++'ın belirli bir manipülasyon türünde eğitilip, FF++ içindeki diğer manipülasyonlarda test edilir.
- **CDFF (Cross-dataset FaceForensics):** FF++ üzerinde meta-öğrenme yapıp, tamamen farklı dağılıma sahip Celeb-DF-v2 üzerinde test edilir.

Veri Ön İşleme (Data Preparation):

- MTCNN ile yüzler tespit edilip kırılır ve 224×224 boyutuna (RGB) yeniden boyutlandırılır.

4. Kullanılan Yöntem / Model

4.1 MEViT Mimarisi

MEViT (Meta-learning EfficientNet Vision Transformer), üç ana bileşenden oluşur:

- **Özellik Çıkarımı (EfficientNet):** EfficientNet (B4 varyantı varsayılan), giriş görüntüsünden 7×7 piksellik uzamsal (spatial) ve yerel özellikleri çıkarır. ImageNet ile ön-eğitimi yapılmıştır.
- **Dikkat Mekanizması (Vision Transformer - ViT):** EfficientNet'in çıkışı düzleştirilir (flattening), ardından CLS token eklenerek ViT encoder'a verilir. ViT, lokal özellikleri global bir çerçevede ilişkilendirir.
- **Meta-Öğrenme Optimizasyon Döngüsü:** Eğitim kümesi (Source Domain), kendi içinde meta-train ve meta-validation olarak ayrılır. Meta-learning, modelin eğitim esnasında sanki unseen bir veri seti görüyor gibi davranmasını (simülasyon) sağlar.

4.2 Kayıp Fonksiyonları (Loss Functions)

- **Pair-Discrimination Loss (PDL):** Sahte ve gerçek görüntü özelliklerinin vektörel uzayda (embedding) ayrışmasını sağlar. Gerçek-sahte çiftleri arasındaki Euclidean mesafesini maksimize ederken, sahte özniteliklerin gerçek öznitelik merkezinden (mean) uzaklaşmasını teşvik eder.
- **Domain Adjustment Loss (DAL):** Farklı domain'lerden (manipülasyon türlerinden) gelen özellik dağılımlarının merkezlerini, global bir öznitelik merkezine (embedding center) yaklaştırarak alan farkını (domain gap) kapatır.

Özet Eğitim Aşaması:

- 1. Meta-Train: PDL, DAL ve BCE Loss ile güncellemeler simüle edilir.
- 2. Meta-Test: Meta-validation verisinde simüle edilen güncellemelerin performansı ölçülür.
- 3. Meta-Optimization: Gerçek model ağırlıkları (SGD ile), hem Meta-train hem Meta-test'ten gelen yönelimler harmanlanarak (gradient aggregation) güncellenir.

5. Sonuçlar ve Değerlendirme

Ana Metrikler: ACC (Accuracy) ve AUC (Area Under Curve)

5.1 IDFF (Intra-dataset) Performansı

- Farklı manipülasyon tekniklerine genellemede (ör. FF++ içinde DF'de eğitilip diğerlerinde test etme), MEViT modeli Face X-ray, XceptionNet gibi standart yöntemleri geride bırakmıştır.

5.2 CDFF (Cross-dataset) Performansı

- FF++ verilerinde eğitilip Celeb-DF-v2 test edildiğinde, geleneksel CNN'ler hızla düşüş yaşarken, MEViT genel hatlarıyla Learning-to-Weight (L2W) gibi SOTA meta-learning metodlarıyla yarışmış, çoğu konfigürasyonda en yüksek genellenabilirliği sağlamıştır.
- Örneğin: LGrad (ACC ~0.50), HiFi-Net (ACC ~0.60) seviyesinde kalırken, MEViT'in cross-dataset performansı %70-%75 AUC bandına çıkabilmektedir.

5.3 Ablasyon Testi (Ablation Study)

- Yalnızca BCE kullanıldığında sonuçlar düşüktür.
- BCE + PDL (Pair Discrimination) ile performans artar.
- BCE + PDL + DAL kombosu, en yüksek (optimal) accuracy (örn. IDFF-2-23 senaryosunda ~0.94 ACC) değerini vermiştir. DAL'ın domain'leri hizalama (alignment) görevi ispatlanmıştır.

5.4 Backbone Karşılaştırması

- EfficientNet B0, B4 ve B7 varyantları kıyaslanmıştır. B7 en yüksek AUC'yi verse de hesaplama maliyeti yüksektir. B4 ise en yüksek ACC oranını ve optimum maliyet dengesini sunmuştur (Makale genelinde B4 kullanılmıştır).

6. Literatüre Katkıları ve Kısıtlar

6.1 Özgün Katkıları

- EfficientNet (yerel özellikler) ile ViT (global ilişkiler) birleşiminin meta-öğrenme ile deepfake tespiti özelinde domain generalization için ilk kez bu kadar güçlü şekilde formüle edilmesi.
- PDL (Sınıf ayırma) ve DAL (Domain yakınlaştırma) kayıplarının birbiriyle rekabet/uyum içinde çalışarak overfit'i engellemesi.

6.2 Kısıtlar (Sınırlılıklar)

- Yalnızca görsel veriye (spatial face) odaklanmaktadır. Ses-görüntü asenkronizasyonu (FakeAVCeleb) gibi multimodal durumları analiz edemez.
- Düşük kaliteli/sıkıştırılmış videolarda (örn. FF++ c40), yüksek kaliteli (c23) olanlara kıyasla performansı hala hassastır (biraz düşük göstermektedir).

7. AISC Perspektifi: Bu Çalışma Üzerine Ne Yapılabilir?

- **Meta-Learning Modülünün AISC'e Eklenmesi:** Mevcut model mimarinize, modelinizi farklı veri setlerinde meta-learning mantığı ile eğitebileceğiniz bir 'Domain Generalization' katmanı veya döngüsü (Algorithm 1) yazılabilir. Bu modelinizin yepyeni deepfake üreticilerinde daha dayanıklı olmasını sağlayacaktır.
- **Loss Functions (Kayıp Fonksiyonları):** Projenizde mevcut Binary Cross-Entropy (BCE) kullanılıyorsa, modelinizin kayıp hesabına PDL (Pair-Discrimination Loss) denklemi bir regularizasyon terimi olarak kolaylıkla entegre edilebilir.
- **Audio-Visual Füzyon İhtiyacı:** Makale yazarının da belirttiği gibi gelecekteki deepfake tehlikesi multimodaldır. AISC, MEViT'i video analiz omurgası olarak alıp, yanına ses modülünü (HuBERT vb.) ekleyerek bu makaledeki eksiği kapatabilir.

== BÖLÜM 2 : TABLO AKTARIM BLOĞU (Google Sheets) ==

Başlık	Değer
Sorumlu Kişi	Kader Terik
Atıf No	Makalede belirtilmemiş (Çok Yeni Yayın - 2025)
Makale Türü	Özgün Araştırma (Original Research)
Makale Adı	MEViT: Generalization of Deepfake Detection With Meta-Learning EfficientNet Vision Transformer
Yıl	2025
Yazarlar	Van-Nhan Tran, Hoanh-Su Le, Piljoo Choi, Suk-Hwan Lee, Ki-Ryong Kwon
Yayınlandığı Dergi-Konferans	IEEE Open Journal of the Computer Society, Vol. 6, s. 789-800
DOI-Link	10.1109/OJCS.2025.3568044
Kaynakça Bilgisi (APA)	Tran, V.-N., Le, H.-S., Choi, P., Lee, S.-H., & Kwon, K.-R. (2025). MEViT: Generalization of Deepfake Detection With Meta-Learning EfficientNet Vision Transformer. IEEE Open Journal of the Computer Society, 6, 789-800. https://doi.org/10.1109/OJCS.2025.3568044
Kullanılan Veri Seti	FaceForensics++ (FF++) [c23, c40 sürümleri], Celeb-DF-v2
Dataset Kaynağı-Linki	Makalede doğrudan link yerine atıf verilmiştir. [FaceForensics++, Celeb-DF-v2 açık erişimdir.]
Veri Seti Detayı	FF++ (DeepFake, Face2Face, FaceSwap, NeuralTexture). Celeb-DF-v2 (Gelişmiş sahte). Sadece görsel modalite.
Dataset Boyutu	FF++: 1000 orijinal, 4000 sahte. Celeb-DF-v2: 890 orijinal, 5639 sahte video (Makalede sadece yüz kırpıntıları kullanılmıştır).
Train-Test-Validation Ayrımı	IDFF/CDFF Benchmark'ları için Domain Generalization kurallarına göre bölünmüştür. (Source domainler meta-train ve meta-val olarak ayrılmış, target domain tamamen unseen test için bırakılmıştır).
Kullanılan Model-Yöntem	MEViT (Meta-learning EfficientNet Vision Transformer)
Model Mimari Detayı	EfficientNet (B4 varyantı ağırlıklı) + Vision Transformer (ViT). 224x224 yüz girişi. Meta-Learning iterasyon döngüsü (Inner LR=0.0005, Gamma=0.0005). Özel kayıplar: PDL, DAL ve BCE.
Çalışmanın Amacı	Deepfake modellerinin ezberlemesini (overfitting) engelleyip, tamamen daha önce görülmemiş (unseen) üretken

	modellere/domainlere karşı genellenebilir (Domain Generalization) bir tespit çerçevesi tasarlamak.
Ölçüm Metrikleri	ACC (Accuracy) ve AUC (Area Under Curve)
Veri Ön İşleme Adımları	MTCNN ile videolar üzerinden yüz kırılması (face extraction). Boyutlandırma (224x224). EfficientNet ile 7x7 spatial patch çıkarma.
Data Augmentation Kullanıldı mı?	Makale metninde sentetik veri artırımı detayı açıkça belirtilmemiştir, odak noktası meta-learning ile domain augmentasyonudur.
Çalışmanın Sonuçları	Cross-dataset (FF++ üzerinde eğitip Celeb-DF-v2'de test etme) senaryolarında, klasik CNN modellerinden çok daha iyi performans sergilenmiş, AUC değerleri en zorlayıcı testlerde bile ~0.75-0.80 bandında kalmıştır.
Kıyaslanan Modeller	XceptionNet, LRNet, CNN+RNN, MTD-Net, Multi-Attentional, LGrad, HiFi-Net, FreqNet, Learning-to-Weight (L2W), MAML, MLDG.
Review Makale İse İncelediği Yöntemler	İlgili değil
Kullanılan Görseller-Grafikler	Şekil 1: MEViT Meta-Learning akışı, Şekil 2: Model genel blok şeması, Şekil 5: EfficientNet-ViT mimarisi. Grafik 7: Loss parametre analiz grafikleri.
Getirdiği Yenilikler-Novelty	Deepfake Tespiti için Meta-Öğrenme + ViT'in özel kayıp fonksiyonları (Pair-Discrimination ve Domain Adjustment Loss) eşliğinde kullanılması.
Dezavantajlar-Kısıtlar	Düşük kaliteli/sıkıştırılmış videolara karşı kırılgan. Yalnızca video (yüz) işler, sesi dikkate almaz.
Projeye Katkısı-Bizim İçin Önemi	Domain Generalization (Farklı veri setlerine adaptasyon) için kod tabanımıza Loss (PDL) ve eğitim döngüsü (Meta-Train / Meta-Test) olarak entegre edilebilir bir mantık (Algoritma 1) sunar.
Kod-GitHub Linki	Makalede belirtilmemiştir.
Durum	İncelendi
Notlar	Çok yeni bir araştırma (Mayıs 2025). IEEE Open Journal of the Computer Society.