

MAKALE ANALİZ RAPORU

Sorumlu Kişi	Kader Terik
Araştırma Grubu	Deepfake Detection — AISC
Makale Türü	Özgün Araştırma (Original Research) — Open Access, CC BY 4.0

Makale Bilgileri

Makale Adı: Real-Time Deepfake Detection via Gaze and Blink Patterns: A Transformer Framework

Yazarlar: Muhammad Javed, Zhaohui Zhang*, Fida Hussain Dahri, Asif Ali Laghari*, Martin Krajčík, Ahmad Almadhor

Kurumlar: 1) Donghua University, Shanghai, China | 2) Southeast University, Nanjing, China | 3) Shenyang Normal University, China | 4) Comenius University, Bratislava, Slovakia | 5) Joutf University, Saudi Arabia

Yayınlandığı Dergi: Computers, Materials & Continua (CMC) — Tech Science Press

Cilt / Sayfa Aralığı: Vol.85, No.1, s. 1457–1493 (2025)

DOI / Link: 10.32604/cmc.2025.062954 | <https://doi.org/10.32604/cmc.2025.062954>

Geliş / Kabul / Yayın Tarihi: 31 Aralık 2024 / 06 Haziran 2025 / 29 Ağustos 2025

Anahtar Kelimeler: deepfake detection; deep learning; video forensics; gaze and blink patterns; transformers; TimeSformer; MesoNet4

Finansman: Araştırmacılar herhangi bir finansman almadığını beyan etmiştir.

Kaynakça (APA): Javed, M., Zhang, Z., Dahri, F. H., Laghari, A. A., Krajčík, M., & Almadhor, A. (2025). Real-time deepfake detection via gaze and blink patterns: A transformer framework. *Computers, Materials & Continua*, 85(1), 1457–1493. <https://doi.org/10.32604/cmc.2025.062954>

BÖLÜM 1 : ANLATI RAPORU

1. Çalışmanın Amacı

Yapay zeka ve büyük ölçekli veri setlerindeki hızlı ilerleme, deepfake video üretimini giderek kolaylaştırmakta; kimlik hırsızlığı, dezenformasyon ve kamuya güven kaybı gibi ciddi tehditler doğurmaktadır. Mevcut deepfake tespit yöntemlerinin büyük çoğunluğu global yüz özelliklerine odaklanmakta; ancak göz bölgesindeki lokalize ve dinamik ipuçları — gaze (bakış yönü) sapmaları ve blink (göz kırpma) anomalileri — yeterince işlenmemektedir.

Bu çalışmanın dört temel hedefi şunlardır:

- TimeSformer modelini, deepfake tespiti için göz bölgesi odaklı spatio-temporal dikkat mekanizmasıyla uyarlamak (ROI ekstraksiyonu ve temporal düzleştirme dahil özel ön işleme ile).
- MesoNet4 (hafif CNN) + TimeSformer'dan oluşan Hibrit Transformer-CNN modelini alternatif baseline olarak geliştirmek ve iki mimari arasındaki doğruluk-verimlilik dengesini analiz etmek.
- Dört standart kıyaslama veri seti üzerinde (FaceForensics, CelebDF-V2, DFDC, FakeAVCeleb) Intra- ve Cross-dataset değerlendirme yaparak çerçevenin genellenebilirliğini kanıtlamak.
- Yüksek FPS (kare/saniye) değerleri ile gerçek zamanlı dağıtıma uygun, hesaplama açısından verimli bir sistem ortaya koymak.

2. Problem Tanımı ve Literatür Bağlamı

Makale dört temel eksikliği tespit etmektedir:

- **Global Özellik Bağımlılığı:** CNN tabanlı yöntemler (VGG16, ResNet50, Xception) ve çoğu ViT yaklaşımı global yüz özelliklerine odaklanır; göz kırpma aralıkları ve bakış yönü gibi lokalize ve temporal dinamikler göz ardı edilmektedir.
- **Genelleme Sorunu:** Eğitim dağılımına özgü aşırı uyum (overfitting); modeller yeni manipülasyon tekniklerine veya farklı veri setlerine genelleyememektedir.
- **Temporal Duyarlılık Eksikliği:** Kare-düzeyi analiz yapan yöntemler, gaze ve blink gibi kare-arası zamanlı tutarsızlıkları yakalamakta yetersiz kalmaktadır.
- **Gerçek Zamanlılık:** Hesaplama maliyeti yüksek sistemlerin sosyal medya platformları gibi gerçek zamanlı uygulamalarda kullanımı kısıtlıdır.

Literatürde öne çıkan ilgili çalışmalar:

- **Coccomini et al. (2022):** EfficientNet B0 + ViT karma mimari; DFDC ve FaceForensics++ üzerinde F1=%88.0. Tüm landmark'ları işlediğinden hesaplama açısından ağırdır.
- **Wodajo & Atnafu (2021) — CViT:** Konvolüsyonel Vision Transformer; FaceForensics'te %93.0, DFDC'de %87.25 doğruluk. Cross-dataset analiz sınırlıdır.
- **Zhao et al. (2023) — ISTVT:** Yorumlanabilir Spatio-Temporal Video Transformer; ayrıştırılmış dikkat + öz-çıkarma mekanizması ile güçlü intra/inter-dataset performansı.
- **Kaddar et al. (2024) — HCiT:** Spatio-temporal transformer; FaceForensics'te %96.0 doğruluk, F1=%93.86. CelebDF-V2'de %76.03 ile zayıf cross-dataset genelleme.
- **Jung et al. (2020) — DEEP:** İnsan göz kırpma deseni tabanlı tespit; göz kırpma analizinin öncü çalışması. Gelişmiş deepfake üretim teknikleri karşısında kırılganlık göstermektedir.
- **FakeCatcher (Ciftci et al., 2024):** PPG (fotopletismografi) biyolojik sinyaller + CNN + SVM; Celeb-DF, FaceForensics ve FakeAVCeleb üzerinde güçlü intra ve inter-dataset performansı.

3. Kullanılan Veri Seti

3.1 Veri Seti Özeti

Çalışmada dört standart kıyaslama veri seti kullanılmıştır:

Veri Seti	Train Real	Train Fake	Val Real	Val Fake	Test Real+Fake
FaceForensics++	47.808	47.808	5.360	5.360	2.000 + 2.000
CelebDF-V2	50.000	50.000	10.000	10.000	1.000 + 1.000
DFDC	50.000	50.000	10.000	10.000	2.000 + 2.000
FakeAVCeleb	47.808	47.808	5.360	5.360	2.000 + 2.000

3.2 Veri Seti Detayları

- **FaceForensics++ [Rössler et al., 2019]:** Deepfake tespitinde en yaygın benchmark. Dört manipülasyon yöntemi içerir: DeepFakes, Face2Face, FaceSwap ve NeuralTextures. Yüksek, orta ve düşük kalite sürümleri mevcuttur. Makalede sample görüntüleri Şekil 2'de sunulmuştur.
- **CelebDF-V2 [Li et al., 2020]:** Yüksek kaliteli sahte videolar; çeşitli demografik özellikler (yaş, cinsiyet, etnik köken). Gelişmiş swap algoritmasıyla üretilmiş, erken deepfake veri setlerindeki düşük çözünürlük ve renk tutarsızlığı sorunları giderilmiştir. Sample görüntüleri Şekil 3'te verilmiştir.
- **DFDC — DeepFake Detection Challenge [Dolhansky et al., 2020]:** Facebook tarafından oluşturulan büyük ölçekli veri seti; cinsiyet, etnik köken ve yaş açısından çeşitli katılımcılar içerir. Birden fazla deepfake üretim yöntemi kullanılmıştır. Sample görüntüleri Şekil 4'te yer almaktadır.
- **FakeAVCeleb [Khalid et al., 2022]:** En güncel veri setlerinden biri; ses-video multimodal deepfake içerikleri barındırır. Ünlü kimlikler üzerinden üretilmiş sahte içerikler. Sample görüntüleri Şekil 5'te sunulmuştur.

3.3 Ön İşleme Pipeline'ı (Matematiksel Detaylar)

- **Adım 1 — ROI Ekstraksiyonu (Göz Bölgesi):** Dlib kütüphanesi ile yüz landmark tespiti: $L = \{(x_i, y_i)\}_{i=1}^n$. Göz bölgesi bounding box: $B_{eye} = [\min x_i, \min y_i, \max x_i, \max y_i]$ (Eq.1). Göz bölgesi kırpma: $I_{eye} = I[B_{eye}]$ (Eq.2). Her kare için tutarlı göz bölgesi kırpıntıları elde edilir (Şekil 6B).
- **Adım 2 — Normalizasyon ve Boyutlandırma:** Bikübik interpolasyon ile sabit (H,W) boyutuna yeniden boyutlandırma: $I'_{eye} = \text{Resize}(I_{eye}, (H,W))$ (Eq.3). Piksel yoğunluğu [0,1] aralığına normalizasyon: $I'_{eye}(i,j) = [I_{eye}(i,j) - \min(I_{eye})] / [\max(I_{eye}) - \min(I_{eye})]$ (Eq.4).
- **Adım 3 — Temporal Düzleştirme (Gaussian Filtre):** Gaze ve blink özelliklerindeki gürültüyü azaltmak için Gaussian filtre uygulanır: $\tilde{G}_t = (1/\sqrt{2\pi\sigma^2}) \cdot \sum_{\tau=-K \text{ to } K} G_{t+\tau} \cdot \exp(-\tau^2/2\sigma^2)$ (Eq.5). Burada σ filtre genişliğini, $2K+1$ pencere boyutunu kontrol eder (Şekil 6C).
- **Adım 4 — Veri Artırımı (Augmentation):** ROI Kaydırma: $I''_{shifted}(i,j) = I'_{eye}(i+\Delta x, j+\Delta y)$ — rastgele ofsetlerle (Eq.6). Kırpma & Ölçekleme: Rastgele alt bölge kırpma + (H,W)'ye yeniden boyutlandırma. Parlaklık Ayarı: $I''_{aug} = \alpha \cdot I''_{eye} + \beta$ — α, β parlaklık ve kontrast kontrol (Eq.7).

4. Kullanılan Yöntem / Model

4.1 TimeSformer Modeli (Ana Model)

TimeSformer (Time-Space Transformer), Facebook AI Research tarafından 2021'de önerilen video anlama için spatio-temporal dikkat tabanlı mimaridir (Bertasius et al., 2021). Bu çalışmada, deepfake tespiti için göz bölgesine özel olarak uyarlanmıştır.

TimeSformer İşlem Akışı — Matematiksel Formülasyon:

- Video: $V = \{F_1, F_2, \dots, F_T\}$ (Eq.8) — T kare dizisi
- ROI Ekstraksiyonu: her kare için göz bölgesi
- Uzamsal Patch'ler
- Konum Gömme: konum bilgisi ekleme
- Uzamsal Dikkat: kare içi ilişkiler
- Temporal Dikkat: kare-arası dinamikler
- Nihai Temsil: sınıflandırma başı

TimeSformer Hiperparametreleri

Parametre	Açıklama	Değer
Input Size	Göz bölgesi çözünürlüğü	128 × 128 piksel
Patch Size	Uzamsal patch boyutu	16 × 16 piksel
Sequence Length	Video kare sayısı	32
Embedding Dim	Gömme boyutu	768
Layers	Transformer katman sayısı	12
Attention Heads	Çok başlı dikkat sayısı	8
Dropout Rate	Regularizasyon	0.1
Optimizer	Eğitim optimizörü	AdamW
Learning Rate	Başlangıç öğrenme oranı	3×10^{-4}
Epochs	Eğitim iterasyonu	50

4.2 Hibrit Transformer-CNN Modeli (Baseline)

TimeSformer'ın birincil model olarak etkinliğini değerlendirmek amacıyla geliştirilen alternatif mimaridir. MesoNet4 (hafif CNN) uzamsal özellik çıkarımı ile transformer modülünün temporal modelleme kapasitesini birleştirmektedir.

Hibrit Model İşlem Akışı — Matematiksel Formülasyon:

- ROI Ekstraksiyonu: $F^{eye_t} = f_{ROI}(F_t)$ (Eq.15)
- CNN (MesoNet4) Uzamsal Özellikler: $S_t = CNN(F^{eye_t})$ (Eq.16)
- Transformer Temporal Dikkat: $H_t = Transformer(S_t)$ (Eq.17)
- Sınıflandırma: $y = Classifier(H_t)$ (Eq.18)

MesoNet4 Detayları:

- Kernel boyutu: 3×3, stride: 1 — ince göz bölgesi özelliklerini yakalamak için
- Hafif mimari: Hesaplama maliyetini azaltmak amacıyla tasarlanmıştır (Afchar et al., 2018)

Hibrit Model Hiperparametreleri

Parametre	Açıklama	Değer
Input Size	Göz bölgesi çözünürlüğü	128 × 128 piksel
Embedding Dim	Gömme boyutu (TimeSformer ile hizalı)	768
CNN Backbone	Uzamsal özellik çıkarıcı	MesoNet4
Kernel Size	CNN konvolüsyon çekirdeği	3 × 3
Stride	CNN katman adımı	1
Transformer Layers	Temporal dikkat katmanları	4
Attention Heads	Çok başlı dikkat sayısı	4
Dropout Rate	Regularizasyon	0.2
Optimizer	Eğitim optimizörü	Adam
Learning Rate	Başlangıç öğrenme oranı	1×10^{-3}
Epochs	Eğitim iterasyonu	50
Batch Size	Eğitim batch boyutu	32

4.3 Kayıp Fonksiyonu

Sınıflandırma görevi için Cross-Entropy (Çapraz Entropi) kayıp fonksiyonu kullanılmıştır. Ek olarak, gaze ve blink hatalarını ele alan yardımcı Temporal Tutarlılık Kaybı (auxiliary temporal consistency loss) da eğitim sürecine dahil edilmiştir.

5. Değerlendirme Metrikleri ve Matematiksel Formüller

- **Accuracy:** $Acc = (TP+TN)/(TP+TN+FP+FN)$ [Eq.19] — TP: doğru sahte, TN: doğru gerçek, FP: gerçeği sahte sanan, FN: sahteyi gerçek sanan
- **Precision:** $Precision = TP/(TP+FP)$ [Eq.20] — yanlış alarm (gerçek videoyu sahte sayan) oranını minimize etmek için kritik
- **Recall (Sensitivity):** $Recall = TP/(TP+FN)$ [Eq.21] — tüm sahte videoların tespit edilmesi; güvenlik uygulamaları için hayati önem
- **F1-Score:** $F1 = 2 \cdot (Precision \cdot Recall) / (Precision + Recall)$ [Eq.22]
- **Gaze Direction Error (GDE):** $GDE = (1/N) \cdot \sum_i ||g^{true}_i - g^{pred}_i||$ [Eq.23] — tahmin edilen ve gerçek bakış vektörleri arasındaki fark; derece (°) cinsinden. Düşük GDE = gaze tutarsızlıklarını daha iyi yakalama.
- **Blink Detection Accuracy (BDA):** $BDA = \text{Doğru Göz Kırpma Tespiti} / \text{Toplam Göz Kırpma (Ground Truth)}$ [Eq.24] — temporal blink özelliklerine duyarlılık ölçütü.
- **FPS (Frames Per Second / Çıkarım Hızı):** $FPS = \text{Toplam İşlenen Kare} / \text{Toplam İşlem Süresi}$ [Eq.25] — gerçek zamanlı uygulanabilirliğin pratik ölçütü. Yüksek FPS $\equiv$ düşük gecikme.

6. Sonuçlar ve Değerlendirme

6.1 TimeSformer Performans Tablosu

Veri Seti	Acc (%)	Prec (%)	Recall (%)	F1 (%)	GDE (°)	BDA (%)	FPS
FaceForensics	97.5	97.8	97.2	97.4	1.5°	90.8	30
CelebDF-V2	96.3	96.5	96.1	96.3	1.8°	89.3	28
DFDC	95.8	95.9	95.6	95.7	2.1°	88.5	27
FakeAVCeleb	97.1	97.3	97.0	97.2	1.6°	91.0	29

6.2 Hibrit Transformer-CNN Performans Tablosu

Veri Seti	Acc (%)	Prec (%)	Recall (%)	F1 (%)	GDE (°)	BDA (%)	FPS
FaceForensics	92.8	93.5	92.2	92.9	3.0°	85.2	24
CelebDF-V2	91.5	92.1	91.0	91.8	3.4°	83.7	23
DFDC	90.9	91.7	90.5	91.2	3.6°	82.9	21
FakeAVCeleb	93.2	94.0	93.0	93.5	3.2°	86.3	22

6.3 Cross-Dataset Değerlendirme — TimeSformer

FaceForensics üzerinde eğitilen TimeSformer'in diğer veri setlerindeki cross-dataset performansı:

Test Veri Seti	Acc (%)	F1 (%)	GDE (°)	BDA (%)
FaceForensics (Intra)	97.5	97.4	1.5°	90.8
CelebDF-V2 (Cross)	95.6	95.5	1.7°	88.5
DFDC (Cross)	94.8	94.7	1.8°	87.2
FakeAVCeleb (Cross)	95.2	95.1	1.6°	88.0

FakeAVCeleb üzerinde eğitilen TimeSformer'in cross-dataset performansı:

Test Veri Seti	Acc (%)	F1 (%)	GDE (°)	BDA (%)
FaceForensics (Cross)	94.7	94.6	1.5°	87.5
CelebDF-V2 (Cross)	94.0	94.0	1.4°	86.8

DFDC (Cross)	94.1	94.1	1.4°	86.5
FakeAVCeleb (Intra)	97.1	97.2	1.6°	91.0

6.4 SOTA Karşılaştırması (FaceForensics ve DFDC)

Referans Model /	FF++ Acc (%)	FF++ F1 (%)	DFDC Acc (%)	CelebDF Acc (%)	FakeAVCeleb Acc (%)
[75] Xception (Full)	74.55	71.93	61.24	52.80	N/A
[75] Xception (Face)	94.92	93.95	85.50	71.60	N/A
[35] MesoNet	87.27	84.50	74.46	54.80	N/A
[77] EfficientNet-b5	90.94	87.22	80.78	73.64	N/A
[53] CViT	93.00	89.97	87.25	73.85	N/A
[55] ISTVT	—	—	—	—	N/A
[81] 3D ResNet	91.82	88.25	87.49	68.17	N/A
[82] RECCE	92.17	90.94	88.35	72.48	N/A
[86] HcIT	96.00	93.86	89.73	76.03	N/A
Önerilen TimeSformer	97.5	97.4	95.8	96.3	97.1
Önerilen Hibrit Trans-CNN	92.8	92.9	90.9	91.5	93.2

6.5 Temel Sayısal Bulgular ve Teknik Yorumlar

- **En Yüksek Doğruluk:** TimeSformer — FaceForensics: %97.5, FakeAVCeleb: %97.1. Tüm veri setlerinde %95 üzerinde doğruluk sağlanmıştır.
- **GDE Avantajı:** TimeSformer, FaceForensics'te GDE=1.5°; Hibrit model GDE=3.0°. TimeSformer gaze tutarsızlıklarını 2 kat daha iyi yakalamaktadır.
- **BDA Avantajı:** TimeSformer, FakeAVCeleb'de BDA=%91.0; Hibrit model BDA=%86.3. Blink tespitinde %5.6 üstünlük.
- **Gerçek Zamanlılık:** TimeSformer: 27–30 FPS; Hibrit model: 21–24 FPS. TimeSformer, gerçek zamanlı dağıtım için belirgin avantaj sağlamaktadır.
- **TimeSformer vs. Hibrit Farkı (FaceForensics):** %4.7 doğruluk artışı, %4.6 F1 artışı, GDE yarıya indi (3.0°→1.5°), BDA %5.6 iyileşme, FPS 24→30.
- **Cross-Dataset Genelleştirme:** FaceForensics üzerinde eğitilen TimeSformer, CelebDF-V2'de %95.6, DFDC'de %94.8 doğruluk ile güçlü cross-dataset performansı sergilemiştir. Bu, mevcut literatürdeki en yüksek cross-dataset genelleme değerlerinden biridir.
- **SOTA Karşılaştırma:** TimeSformer, önceki en iyi olan HcIT (%96.0)'ı FaceForensics'te %1.5 oranında, CelebDF-V2'de %20.3 oranında geçmektedir (%96.3 vs %76.03). DFDC'de de %95.8 ile %89.73 (HcIT)'i önemli ölçüde aşmaktadır.
- **Confusion Matrix Değerleri:** FaceForensics TimeSformer: [TP=930, FN=20, FP=25, TN=1025]. FaceForensics Hibrit: [TP=880, FN=70, FP=65, TN=985].

7. Literatüre Katkıları ve Kısıtlar

7.1 Özgün Katkıları

- **Göz Bölgesi Odaklı TimeSformer:** TimeSformer'ın gaze ve blink anomali tespitine uyarlanması; ROI ekstraksiyonu, Gaussian temporal düzeltme ve özel augmentation ile yeni bir ön işleme pipeline'ı.

- **Dual Dikkat Mekanizması:** Uzamsal dikkat (kare içi göz bölgesi özellikleri) + temporal dikkat (kare-arası blink/gaze dinamikleri) birlikte modellenerek deepfake manipölasyonları daha kapsamlı analiz edilmektedir.
- **GDE ve BDA Metrikleri:** Standart ACC/F1/AUC metriklerine ek olarak domain-spesifik GDE ve BDA metrikleri kullanılarak göz hareketine özgü tespit kalitesi ölçülmüştür.
- **Kapsamlı Cross-Dataset Değerlendirme:** 4 farklı eğitim senaryosu × 4 test veri seti (Tablolar 8–11) ile kapsamlı intra ve cross-dataset analizi yapılmıştır.
- **Multimodal Veri Kümesi:** FakeAVCeleb dahil edilerek ses-video multimodal deepfake'lerin görsel bileşenine karşı model performansı değerlendirilmiştir.
- **Gerçek Zamanlı Çıkarım Ölçümü:** FPS değerleri makalede raporlanmış; TimeSformer'ın 27–30 FPS ile gerçek zamanlı uygulanabilirliği kanıtlanmıştır.

7.2 Kısıtlar ve Dezavantajlar

- **Etiketli Veri Bağımlılığı:** Model etiketli veri setlerine dayanmaktadır; bu durum denetimsiz/yarı-denetimli yaklaşımların sunduğu avantajlardan yoksun kalmaya yol açmaktadır.
- **Dinamik/Engellenmiş Video Senaryoları:** Yüksek hareket veya yüz örtme (occlusion) içeren video senaryolarında çerçevenin performansı yeterince araştırılmamıştır.
- **Yalnızca Görsel Modalite:** FakeAVCeleb ses-video multimodal bir veri seti olmasına karşın model yalnızca görsel analiz yapmaktadır; ses tabanlı deepfake tespiti kapsam dışıdır.
- **Gelişen Deepfake Teknikleri:** Gelişmiş üretim modelleri gerçekçi göz kırpma ve bakış hareketleri üretebilmektedir (örn. Vougioukas et al., 2020; Pham et al., 2018). Bu tür gelişmeler göz kırpma tabanlı tespit yöntemlerinin etkinliğini azaltabilir.
- **Tek Yüz Senaryosu:** Birden fazla kişi içeren video karelerinde her kimliğin bağımsız olarak ele alınması gerekli ancak yöntem bunu nasıl ele aldığını yeterince detaylandırmamaktadır.
- **Eğitim Donanımı Belirtilmemiş:** Eğitim altyapısı (GPU modeli, RAM, işlemci) makalede belirtilmemiştir; sonuçların yeniden üretilmesi zorlaşmaktadır.
- **Ses Füzyonu Yok:** FakeAVCeleb ses bileşeni değerlendirmeye alınmamıştır; tam multimodal bir analiz yapılmamıştır.

8. Mimari ve Görsel Analizi

Temel olanlar:

- **Öneri Çerçeve Akış Diyagramı:** Veri seti seçimi → ROI ekstraksiyonu → normalizasyon/boyutlandırma → temporal düzleştirme → TimeSformer / Hibrit model → değerlendirme boru hattını gösterir.
- **Ön İşleme Aşamaları:** (A) Dlib ile yüz landmark tespiti; (B) iki özne için ROI kırpma örneği; (C) Gaussian temporal düzleştirme görselleştirmesi ($\exp(-\tau^2/2\sigma^2)$ ağırlıklama).
- **TimeSformer Mimarisi:** Esnek (flexible) TimeSformer modelinin tam katman yapısı: Video patch bölümlenme → konum gömme → çift dikkat (uzamsal + temporal) → sınıflandırma başı.
- **Hibrit Transformer-CNN Mimarisi:** MesoNet4 uzamsal özellik çıkarımı + ara birleştirme katmanı + transformer temporal modelleme.
- **TimeSformer Karışıklık Matrisleri:** 4 veri seti için TP, TN, FP, FN değerleri. FaceForensics: [930, 20, 25, 1025] en düşük hata oranı.

- **Hibrit Model Karışıklık Matrisleri:** 4 veri seti için FP ve FN değerleri TimeSformer'a kıyasla daha yüksek.
- **Öğrenme Eğrileri:** Her veri seti için eğitim/doğrulama kaybı ve skor eğrileri; modellerin overfitting/underfitting durumu görselleştirilmiştir.

9. AISC Perspektifi: Bu Çalışma Üzerine Ne Yapılabilir?

9.1 Doğrudan Uygulanabilir Teknikler

- **TimeSformer'ı AISC'e Entegre Etme:** TimeSformer, AISC projesindeki mevcut kare-düzeyi analiz sisteminin yerini alabilir. ROI tabanlı önileme pipeline'ı (Dlib + bounding box + Gaussian smoothing) doğrudan mevcut sisteme eklenebilir.
- **GDE ve BDA Metriklerini Benimse:** AISC, standart metriklere (Acc, F1, AUC) ek olarak GDE ve BDA'yı da raporlayarak daha kapsamlı ve özgün bir değerlendirme sunabilir.
- **Gaussian Temporal Düzleştirme:** Ön işleme adımına Gaussian filtre eklenmesi, gürültülü gaze ve blink verilerini temizleyerek modelin öğrenme kalitesini artırabilir.

9.2 Tespit Edilen Boşluklar — AISC Açısından Fırsatlar

- **Ses + Video Füzyonu:** Makale FakeAVCeleb'i kullanmış; ancak yalnızca görsel analiz yapmıştır. AISC, göz bölgesi (TimeSformer) + ses bileşeni (HuBERT, SENet) füzyonu ile gerçek anlamda multimodal bir deepfake detektörü geliştirebilir.
- **Yeni Nesil Deepfake'e Dayanıklılık:** Gerçekçi göz kırpma üreten modeller (GAN tabanlı) göz kırpma analizini aşabilir. AISC, sadece blink değil yüz yüzeyi tutarlılığı, frekans alanı analizi veya derinlik tahmini ile hibrit bir sağlamlık katmanı ekleyebilir.
- **Hafif Mimari Keşfi:** TimeSformer'ın 12 katman / 768 boyutlu gömme yapısı ağır olabilir. AISC, daha az katman ile MobileViT veya EfficientFormer tabanlı hafif varyantları deneyerek mobil/gömülü sistemlere uygun bir sürüm geliştirebilir.
- **Dinamik/Oklude Senaryo Testi:** Makale bu senaryoları test etmemiştir. AISC, yüzün kısmen örtülü olduğu, hızlı hareket içeren veya düşük aydınlatmalı videolarda test yaparak gerçek dünya sağlamlığını ölçebilir.
- **Veri Setleri Arası Robustness Analizi:** Her veri seti için dört eğitim-test senaryosu zaten test edilmiştir. AISC, DeeperForensics-1.0, DFFD veya WildDeepfake gibi daha zorlu veri setlerini ekleyerek genellenebilirlik testini genişletebilir.

== BÖLÜM 2 : TABLO AKTARIM BLOĞU (Google Sheets) ==

Başlık	Değer
Sorumlu Kişi	Kader Terik
Atıf No	Makalede belirtilmemiş
Makale Türü	Özgün Araştırma (Original Research) — Open Access, CC BY 4.0
Makale Adı	Real-Time Deepfake Detection via Gaze and Blink Patterns: A Transformer Framework
Yıl	2025
Yazarlar	Muhammad Javed; Zhaohui Zhang; Fida Hussain Dahri; Asif Ali Laghari; Martin Krajčák; Ahmad Almadhor
Yayınlandığı Dergi-Konferans	Computers, Materials & Continua (CMC) — Vol.85, No.1, s.1457–1493 — Tech Science Press

DOI-Link	10.32604/cmc.2025.062954 https://doi.org/10.32604/cmc.2025.062954
Kaynakça Bilgisi (APA)	Javed, M., Zhang, Z., Dahri, F. H., Laghari, A. A., Krajčık, M., & Almadhor, A. (2025). Real-time deepfake detection via gaze and blink patterns: A transformer framework. Computers, Materials & Continua, 85(1), 1457–1493. https://doi.org/10.32604/cmc.2025.062954
Kullanılan Veri Seti	FaceForensics++ CelebDF-V2 DFDC FakeAVCeleb (4 benchmark veri seti)
Dataset Kaynağı-Linki	FF++: https://paperswithcode.com/dataset/faceforensics-1 CelebDF-V2: https://paperswithcode.com/dataset/celeb-df DFDC: https://paperswithcode.com/dataset/dfdc FakeAVCeleb: https://github.com/DASH-Lab/FakeAVCeleb
Veri Seti Detayı	FaceForensics++ — 4 manipülasyon yöntemi (DeepFakes, Face2Face, FaceSwap, NeuralTextures); CelebDF-V2 — yüksek kalite sahte, 59 ünlü kimliği; DFDC — büyük ölçek, çeşitli demografi; FakeAVCeleb — ses-video multimodal deepfake. RGB modalitesi, video tabanlı.
Dataset Boyutu	FF++ & FakeAVCeleb: Train 47.808R+47.808F, Val 5.360R+5.360F, Test 2.000R+2.000F. CelebDF-V2 & DFDC: Train 50.000R+50.000F, Val 10.000R+10.000F, Test 1.000R+1.000F (veya 2.000R+2.000F).
Train-Test-Validation Ayrımı	Kesin oranlar Tablo 1'de verilmiştir. Tüm veri setleri Train/Validation/Test olarak üç parçaya bölünmüştür.
Kullanılan Model-Yöntem	Ana Model: TimeSformer (spatio-temporal attention, göz bölgesi odaklı). Baseline: Hibrit Transformer-CNN (MesoNet4 + hafif Transformer modülü).
Model Mimari Detayı	TimeSformer: Input 128×128, Patch 16×16, Seq.len=32, Embed=768, 12 katman, 8 attention head, Dropout=0.1, AdamW, LR=3e-4, 50 epoch. Hibrit: MesoNet4 CNN backbone (kernel 3×3, stride 1), Embed=768, 4 transformer katman, 4 head, Dropout=0.2, Adam, LR=1e-3, 50 epoch, Batch=32. Kayıp: Cross-Entropy + yardımcı temporal tutarlılık kaybı.
Çalışmanın Amacı	Gaze ve blink anomali analizi ile gerçek zamanlı deepfake video tespiti için TimeSformer tabanlı özgün bir çerçeve geliştirmek. Lokalize göz bölgesi analizine odaklanarak global özellik bağımlılığını ve hesaplama verimsizliğini aşmak.
Ölçüm Metrikleri	Accuracy, Precision, Recall, F1-Score, GDE (Gaze Direction Error — derece °), BDA (Blink Detection Accuracy — %), FPS (Frames Per Second), Confusion Matrix.
Veri Ön İşleme Adımları	1) ROI ekstraksiyonu — Dlib landmark tespiti + bounding box kırpma 2) Normalizasyon [0,1] + biküçük interpolasyon ile (H,W) boyutlandırma 3) Gaussian temporal düzleştirme (pencere 2K+1, σ kontrolü) 4) Augmentation: ROI shifting ($\Delta x, \Delta y$), kırpma+ölçekleme, parlaklık ayarı (α, β)
Data Augmentation Kullanıldı mı?	Evet. ROI shifting, frame cropping ve ROI scaling kullanılmıştır.
Çalışmanın Sonuçları	TimeSformer — FF: %97.5 Acc, %97.4 F1, GDE=1.5°, BDA=90.8, 30FPS; CelebDF-V2: %96.3 Acc; DFDC: %95.8 Acc; FakeAVCeleb: %97.1 Acc. Hibrit — FF: %92.8 Acc, GDE=3.0°, BDA=85.2, 24FPS; DFDC: %90.9 Acc (en zayıf); FakeAVCeleb: %93.2 Acc (en güçlü). Cross-dataset: FF eğitilmiş TimeSformer → CelebDF-V2 %95.6, DFDC %94.8.
Kıyaslanan Modeller	Xception (Full) %74.55, Xception (Face) %94.92, MesoNet %87.27, EfficientNet-b5 %90.94, InceptionResV1 %79.51, Conv-LSTM %52.38, CViT %93.00, DSP-FWA %89.57, 3D ResNet %91.82, RECCE %92.17, RFM %90.81, DCL %92.17, FedForgery %91.38, HcIT %96.00. TimeSformer tüm SOTA modelleri geçmiştir.
Review Makale İse İncelediği Yöntemler	İlgili değil — Özgün araştırma makalesidir.
Kullanılan Görseller-Grafikler	Şekil 1: Çerçeve akış diyagramı; Şekil 2-5: Veri seti örnekleri (FF++, CelebDF-V2, DFDC, FakeAVCeleb); Şekil 6: ROI ekstraksiyonu ve temporal düzleştirme; Şekil 7: TimeSformer mimarisi; Şekil 8: Hibrit Transformer-CNN mimarisi; Şekil 9: TimeSformer performans grafikleri; Şekil 10: TimeSformer CM'leri (4 veri seti); Şekil 11: Hibrit model grafikleri; Şekil 12: Hibrit CM'ler; Şekil 13: Karşılaştırma grafikleri; Şekil 14-17: Cross-dataset değerlendirme; Şekil 18-21: Öğrenme eğrileri.

Getirdiđi Yenilikler-Novelty	TimeSformer'ın deepfake göz bölgesi analizine ilk uyarlanması. GDE ve BDA domain-spesifik metrikleri. ROI+Gaussian temporal düzleştirme + augmentation içeren özgün ön işleme pipeline'ı. 4 veri setinde kapsamlı intra+cross-dataset değerlendirme. 27-30 FPS gerçek zamanlı çıkarım performansı ölçümü.
Dezavantajlar-Kısıtlar	Etiketli veri bağımlılığı; dinamik/oklude senaryo testi yapılmamış; yalnızca görsel modalite (ses füzyonu yok); gelişen deepfake teknikleri göz kırpmaya bazlı tespiti aşabilir; eğitim donanımı belirtilmemiş; kısmi yüz senaryoları analiz edilmemiş.
Projeye Katkısı-Bizim İçin Önemi	TimeSformer + göz bölgesi analizi model'e doğrudan entegre edilebilir. GDE ve BDA metrikleri raporlaması özgün değer katabilir. Cross-dataset genelleme sonuçları (>%94) Modelin hedef performansı için referans sunuyor. Ses füzyonu eksikliği model için multimodal geliştirme fırsatı.
Kod-GitHub Linki	Makalede belirtilmemiştir. Veri setleri açık erişimlidir (PapersWithCode ve GitHub).
Durum	İncelendi
Notlar	37 sayfalık özgün araştırma makalesi — CMC (Computers, Materials & Continua), Vol.85 No.1 2025. Geliş: 31.12.2024 / Kabul: 06.06.2025 / Yayın: 29.08.2025. Finansman alınmamıştır. Ç.İ. çakışması yok. TimeSformer: Facebook AI Research (Bertasius et al., 2021). MesoNet4: Afchar et al. (2018). 85 atıf içermektedir.