

MAKALE ANALİZ RAPORU

Sorumlu Kişi	Kader Terik
Araştırma Grubu	Deepfake Detection — AISC
Makale Türü	Özgün Araştırma (Original Research)

Makale Bilgileri

Makale Adı: Regression and Classification Approaches to Eye Localization in Face Images

Yazarlar: Mark Everingham, Andrew Zisserman

Kurumlar: Department of Engineering Science, University of Oxford

Yayınlandığı Dergi-Konferans: 7th International Conference on Automatic Face and Gesture Recognition (FGR'06)

Cilt / Yıl / DOI: Yıl: 2006 | DOI: 10.1109/FGR.2006.77

Anahtar Kelimeler: Eye localization, Face detection, Kernel Ridge Regression, Bayesian modeling, AdaBoost

Kaynakça (APA): Everingham, M., & Zisserman, A. (2006). *Regression and Classification Approaches to Eye Localization in Face Images*. In *Proceedings of the 7th International Conference on Automatic Face and Gesture Recognition (FGR'06)* (pp. 53-58). IEEE.

== BÖLÜM 1 : ANLATI RAPORU ==

1. Çalışmanın Amacı

Yüz dedektörü (örn. Viola-Jones) tarafından çıkarılan gri tonlamalı yüz görüntülerinde gözleri doğru bir şekilde lokalize etmektir. Kötü lokalizasyon, yüz tanıma doğruluğunu ciddi şekilde bozmaktadır. Bu çalışma; Regresyon, Bayesian Sınıflandırma ve Ayırt Edici (Discriminative/AdaBoost) Sınıflandırma olmak üzere üç farklı yaklaşımı, aynı eğitim ve test verileri üzerinde tarafsız bir şekilde karşılaştırmayı amaçlamaktadır.

2. Problem Tanımı ve Literatür Bağlamı

Yüz hizalamada 'göz konumu' kilit bir noktadır. Literatürde pek çok farklı algoritma önerilmiştir ancak algoritmaların veri setleri, eğitim süreçleri ve test protokolleri farklı olduğu için hangisinin daha başarılı olduğunu belirlemek oldukça zordur. Genellikle Discriminative (AdaBoost) gibi gelişmiş yöntemlerin daha iyi olduğu varsayılır, bu çalışma bunu sorgulamaktadır.

3. Kullanılan Veri Seti

- **FERET Veritabanı:** 3,337 adet önden çekilmiş, yüksek çözünürlüklü, kapalı alan ve iyi aydınlatılmış (kontrollü) yüz fotoğrafları.
- **WWW Veritabanı:** İnternette toplanan 10,118 adet zorlu görüntü. Çözünürlük, ışık ve poz (out-of-plane rotation) son derece değişkendir. Her iki veri setinden de test için 1000'er adet görüntü rastgele ayrılmıştır.

4. Kullanılan Yöntem / Model

Tüm görüntüler standart olarak Viola-Jones ile bulunup 100x100 piksele normalize edildikten sonra 3 farklı yöntem test edilmiştir:

4.1 Regresyon Yaklaşımı

Gerçek ve tahmin edilen göz pozisyonları arasındaki Öklid mesafesini doğrudan minimize etmeye çalışır. Kernel Ridge Regresyonu ve RBF (Radial Basis Function) kullanılmıştır.

4.2 Bayesian Sınıflandırma Yaklaşımı

Göz (eye) ve göz olmayan (non-eye) bölge görünümelerini Bağımsız Gauss Dağılımları ile modeller. Görüntüdeki yamalar (patches) üzerinde Log-likelihood oranı hesaplanır. Kovaryans matrisi aşırı uyumu (overfitting) önlemek için düzenlenmiştir (regularization).

4.3 Discriminative Sınıflandırma Yaklaşımı

Göz ve göz olmayan bölgeleri ayırt etmek için AdaBoost algoritması ve Haar-like (Haar-benzeri) özellikleri kullanarak bir 'Güçlü Sınıflandırıcı' (Strong Classifier) eğitilmiştir.

5. Sonuçlar ve Değerlendirme

- Beklenenin aksine, basit Bayesian yaklaşımı her iki veri setinde de (FERET ve WWW) en iyi performansı göstermiştir.
- FERET testinde görüntülerin %90'ında göz, 2.04 piksel hata payı (inter-ocular mesafenin %4.7'si) içinde bulunmuştur.
- Zorlu WWW veritabanında Bayesian yöntemi, regresyon (3.29 piksel) ve Discriminative (3.77 piksel) yöntemlere kıyasla 2.74 piksellik (90% quantile) daha düşük bir hata payı elde etmiştir.
- İlginç bir bulgu: İnsanların (etiketleyicilerin) karmaşık/bulanık web görüntülerinde yaptığı işaretleme hatalarıyla Bayesian yöntemin doğruluğu yarışmıştır (hatta yöntemin yer yer daha kararlı olduğu görülmüştür).

6. Literatüre Katkıları ve Kısıtlar

- **Özgün Katkıları:** Kompleks sınırlara sahip AdaBoost/Discriminative yöntemlerin eğitim verilerindeki ufak lokalizasyon hatalarına (ground truth noise) karşı çok hassas olduğunu, oysa üretken (generative) basit Bayesian modelin bu tarz gürültüleri absorbe ederek daha tutarlı (robust) lokalizasyon sağladığını ispatlamıştır.
- **Kısıtlar (Sınırlılıklar):** Gözlük parlaması, saçın gözü kapatması veya çok uç düzey aydınlatma hataları (extreme lighting) gibi durumlarda lokalizasyon hala başarısız olmaktadır.

7. AISC Perspektifi: Bu Çalışma Üzerine Ne Yapılabilir?

- **Basit Modellerin Sağlamlığı (Robustness of Generative Models):** Deepfake tespit sistemlerinde internetten indirilen düşük çözünürlüklü ve gürültülü (WWW tarzı) videolardaki göz/yüz bölgelerini çıkarırken karmaşık yöntemler (örn. YOLO veya ağır landmark dedektörleri) frame-frame titremeler (jitter) yapabilir. Klasik bir Bayesian olasılıksal yaklaşımın kırpma (cropping) stabilizasyonunu artırabileceği görülmektedir. Bu durum, temporal (zamansal) deepfake kırpma stratejileri geliştirirken olasılıksal bir düzleştirme (smoothing) fonksiyonu kullanmamız konusunda ilham vermektedir.

== BÖLÜM 2 : TABLO AKTARIM BLOĞU (Google Sheets) ==

Başlık	Değer
Sorumlu Kişi	Kader Terik
Atıf No	Makalede Belirtilmemiştir
Makale Türü	Özgün Araştırma (Original Research)
Makale Adı	Regression and Classification Approaches to Eye Localization in Face Images
Yıl	2006
Yazarlar	Mark Everingham, Andrew Zisserman
Yayınlandığı Dergi-Konferans	7th International Conference on Automatic Face and Gesture Recognition (FGR'06) / IEEE
DOI-Link	10.1109/FGR.2006.77
Kaynakça Bilgisi (APA)	Everingham, M., & Zisserman, A. (2006). Regression and Classification Approaches to Eye Localization in Face Images. In Proceedings of the 7th International Conference on Automatic Face and Gesture Recognition (FGR'06). IEEE.
Kullanılan Veri Seti	FERET, WWW
Dataset Kaynağı-Linki	FERET (Açık Veritabanı), WWW (Yazarların Kendi Derlemesi)
Veri Seti Detayı	FERET: 3,337 kaliteli iç mekan resmi. WWW: İnternette toplanmış, poz, aydınlatma ve çözünürlük açısından aşırı değişken 10,118 resim.
Dataset Boyutu	Toplam ~13,450 resim. (Her setten test için rastgele 1000'er adet ayrılmıştır.)
Train-Test-Validation Ayrımı	Her veritabanı için: 1000 resim test, kalanlardan yarısı eğitim (train), yarısı validasyon (validation) için parametre ayarı (grid search) amaçlı kullanılmıştır.
Kullanılan Model-Yöntem	3 Farklı Yöntem Karşılaştırması: 1. Kernel Ridge Regresyonu. 2. Bayesian (Generative) Sınıflandırıcı. 3. Discriminative (AdaBoost) Sınıflandırıcı.
Model Mimari Detayı	Regresyon: RBF Kernel ile x,y minimizasyonu. Bayesian: Göz ve göz olmayan parçalar için Gauss dağılımları (Log-likelihood oranı). AdaBoost: Haar-like feature'lar ile Strong Classifier.
Çalışmanın Amacı	Ortak eğitim/test verileri kullanarak Regresyon, Üretken (Bayesian) ve Ayırt Edici (AdaBoost) modellerden hangisinin göz lokalizasyonunda en iyi performansı gösterdiğini tarafsızca belirlemek.
Ölçüm Metrikleri	Euclidean Distance (Öklid Mesafesi - Piksel bazında ve Inter-ocular mesafeye normalize edilmiş oran)
Veri Ön İşleme Adımları	Viola-Jones ile yüz tespiti. Bulunan Bounding Box'ın 100x100 piksele standardize edilmesi (Scale normalization). Görüntü parçalarının (patch) normalize edilmesi.
Data Augmentation Kullanıldı mı?	Açıkça data augmentation yapılmamış ancak Bayesian modelde 'Kovaryans Düzenleme' (Regularization) yapılmış (bu da modele sanal Gauss gürültüsü eklemekle eşdeğerdir).
Çalışmanın Sonuçları	En karmaşık modelin değil, basit Bayesian modelin iki veri setinde de (kaliteli ve kalitesiz) en düşük ortalama hatayı (FERET: 1.18px, WWW: 1.73px ortalama hata) verdiği kanıtlanmıştır.
Kıyaslanan Modeller	Kendi aralarında 3 model + O dönemki State-of-the-art yöntem olan Wang & Ji (AdaBoost tabanlı).

Review Makale İse İncelediği Yöntemler	İlgili Değil
Kullanılan Görseller-Grafikler	Hata dağılım grafikleri (Şekil 4). İyi/kötü lokalizasyon tespit örnekleri (Şekil 5). Pozitif/Negatif eğitim patchlerinin dağılımı (Şekil 3).
Getirdiği Yenilikler-Novelty	Gelişmiş 'Discriminative' sınıflandırıcıların ground truth (etiketleme) gürültülerine karşı dayanıksız olduğunu gösterip, basit üretken modellerin stabilitesini vurgulaması.
Dezavantajlar-Kısıtlar	Saç, kalın gözlük çerçeveleri veya kaşların göze çok yakın olması durumlarında lokalizasyon algoritması istikrarlı çalışmamakta, 'kaşı' göz zannedebilmektedir.
Projeye Katkısı-Bizim İçin Önemi	Model eğitiminde (Deepfake Tespiti), yüksek gürültülü (compressed) videolarda ROI'yi çıkarırken 'bayesian smoothing' veya üretken yaklaşımlar kullanarak kırpma stabilizasyonu sağlamak için mantıksal temel sağlar.
Kod-GitHub Linki	Belirtilmemiş.
Durum	İncelendi
Notlar	Çok eski (2006) bir makale olmasına rağmen, makine öğrenmesi modellerindeki 'Aşırı karmaşıklık her zaman iyidir' algısını kırması açısından pedagojik bir değeri vardır.