

MAKALE ANALİZ RAPORU

Sorumlu Kişi	Kader Terik
Araştırma Grubu	Deepfake Detection — AISC
Makale Türü	Özgün Araştırma (Original Research)

Makale Bilgileri

Makale Adı: VLForgery Face Triad: Detection, Localization and Attribution via Multimodal Large Language Models

Yazarlar: Xinan He, Yue Zhou, Bing Fan, Bin Li, Guopu Zhu, Feng Ding

Kurumlar: Nanchang University, Shenzhen University, University of North Texas, Harbin Institute of Technology

Yayınlandığı Dergi-Konferans: 39th Conference on Neural Information Processing Systems (NeurIPS)

Cilt / Yıl / DOI: Yıl: 2025 | DOI: Belirtilmemiş

Anahtar Kelimeler: Deepfake detection, Multimodal Large Language Models (MLLMs), Forgery localization, Attribution, Diffusion Models, VLForgery

Kaynakça (APA): He, X., Zhou, Y., Fan, B., Li, B., Zhu, G., & Ding, F. (2025). VLForgery Face Triad: Detection, Localization and Attribution via Multimodal Large Language Models. 39th Conference on Neural Information Processing Systems (NeurIPS 2025).

== BÖLÜM 1 : ANLATI RAPORU ==

1. Çalışmanın Amacı

Difüzyon Modelleri (Diffusion Models - DM) tarafından üretilen son derece gerçekçi sahte (fake) görüntülerin tespitinde, çoğu dedektörün yalnızca 1/0 şeklinde ikili kararlar verebildiği gerçeğinden yola çıkarak; Multi-Modal Büyük Dil Modelleri (MLLMs) kullanarak sahteliği 'tespit eden', üzerinde oynanmış bölgeyi 'lokalize eden' ve sahteliğin hangi jeneratörden (örn. SDXL) geldiğini 'ilişkilendiren' (attribution) üçlü bir framework (VLForgery) geliştirmektedir.

2. Problem Tanımı ve Literatür Bağlamı

Geleneksel derin sahte (deepfake) dedektörleri, yüksek kaliteli DM çıktılarına karşı zayıf kalmaktadır. Ayrıca, VQA (Görsel Soru Cevaplama) tarzında çalışan MLLM'ler, sahteliğe ilgili 'halüsinasyonlar' görebilmektedir çünkü ince taneli (fine-grained) adli özelliklerde eğitimleri zayıftır. Lokalizasyon ve Atıf (Attribution) ise çoğu modelde ya desteklenmez ya da ayrı ağlar gerektirir.

3. Kullanılan Veri Seti

- **VLF (Visual Language Forensics) Veri Seti:** Bu çalışma için özel üretilmiş yeni bir multimodal veri setidir. Temiz yüzler: FFHQ, CelebA-HQ ve FF++'tan alınmıştır.
- **Kısmi Sentez (Partial Synthesis):** SDXL, SD2 ve Kandinsky2.2 kullanılarak sadece belirli yüz hatlarının (burun, kaş, saç) değiştirildiği veri havuzu.
- **Tam Sentez (Full Synthesis):** Tamamen sahte kimlikler veya farklı arkaplanlara aktarılmış yüzler içerir (Flux, InstantID, SD3 vb. destekli).

4. Kullanılan Yöntem / Model

VLForgery adlı üçlü analiz sistemi tasarlanmıştır. Bu sistem üç ana modülden oluşur:

4.1 Düşük Seviyeli Görüntü Karşılaştırma Boru Hattı (Low-level Vision Pipeline)

Gerçek ve sahte görüntü setleri arasındaki keskinlik, parlaklık, sıkıştırma hataları gibi düşük seviyeli farklar, bir görsel dil modeli (Llama-3.2-11B-Vision) yardımıyla metne dökülerek sistem için 'karar önyargıları' (judgment bias) oluşturulur.

4.2 EkCot (Extrinsic Knowledge-guided Chain-of-Thought)

Dil modelinin mantıksal bir sırayla düşünmesini sağlamak için harici bilgilerin (ör. promptlar, maske konumları) sisteme verildiği yeni bir zincirleme düşünme yöntemidir. MLLM'e halüsinasyon gördürmeden sırasıyla; Karar -> Lokalizasyon -> Kaynak Atfı yaptırır.

4.3 MLLM İnce Ayarı (Fine-Tuning LLaVa-1.5-7B)

Sistemin adli analiz görevlerine adapte olması için LoRA (Low-Rank Adaptation) tekniği ile ince ayar (fine-tuning) yapılır. Model, bir yüzü maske olarak değil, 'burun ve saç bölgeleri oynanmış' gibi doğal dilde tanımlamayı öğrenir.

5. Sonuçlar ve Değerlendirme

- **Tespit (Detection):** Klasik CNN'ler, frekans/spatial tabanlı adli yöntemler ve ince ayar görmemiş LLM'ler karşısında %90'ın üzerinde başarı sağlamıştır.
- **Lokalizasyon (Localization):** Geleneksel piksel maskesi veren yöntemlerden (örn. PSCC-Net) çok daha sağlamdır. Arkaplan parazitlerine takılmadan saç (%88.9) ve burun gibi küçük alanları tespit edebilmiştir.
- **Kaynak Atfı (Attribution):** Tam sentez görüntülerinin hangi modelden (SDXL, Flux vb.) geldiğini %91.7 oranında doğru bulmuştur. Ancak kısmi değiştirilmiş yüzlerdeki kaynak tespiti görece zordur (%70).

6. Literatüre Katkıları ve Kısıtları

- **Özgün Katkıları:** Deepfake tespitinde ikili (1/0) sonuçtan ziyade 'Açıklanabilir Yapay Zeka (XAI)' düzeyinde doğal dille cevap veren ve halüsinasyon oranını minimuma indiren uçtan uca bir sistem (VLForgery + EkCot) tasarlanmıştır.

- **Kısıtlar (Sınırlılıklar):** Model, sadece küçük bir yüzdesinde (kısmi sentez) oynanmış olan yüksek kaliteli deepfake'lerin üretim kaynağını (Attribution) bulmakta zorlanmaktadır. Farklı ve yeni Jeneratör mimarilerine karşı adaptasyon hızının geliştirilmesi gerekir.

7. AISC Perspektifi: Bu Çalışma Üzerine Ne Yapılabilir?

- **Açıklanabilir (Explainable) Deepfake Raporlama:** AISC grubumuzdaki mevcut analiz yazılımlarına/modellerine entegre edilebilecek harika bir konsepttir. Sadece 'Bu video sahte' demek yerine, üretilen bir MLLM katmanı (Llama tabanlı bir Vision modeli), adli bilişim (forensics) personeline veya son kullanıcıya 'Saç sınırlarında sıkıştırma hatası bulundu, difüzyon tabanlı kısmi manipülasyon şüphesi' gibi açıklayıcı metin raporları sunan modüller geliştirebiliriz. EkCot tekniği, prompt bazlı modeller için referans teşkil edebilir.

== BÖLÜM 2 : TABLO AKTARIM BLOĞU (Google Sheets) ==

Başlık	Değer
Sorumlu Kişi	Kader Terik
Atıf No	Makalede Belirtilmemiştir
Makale Türü	Özgün Araştırma (Original Research)
Makale Adı	VLForgery Face Triad: Detection, Localization and Attribution via Multimodal Large Language Models
Yıl	2025
Yazarlar	Xinan He, Yue Zhou, Bing Fan, Bin Li, Guopu Zhu, Feng Ding
Yayınlandığı Dergi-Konferans	39th Conference on Neural Information Processing Systems (NeurIPS)
DOI-Link	Belirtilmemiş
Kaynakça Bilgisi (APA)	He, X., Zhou, Y., Fan, B., Li, B., Zhu, G., & Ding, F. (2025). VLForgery Face Triad: Detection, Localization and Attribution via Multimodal Large Language Models. 39th Conference on Neural Information Processing Systems (NeurIPS).
Kullanılan Veri Seti	FFHQ, FF++, CelebA-HQ (Orijinaler) ve VLF (Yeni Üretilen Multimodal Veri Seti)
Dataset Kaynağı-Linki	VLF, Yazarlar tarafından bu çalışma için türetilmiş (SDXL, SD2, Kandinsky, Flux kullanılarak)
Veri Seti Detayı	Pristine: 72K, DM-based Partial: 228K, DM-based Full: ~152K görüntü. Toplam yaklaşık yarım milyonluk veri.
Dataset Boyutu	~450,000+ görüntü
Train-Test-Validation Ayrımı	Her bir alt küme (generator bazlı) eğitim ve test olarak 4:1 (train:test) oranında rastgele bölünmüştür.
Kullanılan Model-Yöntem	MLLM Tabanlı Adli Analiz: LLaVa-1.5-7B, LoRA İnce Ayarı, EkCot (Extrinsic Knowledge-guided Chain-of-Thought), Llama-3.2-11B-Vision ile Düşük Seviyeli Adli Feature Tespiti.
Model Mimari Detayı	Visual Encoder (CLIP) -> Adapter -> LLM (LoRA). Model, görselle birlikte EkCot şablonunu (Prompt+Low Level Bias) alarak Doğal Dilde Tespit, Lokalizasyon ve Atıf (Generator tahmini) sonuçları üretir.
Çalışmanın Amacı	İkili tespit yapan derin öğrenme dedektörlerini aşarak, MLLM'ler ile sahteliği tespit etmek, oynanmış bölgeyi sözel olarak işaretlemek ve sahteliğin hangi generatörden geldiğini tahmin etmek.
Ölçüm Metrikleri	Accuracy (Doğruluk)
Veri Ön İşleme Adımları	Maske üretimi (CelebA-HQ maskelerinden faydalanılarak), GPT-4o ile prompt ve sözlük (dictionary) üretimi, inpainting ile kısmi sahte üretimi.
Data Augmentation Kullanıldı mı?	Sentetik veri üretiminin kendisi bir tür data augmentation'dır. Farklı prompt kombinasyonları ve maskeler rastgele birleştirilerek devasa sentetik veri üretilmiştir.
Çalışmanın Sonuçları	Tam (Full) sentezde tespit oranları %99'un üzerinde. Kısmi (Partial) sentezlerde genelleme yeteneği diğer tüm dedektörlerden

	(CNN, Frequency, Spatial) açık ara daha yüksektir. Atıf doğruluğu %91+ seviyelerindedir.
Kıyaslanan Modeller	Naive CNNs (ResNet-50, Xception), Frekans Dedektörleri (F3Net, SPSTL), Spatial (DRCT, SAFE), MLLM tabanlılar (CLIPping, Llama-3.2-Vision, Qwen2.5VL).
Review Makale İse İncelediği Yöntemler	İlgili Değil
Kullanılan Görseller-Grafikler	EkCot ve Data Pipeline şemaları (Şekil 1,2), Diğer LLM'ler ve MLLM'ler ile kalitatif cevap karşılaştırmaları (Şekil 3), Maske ile lokalizasyon performans şeması (Şekil 4).
Getirdiği Yenilikler-Novelty	Deepfake analizinin 1-0 tespitten çıkartılıp 'Explainable AI' konseptine taşınması. Sözel Lokalizasyon (Maske yerine doğal dille tanımlama) ve EkCot tekniği ile halüsinasyonun kırılması.
Dezavantajlar-Kısıtlar	MLLM'lerin (özellikle 7B+ parametrelili olanların) çıkarım (inference) ve eğitim maliyetleri klasik bir ResNet dedektörüne göre muazzam derecede yüksektir. Gerçek zamanlı sistemlere entegrasyonu zor olabilir.
Projeye Katkısı-Bizim İçin Önemi	Adli bilişim (forensics) raporlarında bir videonun NİYE sahte olduğunu insan dilinde açıklayabilen bir yapay zeka tasarlamak, yapay zeka destekli karar alma (AI-assisted decision making) için vazgeçilmez bir trenddir. Bu makale bu trendin öncülerinden.
Kod-GitHub Linki	Belirtilmemiş.
Durum	İncelendi
Notlar	Prompt injection mantığını tersine mühendislikle (EkCot) LLM'i eğitmek için kullanmaları harika bir yaklaşım.