

MAKALE ANALİZ RAPORU

Sorumlu Kişi	Kader Terik
Araştırma Grubu	Deepfake Detection — AISC
Makale Türü	Özgün Araştırma (Original Research)

Makale Bilgileri

Makale Adı: WaViT-CDC: Wavelet Vision Transformer With Central Difference Convolutions for Spatial-Frequency Deepfake Detection

Yazarlar: Nour Eldin Alaa Badr, Jean-Christophe Nebel, Darrel Greenhill, Xing Liang

Kurumlar: School of Computer Science and Mathematics, Kingston University London, UK

Yayınlandığı Dergi: IEEE Open Journal of Signal Processing

Cilt / Yıl / DOI: Vol. 6, 2025 | DOI: 10.1109/OJSP.2025.3571679

Anahtar Kelimeler: Deepfake detection, central difference convolutions, vision transformer, spatial-frequency analysis, discrete wavelet transform

Kaynakça (APA): Badr, N. E. A., Nebel, J.-C., Greenhill, D., & Liang, X. (2025). WaViT-CDC: Wavelet Vision Transformer With Central Difference Convolutions for Spatial-Frequency Deepfake Detection. *IEEE Open Journal of Signal Processing*, 6, 621-630. <https://doi.org/10.1109/OJSP.2025.3571679>

BÖLÜM 1 : ANLATI RAPORU

1. Çalışmanın Amacı

Deepfake (derin sahte) medyanın kötü niyetli kullanımı, bilgisayarlı görü topluluğunu yüksek genellenebilirlik (generalization) yeteneğine sahip algoritmalar geliştirmeye itmiştir. Mevcut algoritmalar genellikle yalnızca uzamsal (spatial) veya yalnızca frekans (frequency) özelliklerine odaklandıkları için, yeni ve görülmemiş veri setlerinde veya düşük kaliteli (yüksek sıkıştırılmalı) videolarda zayıf performans göstermektedir.

Çalışmanın amacı, frekans ve uzamsal etki alanlarını birleştiren uçtan uca WaViT-CDC adlı bir mimari tasarlayarak özellikle genelleme problemini çözmektir. Bu sayede ince doku değişimleri (frekans/yerel) ile küresel bağlam (uzamsal) birlikte değerlendirilecektir.

2. Problem Tanımı ve Literatür Bağlamı

Derin sahte tespitindeki başlıca problemler:

- **Uzamsal ve Frekans Odaklarının Ayrışması:** CNN veya ViT tabanlı modeller sadece uzamsal bilgiye bakarken, DCT veya Steganalysis tabanlı modeller sadece frekans domainine bakar. İkisini harmanlamak ise (örneğin SFDG [7]) genellikle çok yüksek donanım kaynağı ister.
- **Merkezi Farklılık Konvolüsyonu (CDC):** Önceki çalışmalar CDC'nin ince ayrıntıları (yerel doku farklarını) yakalamakta çok iyi olduğunu bulmuştur, ancak bu yöntem küresel özellikleri gözden kaçırmakta ve tek başına zayıf kalmaktadır.

Literatürdeki bu eksiklikleri gidermek için, model DWT (Discrete Wavelet Transform) ve CDC'yi Vision Transformer (ViT) ile birlikte kullanan hafif (kısmen) ve etkili bir birleştirme önermektedir.

3. Kullanılan Veri Seti

Değerlendirmelerde derin sahte tespitinde literatür standardı olan üç büyük veri seti kullanılmıştır:

- **FaceForensics++ (FF++):** Eğitim ve içi (intra-testing) testler için kullanılmıştır. Model hem yüksek kaliteli (HQ) hem de düşük kaliteli (LQ, yüksek sıkıştırılmış) versiyonlarında ayrı ayrı eğitilmiştir. 1000 gerçek, 4000 sahte video içerir.
- **Celeb-DF (V2):** Cross-dataset (Genelleştirme) testi için ayrılmıştır. Yüksek çözünürlüklü ve yüksek kaliteli manipülasyonlardır (590 Gerçek, 5639 Sahte).
- **WildDeepfake:** Cross-dataset testi için ayrılmış, tamamen internetten toplanan gerçek dünya verisidir (7314 yüz dizisi).

Ön İşleme (Preprocessing):

- Her videodan eşit aralıklarla 25 kare (frame) çıkarılmıştır.
- Yüzler MTCNN ile tespit edilmiş ve 224x224 boyutuna yeniden ölçeklendirilmiştir.

4. Kullanılan Yöntem / Model (WaViT-CDC)

Önerilen WaViT-CDC (Wavelet Vision Transformer with Central Difference Convolutions) üç ana bileşenden oluşur:

4.1 WaveletCDC Modülü

- **Discrete Wavelet Transform (DWT):** Görüntüyü 4 seviyeli frekans bileşenlerine (LL, LH, HL, HH) ayrıştırır. Bu işlem, görüntünün hem kaba (yaklaşım) hem de ince (yönlü detay) özelliklerini korur.
- **Central Difference Convolution (CDC) & Squeeze-Excitation (SE):** DWT'den çıkan frekans katsayıları doğrudan CDC bloklarına girer. CDC, pikseller ile komşuları arasındaki farkı (kontrastı) arttırarak ince doku manipülasyonlarını daha belirgin hale getirir. Ardından SE (Kanal Dikkati) en önemli frekans haritalarını vurgular.

4.2 Vision Transformer (ViT)

- Küresel özellikleri ve uzak bölgeler arasındaki mekansal (spatial) korelasyonları yakalamak için ImageNet-21k ile önceden eğitilmiş (pretrained) ViT kullanılmış ve bu probleme göre ince ayar (fine-tuning) yapılmıştır.

4.3 Frequency-Spatial Feature Fusion Attention (FSFFA)

- WaveletCDC'den gelen ince taneli frekans özellikleri (dikkat haritaları), ViT'in uzamsal özellikleri ile sigmoid aktivasyonu aracılığıyla çarpılarak birleştirilir. Böylece frekans bilgisi, ViT'in nereye bakması gerektiğine rehberlik eder.

4.4 Veri Artırma ve Hafif Pertürbasyonlar (Subtle Perturbations)

- Uzamsal Domain: Yüz üzerinde dlib ile 68 landmark noktası bulunur ve buralara (5x5 bölgelere) hafif Gauss gürültüsü eklenir.
- Frekans Domaini: Wavelet katsayılarına difüzyon tabanlı rastgele gürültü eklenir ve düşük katsayılar filtre (threshold) ile elenir. Bu teknik genelleştirme (generalization) üzerinde devasa bir etki yaratmıştır.

4.5 Kayıp Fonksiyonları (Loss)

- Focal Loss (zor ve yanlış sınıflandırılan örnekleri cezalandırır) ile Soft Target Cross-Entropy (Mixup ile birleştirilmiş yumuşak etiketleri yönetir) birleştirilerek kullanılmıştır.

5. Sonuçlar ve Değerlendirme

5.1 Intra-Testing (FF++ üzerinde Eğitim ve Test)

- Model FF++ (HQ) verisinde 96.35% Acc, 98.81% AUC;
- Çok zorlu FF++ (LQ - Sıkıştırılmış) verisinde 88.28% Acc, 95.82% AUC elde etmiştir. (LAA, SFDG vb. SOTA modelleriyle çok yakın sonuçlar).

5.2 Cross-Testing (Genelleştirme Performansı)

- **FF++ (LQ) Eğitimi ile Test:** Model Celeb-DF veri setinde 78.60% AUC, WildDeepfake setinde 75.91% AUC ile önceki SOTA (SFDG, LAA) modelleri geride bırakmıştır.
- **FF++ (HQ) Eğitimi ile Test:** Celeb-DF üzerinde 81.37% AUC, WildDeepfake üzerinde 81.71% AUC'ye ulaşarak genellenebilirliği bir üst seviyeye taşımıştır.

5.3 Ablasyon (Ablation) ve Açıklanabilirlik

- Sadece WaveletCDC %60 AUC sağlarken, sadece ViT %74 AUC sağlamıştır. Ancak birleşimi %81 AUC'ye çıkarak füzyonun başarısını kanıtlamıştır.
- Pertürbasyonların (özellikle frekans gürültüsü eklemenin) AUC'yi Celeb-DF üzerinde %8 (muazzam bir etki) artırdığı saptanmıştır.
- Hesaplama Karmaşıklığı (FLOPs): Sadece ViT (16.8 GMac) kullanmaktan %27 daha maliyetli (21.49 GMac) olsa da bu maliyet genelleştirme kazancına değmektedir.
- Grad-CAM/LIME sonuçlarında modelin (WaViT-CDC) yalnızca dağılmış noktalara değil; ağız, çene ve gözler gibi sahtecilik izlerinin yoğun olduğu anlamlı konturlara odaklandığı görselleştirilmiştir.

6. Literatüre Katkıları ve Kısıtları

6.1 Özgün Katkıları

- DWT (frekans ayrışımı) + CDC (merkezi fark) modüllerinin birlikte kullanılıp, çıkan yerel sonuçların ViT (Vision Transformer) küresel ağı ile harmanlanması (WaViT-CDC).

- Görsel ve frekans seviyesinde kasıtlı, hafif pertürbasyonların (gürültülerin) modele verilerek modelin genelleme ezberinden çıkarılması stratejisi (özellikle frekans gürültüsü detayı).

6.2 Kısıtlar (Sınırlılıklar)

- Donanım Maliyeti: Transformer kaynaklı yüksek işlem ve parametre (memory) kullanım ihtiyacı (21.49 GFLOPs). Çok düşük kaynaklı cihazlarda (edge computing) çalıştırılması zordur.
- Video/Temporal bilgi (kareler arası ilişki) kullanılmamaktadır; yalnızca spatial ve freq düzeyinde tekil kare işlenmektedir.

7. AISC Perspektifi: Bu Çalışma Üzerine Ne Yapılabilir?

- **Pertürbasyon (Gürültü) Stratejisi (Çok Önemli):** Makaledeki en kritik öğrenim, modele eğitim sırasında landmark bölgelerine veya frekans (DWT) verilerine küçük oranlarda rastgele difüzyon (Gauss) gürültüsü eklemenin genellenabilirliği muazzam (örneğin %8) artırdığı gerçeğidir. Mevcut projemizdeki Data Augmentation (Veri Artırımı) boru hattına bu gürültü ekleme kısmı kesinlikle entegre edilmelidir.
- **Frekans Filtrelemesi:** DWT (Ayrık Dalgacık Dönüşümü) kullanıyorsanız veya eklerseniz, çok düşük katsayıları eşikleyerek (threshold=0.01) sıfırlamak, gürültüyü azaltıp ana özelliklere odaklanılmasını sağlamıştır. AISC veri boru hattı için uygulanabilir bir tüyodur.
- **Central Difference Convolution (CDC):** AISC modelinin omurgasına (backbone) normal konvolüsyon katmanları yerine CDC katmanları eklemek, kenar ve doku manipülasyonu tespitinde büyük fark yaratabilir.

== BÖLÜM 2 : TABLO AKTARIM BLOĞU (Google Sheets) ==

Başlık	Değer
Sorumlu Kişi	Kader Terik
Atıf No	Makalede Belirtilmemiştir (2025 Yayını)
Makale Türü	Özgün Araştırma (Original Research)
Makale Adı	WaViT-CDC: Wavelet Vision Transformer With Central Difference Convolutions for Spatial-Frequency Deepfake Detection
Yıl	2025
Yazarlar	Nour Eldin Alaa Badr, Jean-Christophe Nebel, Darrel Greenhill, Xing Liang
Yayınlandığı Dergi-Konferans	IEEE Open Journal of Signal Processing, Vol. 6, s. 621-630
DOI-Link	10.1109/OJSP.2025.3571679
Kaynakça Bilgisi (APA)	Badr, N. E. A., Nebel, J.-C., Greenhill, D., & Liang, X. (2025). WaViT-CDC: Wavelet Vision Transformer With Central Difference Convolutions for Spatial-Frequency Deepfake Detection. IEEE Open Journal of Signal Processing, 6, 621-630. https://doi.org/10.1109/OJSP.2025.3571679
Kullanılan Veri Seti	FaceForensics++ (FF++) [HQ ve LQ (Sıkıştırılmış) formatları], Celeb-DF V2, WildDeepfake
Dataset Kaynağı-Linki	Açık veri setleri. (Atıf 36, 3, 37)
Veri Seti Detayı	FF++ eğitim ve intra-test için (Yüksek ve düşük sıkıştırılmalı formatlar ile 4 farklı manipülasyon). Celeb-DF V2 ve internet üzerinden toplanmış gerçek dünya örnekleri olan WildDeepfake ise zorlu (Cross-dataset) genelleme testi için.
Dataset Boyutu	FF++: 1000 Gerçek, 4000 Sahte. Celeb-DF: 590 Gerçek, 5639 Sahte. WildDeepfake: 7314 Yüz sequence.
Train-Test-Validation Ayrımı	FF++ Standard Protokolü: 740 Eğitim, 140 Doğrulama, 140 Test.
Kullanılan Model-Yöntem	WaViT-CDC (Wavelet Vision Transformer With Central Difference Convolutions)

Model Mimari Detayı	DWT (4 Seviye, frekans ayrıştırıcı) + CDC (Yerel doku ve kontrast yakalayıcı) ile WaveletCDC birimi. ImageNet-21k ViT-Base modeli (Küresel bağlam) ile FSFFA mekanizması üzerinden füzyon. Optimizer: AdamW (LR:1e-4).
Çalışmanın Amacı	Modellerin yalnızca frekans veya yalnızca uzamsal özelliklere bağlı kalması sebebiyle bilmediği veri setlerinde başarısız olması sorununu çözerek (Generalization) yüksek genellenebilirlik elde etmek.
Ölçüm Metrikleri	AUC (Area Under Curve), Accuracy, EER (Equal Error Rate)
Veri Ön İşleme Adımları	Videonun 25 kareye bölünmesi. MTCNN ile yüz kırpma, 224x224 yeniden boyutlandırma. dlib ile 68 landmark tespiti.
Data Augmentation Kullanıldı mı?	Evet, yoğun olarak. Albumentations (Mixup, CutMix, Coarse Dropout, Saturation, Image Compression). En önemlisi: Landmark (Uzamsal) noktalarına ve DWT (Frekans) katsayılarına rastgele difüzyon Gauss Gürültüsü eklenmesi (Pertürbasyon).
Çalışmanın Sonuçları	Eğitildiği model dışı veri setlerinde (Cross-testing) devasa başarı: FF++ (HQ) eğitilmiş model Celeb-DF'de %81.37 AUC, WildDeepfake'de %81.71 AUC skorları alarak eski model SOTA'larını %2.5 - %4.5 ortalama ile geçmiş ve genelleme rekorunu geliştirmiştir.
Kıyaslanan Modeller	LAA, SFDG, M2TR, Local Relation, F3-Net, Capsule, vb. SOTA modellerle geniş bir kıyaslama yapılmıştır.
Review Makale İse İncelediği Yöntemler	İlgili değil
Kullanılan Görseller-Grafikler	Şekil 1: WaViT-CDC Genel Akışı (Pertürbasyon eklentili). Şekil 2: WaveletCDC mimari detayı (DWT + CDC). Şekil 3: Grad-CAM ve LIME (Açıklanabilirlik) Haritaları.
Getirdiği Yenilikler-Novelty	Frekans (DWT) verilerine Central Difference Convolutions (CDC) uygulanarak özellik çıkarma. ViT ile füzyon. Modelin 'ezberini' kırmak için uzamsal ve frekans bazlı hassas (subtle) pertürbasyon (gürültü) kullanımı.
Dezavantajlar-Kısıtlar	Donanım ihtiyacı yüksektir (21.49 GFLOPs), ViT temelli olmasından kaynaklı. Temporal veriyi kullanamamaktadır.
Projeye Katkısı-Bizim İçin Önemi	Cross-dataset başarı (genelleme) için eğitim sırasında frekans veya landmark noktalarına bilinçli olarak hafif difüzyon/Gauss gürültüsü (pertürbasyon) eklenmesinin büyük kazanç sağladığını göstermiştir. Bu bizim projemize 'Veri Artırımı (Augmentation)' aşamasında uyarlanabilir.
Kod-GitHub Linki	https://github.com/noureldinalaa/WaViT-CDC
Durum	İncelendi
Notlar	Çok değerli teknik ipuçları içeren bir makale. (Focal Loss ve Soft Target Cross Entropy birlikte kullanımı da başarıyı artırmıştır).